

Fabio Rossi Versolatto

Infraestrutura de tecnologia da informação: fundamentos, evolução e tendências

Dados Internacionais de Catalogação na Publicação (CIP)
(Claudia Santos Costa - CRB 8ª/9050)

Versolatto, Fabio Rossi

Infraestrutura de tecnologia da informação: fundamentos, evolução e tendências / Fabio Rossi Versolatto. – São Paulo: Editora Senac São Paulo, 2025. (Série Universitária)

Bibliografia.

e-ISBN 978-85-396-5243-3 (ePub/2025)

e-ISBN 978-85-396-5244-0 (PDF/2025)

1. Tecnologia da informação – Infraestrutura. 2. Processamento de dados. 3. Sistemas operacionais. 4. Redes de computadores. 5. Virtualização. 6. Computação em nuvem. I. Título. II. Série.

25-2419c

CDD – 004

BISAC COM032000

COM043000

Índice para catálogo sistemático:

1. Infraestrutura de tecnologia da informação 004

INFRAESTRUTURA DE TECNOLOGIA DA INFORMAÇÃO: FUNDAMENTOS, EVOLUÇÃO E TENDÊNCIAS

Fabio Rossi Versolatto





Administração Regional do Senac no Estado de São Paulo

Presidente do Conselho Regional

Abram Szajman

Diretor do Departamento Regional

Luiz Francisco de A. Salgado

Superintendente Universitário e de Desenvolvimento

Luiz Carlos Dourado

Editora Senac São Paulo

Conselho Editorial

Luiz Francisco de A. Salgado

Luiz Carlos Dourado

Darcio Sayad Maia

Lucila Mara Sbrana Sciotti

Luís Américo Tousi Botelho

Gerente/Publisher

Luís Américo Tousi Botelho

Coordenação Editorial

Verônica Marques Pirani

Prospecção

Andreza Fernandes dos Passos de Paula

Dolores Crisci Manzano

Paloma Marques Santos

Administrativo

Marina P. Alves

Comercial

Aldair Novais Pereira

Comunicação e Eventos

Tania Mayumi Doyama Natal

Coordenação de Arte

Antonio Carlos De Angelis

Coordenação de Revisão de Texto

Marcelo Nardeli

Acompanhamento Pedagógico

Otacília da Paz Pereira

Designer Educacional

Priscila Arruda Ferreira de Carvalho

Revisão Técnica

Evandro Carlos Teruel

Preparação e Revisão de Texto

Ana Paula de Aquino

Projeto Gráfico

Alexandre Lemes da Silva

Emília Corrêa Abreu

Capa

Antonio Carlos De Angelis

Editoração Eletrônica e Ilustrações

Tiago Filu

Imagens

Adobe Stock Photos

Proibida a reprodução sem autorização expressa.

Todos os direitos desta edição reservados à

Editora Senac São Paulo

Av. Engenheiro Eusébio Stevaux, 823 – Prédio Editora

Jurubatuba – CEP 04696-000 – São Paulo – SP

Tel. (11) 2187 4450

editora@sp.senac.br

<https://www.editorasenacsp.com.br>

© Editora Senac São Paulo, 2025

Sumário

Capítulo 1 Introdução à infraestrutura de tecnologia da informação (TI), 7

- 1 O que é infraestrutura de TI?, 8
 - 2 A evolução da infraestrutura da tecnologia da informação no contexto histórico, 12
 - 3 O papel da infraestrutura de TI nas organizações digitais, 16
- Considerações finais, 19
- Referências, 20

Capítulo 2 Processamento de dados: centralizado e distribuído, 21

- 1 Servidor: conceito, classificação, componentes e principais usos, 22
 - 2 Centro de processamento de dados (*data centers*), 33
 - 3 Processamento de dados distribuídos, 38
- Considerações finais, 39
- Referências, 39

Capítulo 3 Sistemas operacionais, 41

- 1 A evolução dos sistemas operacionais no contexto histórico, 42
 - 2 Objetivos de um sistema operacional, 44
 - 3 Arquitetura de sistemas operacionais, 47
 - 4 Tipos de sistemas operacionais, 51
- Considerações finais, 55
- Referências, 55

Capítulo 4 Redes de computadores, 57

- 1 Introdução ao conceito de redes de computadores, 58
 - 2 Modelo de referência OSI, 60
 - 3 Camada física, 62
 - 4 Camada de enlace, 65
 - 5 Camada de rede, 66
 - 6 Camada de transporte, 68
 - 7 Camada de sessão, 69
 - 8 Camada de apresentação, 70
 - 9 Camada de aplicação, 70
 - 10 Introdução ao conceito de segurança de redes, 72
- Considerações finais, 73
- Referências, 74

Capítulo 5 Virtualização, 75

- 1 Introdução ao conceito de virtualização de *hardware*, 76
 - 2 Vantagens e desvantagens da virtualização, 77
 - 3 Virtualização de máquinas, 80
 - 4 Virtualização de armazenamento, 82
 - 5 Virtualização de redes, 83
 - 6 Introdução ao conceito de containerização, 86
- Considerações finais, 90
- Referências, 91

Capítulo 6

Computação em nuvem, 93

- 1** Introdução ao conceito de *cloud computing*, 94
 - 2** Vantagens e desvantagens no modelo de computação em nuvem, 96
 - 3** Tipos de *cloud*, 99
 - 4** Modelos de serviço de *cloud*, 101
 - 5** Introdução ao conceito de segurança na abordagem de computação em nuvem, 105
- Considerações finais, 109
- Referências, 109

Capítulo 7

Governança de infraestrutura de TI, 111

- 1** Introdução ao conceito de governança, 112
 - 2** Pilares da governança de TI, 116
 - 3** Metas e métricas, 122
- Considerações finais, 125
- Referências, 126

Capítulo 8

Infraestrutura de TI: presente e futuro, 127

- 1** Infraestrutura como código, 128
 - 2** Infraestrutura em *big data*, 133
 - 3** Infraestrutura em Internet das Coisas (IoT), 136
 - 4** Infraestrutura para aprendizado de máquina e inteligência artificial, 140
- Considerações finais, 144
- Referências, 145

Sobre o autor, 149

Introdução à infraestrutura de tecnologia da informação (TI)

A tecnologia da informação (TI) tem papel fundamental em um mundo cada vez mais digital, em que empresas, universidades, governos e organizações interagem entre si e se integram na busca da formação de ecossistemas que tenham como objetivos a resolução de problemas de forma conjunta, a eficiência, a eficácia e a inovação.

Neste primeiro capítulo, discutiremos os fundamentos teóricos e tecnológicos implicados na composição da infraestrutura de sistemas de informação e abordaremos, em perspectiva histórica, a evolução da infraestrutura de TI, fazendo um paralelo com as tecnologias atuais nas organizações digitais.

1 O que é infraestrutura de TI?

Ao falarmos em infraestrutura, automaticamente somos levados a pensar em estruturas e componentes tangíveis, ou seja, que podemos ver, tocar e sentir. Se estivermos dentro do contexto da tecnologia, classificaremos como infraestrutura tudo aquilo que é perceptível no meio físico, como por exemplo, sistemas de hardware.

Essa ideia está relacionada à etimologia da palavra “infraestrutura”: “infra” + “estrutura” que, segundo o dicionário, estão relacionadas a elementos que servem de base ou de suporte para a construção ou desenvolvimento de algo (Infraestrutura, 2009).

Aproximando esse conceito da engenharia civil, tão comum no nosso dia a dia, poderíamos dizer que a infraestrutura de uma casa ou prédio é composta por suas fundações, vigas e colunas, ou ainda, que o sistema de saneamento básico corresponde à infraestrutura de uma cidade.

Aqui, temos um aspecto importante para entendermos o conceito de infraestrutura, que serve tanto no contexto da engenharia civil quanto da tecnologia da informação (TI): a infraestrutura está diretamente relacionada ao problema que pretendemos resolver.

A definição de infraestrutura no contexto da tecnologia da informação também foi se modificando à medida em que os problemas a serem resolvidos pela TI se tornaram mais complexos (Laan, 2017).

Há algum tempo, poderíamos resumir infraestrutura de TI apenas como sistemas de hardware, e ficaríamos restritos a computadores e

equipamentos responsáveis por conectá-los, como cabos de redes, *switches* e *hubs*. Essa é uma visão limitada do que de fato é a infraestrutura de tecnologia da informação atualmente, e a definição do ITIL, apresentada a seguir, nos ajuda a ampliar esse conceito.



PARA SABER MAIS

O ITIL, do inglês *Information Technology Infrastructure Library*, é um *framework* que auxilia as empresas a alinharem seus objetivos aos recursos e serviços de TI, de forma que a tecnologia seja utilizada de maneira eficiente e eficaz para resolver os problemas de negócio.

Um *framework*, de forma resumida, é um conjunto de boas práticas que já foram testadas, aplicadas e possivelmente melhoradas para atingir um determinado objetivo.

No caso do ITIL, o *framework* nos oferece um guia de como entregar mais valor ao usuário de tecnologia, aumentar a eficiência e a eficácia operacional, aumentar a produtividade dos times e, principalmente, promover maior adaptabilidade das soluções tecnológicas às diferentes e constantes mudanças do mercado.

Ele é utilizado por grandes empresas de tecnologia, como IBM e Microsoft, e por entidades governamentais e empresas privadas do mercado financeiro, de saúde e de educação (Axelos, 2019).

Segundo o *framework*, infraestrutura de TI inclui todos os componentes de tecnologia e recursos necessários para fornecer serviços de TI de forma eficiente e eficaz. Esses componentes correspondem a sistemas de hardware, software, redes, instalações e equipamentos utilizados para resolver problemas dos usuários de tecnologia. A essa lista de componentes, poderíamos adicionar desde computadores pessoais até *data centers*, passando por servidores, dispositivos de redes e por sistemas de software, como sistemas operacionais e aplicações destinadas ao usuário final (Axelos, 2019).

Aqui, temos outro ponto importante: a visão do que é infraestrutura de TI e quais são seus componentes está ligada ao contexto do problema em que ela está inserida e está relacionada à visão que o usuário final tem sobre o que se pretende resolver (Laan, 2017).

Quando falamos em objetivos ou problemas de negócios a serem resolvidos, em um primeiro momento, não estamos falando propriamente da implementação ou implantação de uma tecnologia. Um processo de negócio é um conjunto de atividades executadas em determinada sequência, por indivíduos (ou papéis) que têm como objetivo resolver um problema específico. Nesse processo, é possível que existam entradas, que chamamos de insumos e que ao final dessa execução tenhamos uma saída (Hammer e Champy, 1993).



NA PRÁTICA

Para entender o que é um processo de negócio, imagine um exemplo de uma empresa que tem como objetivo de negócio o envase e a distribuição de refrigerantes. Considere que esse seja um processo simples, em que, primeiramente, uma pessoa é responsável por retirar os refrigerantes envasados de uma máquina e colocá-los em caixas com uma determinada quantidade. Assim que uma caixa fica completa, ela é fechada e etiquetada, indicando que saiu da linha de produção.

As caixas são enviadas para uma área de qualidade, responsável por verificar se os produtos estão seguindo os padrões da companhia. Os testes são feitos, os produtos reprovados são enviados para descarte enquanto os aprovados são enviados para a área de expedição.

A expedição é responsável por emitir uma nota fiscal de saída para cada lote de caixas de refrigerante. Esse documento precisa ser conferido e assinado pela pessoa responsável pelo departamento.

As notas fiscais são anexadas ao lote de caixas e enviadas para o departamento de logística, que é responsável por montar o melhor arranjo possível para os lotes, endereços de entrega e veículos que transportarão as bebidas. Todas as informações referentes ao lote, veículo e trajeto devem ser anotadas para que seja mantida a rastreabilidade das entregas.

No momento da entrega, o documento fiscal é assinado pela pessoa responsável pelo recebimento, uma cópia dessa nota fica no local de entrega e outra é enviada de volta para a empresa, onde é armazenada em um local específico para futuras consultas.

Nessa pequena e resumida história, foi apresentado um processo em que podemos notar alguns aspectos importantes: quais atividades foram executadas, a sequência lógica de execução e quais são as pessoas ou cargos responsáveis por essa execução. Ademais, é possível identificar as entradas e saídas de cada atividade. Este é um exemplo de processo de negócio e está diretamente ligado ao negócio “envasamento e distribuição de refrigerantes”.

Sob o ponto de vista desse processo, referem-se à infraestrutura de TI todos os componentes tecnológicos que dariam sustentação a ele, seja na automatização e possivelmente no acréscimo da eficiência e eficácia da sua execução.

Neste caso, poderíamos citar como exemplos de infraestrutura de tecnologia da informação: computadores, servidores, ativos de rede (como cabeamento, *hubs* e roteadores), *scanners* de leitura e dispositivos de armazenamento (*storage*). A essa lista, poderíamos acrescentar sistemas de *software*, como sistemas operacionais, sistemas ERP e sistemas de controle logístico, por exemplo.

Em contrapartida, se o nosso processo de negócio não fosse o caso da fábrica de refrigerantes, mas sim de uma empresa cujo objetivo é a produção e desenvolvimento de um sistema de *software*, a lista de componentes de infraestrutura de tecnologia da informação não seria a mesma.

Neste caso, a infraestrutura que suportaria esse negócio poderia ser formada por computadores pessoais, dispositivos de Internet das Coisas (IoT) para testes, servidores, dispositivos de rede, sistemas operacionais e sistemas de *software* utilizados para a programação, por exemplo.



PARA SABER MAIS

O correto mapeamento e documentação de processos de negócio é parte importante no sucesso de um projeto (Hammer e Champy, 1993).

Uma abordagem muito utilizada e que nos auxilia nesse trabalho é o BPMN, do inglês *Business Process Model and Notation*. O BPMN é um padrão de modelagem que tem como objetivo auxiliar no desenvolvimento, projeto e análise de processos de negócio a partir de uma notação gráfica (OMG, 2011).

Por se tratar de um padrão aberto e gráfico, a abordagem tem por finalidade promover a comunicação mais fluida entre equipe técnica, de projetos e usuários de negócio.

Em resumo, o processo de negócio tem como objetivo resolver um determinado problema do mundo real e a infraestrutura de TI corresponde aos componentes tecnológicos que dão suporte à sua execução (Laan, 2017).

2 A evolução da infraestrutura da tecnologia da informação no contexto histórico

Agora que já sabemos o que é infraestrutura de TI, nesta sessão vamos entender a sua evolução dentro de uma linha do tempo. Aqui, o objetivo será traçarmos um paralelo das tecnologias emergentes atuais com tecnologias passadas.

Seria muito complexo encaixarmos de forma cronológica todas as tecnologias relevantes que compuseram a evolução dos últimos anos. Todavia, a International Data Corporation (IDC) – consultoria de tecnologia que desenvolve pesquisas com alto grau de confiabilidade – propõe uma subdivisão dessas tecnologias em “gerações”, que ela chamou de “plataformas”.

A primeira geração, ou plataforma, compreende o período entre 1960 e 1980. Essa plataforma se caracteriza pelo processamento de dados centralizado, e a tecnologia que melhor representa esse período são os *mainframes*.

Você poderia perguntar: “não existe nenhuma categoria anterior a 1960?”. E a resposta é simples: a classificação inicia-se no final da década de 1950, mais propriamente em 1958, quando do advento do circuito integrado. Anterior a essa data, temos o que chamamos de momento zero da computação: computadores com válvulas termiônicas, cabos elétricos e tubos a vácuo.

A segunda plataforma data do intervalo de 1980 até os dias atuais. A segunda geração possui dois grandes marcos: a popularização dos computadores (computadores pessoais) e o processamento de dados descentralizado, ou, computação distribuída (IDC, 2005).

O aumento massivo da utilização dos computadores, conhecidos como “computadores pessoais”, teve como característica principal componentes eletrônicos em menor tamanho, consumindo menos energia e com maior capacidade computacional se comparado aos dispositivos anteriores.



PARA SABER MAIS

Em 1965, Gordon Moore (cofundador da Intel) afirmou que o número de transistores em um chip de circuito integrado dobraria em um período de dois anos, enquanto os custos de produção e de consumo de recursos desses circuitos diminuiriam no mesmo período (Moore, 1965).

Essa afirmação ficou conhecida como a Lei de Moore, e nos ajuda a explicar o fenômeno do aumento de capacidade computacional, a diminuição de tamanho dos circuitos e a massificação de seu uso, tendo em vista a diminuição dos custos.

Chamamos de computação descentralizada, ou distribuída, a capacidade de executarmos pedaços de um sistema de *software* em diferentes computadores. O objetivo aqui é aumentarmos a capacidade computacional e reduzirmos custos, ou seja, quando antes tínhamos um grande computador (*mainframe*) com todos seus custos, passaríamos a ter vários computadores trabalhando em conjunto para processar mais dados em menos tempo com menor custo (Tanenbaum e Van Steen, 2007).

Ainda segundo os autores, a computação distribuída deu origem a uma abordagem arquitetural chamada “cliente/servidor”, em que uma parte do processamento acontecia em um computador chamado cliente e outra parte em um computador chamado servidor. Essa arquitetura contribuiu muito para o que chamamos de *world wide web*, ou simplesmente: internet.

A razão pela qual a geração conhecida como segunda plataforma data até os dias atuais é a utilização atual das duas tecnologias que marcam essa plataforma: computação distribuída e utilização de computadores pessoais.

Nesse momento, temos um rápido aumento na capacidade computacional (apoiada pela Lei de Moore) somado à evolução das redes de computadores e das telecomunicações. O resultado desse cenário é a base para o que chamamos de terceira plataforma (IDC, 2005).

A terceira plataforma, ou terceira geração, engloba todas as tecnologias das plataformas anteriores somadas ao aumento de capacidade computacional e de telecomunicações. Essa plataforma é rotulada de “combinação de plataformas” e tem data de início nos anos 2000 e continua até os dias atuais (IDC, 2005).


Surgem aqui as tecnologias móveis, embarcadas e redes móveis ou não cabeadas de alta velocidade e, a partir disso, termos como Internet das Coisas (*Internet of Things* – IoT). O aumento da capacidade computacional

dos servidores, dentro de um modelo arquitetural cliente/servidor, somado à evolução das telecomunicações, em que pesa a diminuição da latência das redes entre os computadores, cria um modelo de comercialização de *datacenter*, a computação em nuvem (*cloud computing*).

Ainda são exemplos de tecnologias da terceira plataforma: redes sociais, geração, armazenamento e processamento de grandes volumes de dados com formatos variados (*big data*) e sistemas baseados em algoritmos de inteligência artificial (*machine learning*) (IDC, 2005).

Na figura 1, é apresentada, de forma gráfica e resumida, a linha do tempo das três plataformas, colocando abaixo de cada uma, as principais tecnologias que as marcam.

Figura 1 – Evolução da infraestrutura da tecnologia da informação



É importante notar, ainda na figura 1, que a evolução das plataformas se dá, principalmente, pela evolução dos circuitos integrados, apoiados pela Lei de Moore, e pela evolução das tecnologias de rede e das telecomunicações.



PARA PENSAR

Vimos que *cloud computing* é resultante do modelo de computação distribuída, associado a um aumento da capacidade computacional e da evolução das telecomunicações, que promoveu um modelo economicamente viável de fornecimento de serviços computacionais em larga escala a partir da internet. Logo, podemos concluir que essa tecnologia não é algo totalmente disruptivo, mas sim, o produto da evolução das tecnologias.

Os algoritmos de inteligência artificial (IA) e aprendizado de máquinas também não são necessariamente novos. O algoritmo de classificação de Naive Bayes, por exemplo, passou a ser estudado em computação na década de 1960.

Para maior eficiência na execução, algoritmos de IA necessitam de duas coisas: alta capacidade computacional e grande volume de dados.

Inteligência artificial e aprendizado de máquina seriam tecnologias 100% novas e disruptivas ou, assim como *cloud computing*, poderiam ser classificadas como tecnologias que surgiram da combinação de tecnologias anteriores somadas a evolução natural das plataformas?

3 O papel da infraestrutura de TI nas organizações digitais

Como vimos no início desse capítulo, a infraestrutura de tecnologia da informação tem como principal objetivo o aumento da eficiência e da eficácia na execução dos processos de negócio. Vimos também que, em um curto tempo, a evolução e a combinação de tecnologias criaram um cenário em que essas tecnologias passam a ser cada vez mais acessíveis.

Segundo Sousa Neto (2019), a tecnologia da informação passa a ter um papel maior do que simplesmente automatizar os processos de negócio e começa a ser vista como um elemento estratégico para as

empresas. Podemos observar essa mudança de paradigma corporativo na relação com a tecnologia da informação no termo “transformação digital”.

Ainda segundo o autor, em um mundo em que os negócios são feitos cada vez mais utilizando a infraestrutura da tecnologia da informação, a transformação digital relaciona a TI ao “papel-chave na transformação da estratégia, estrutura, processos e cultura de uma empresa” (Sousa Neto, 2019, p. 11).

O mesmo autor ainda observa que “a TI só possui valor no contexto da estratégia das corporações.” (Sousa Neto, 2019, p. 12). Podemos notar aqui uma mudança na fatia que a infraestrutura de TI passa a ocupar dentro do planejamento estratégico das empresas.

A transformação digital leva ao aumento na capacidade de conexão e integração entre as empresas, promovido pelo avanço da infraestrutura de TI, fomentando um novo modelo de negócios. Nele, as empresas interagem entre si, fornecendo seus serviços e trocando informações de forma digital, de tal forma a criar um ecossistema corporativo (Sousa Neto, 2019).

Por exemplo, imagine que você tenha uma empresa de comércio eletrônico, cujo objetivo final seja conectar pessoas que estejam vendendo um determinado produto com pessoas que eventualmente queiram comprar este produto. Para viabilizar essa conexão, você se utiliza de um website.

Aqui, temos um aspecto importante: o objetivo de negócio bem definido. Seu objetivo é conectar pessoas vendedoras e pessoas compradoras, excluindo dessa proposta outras missões como operação de pagamento, controle da logística de entrega e devolução dos produtos, por exemplo.

Todavia, sabemos que não existe uma plataforma de compra on-line que não tenha incorporado um processo de pagamento. Sabemos

também que este processo não é tão simples, pois envolve uma série de regras como verificar se um cartão de crédito é válido, se possui saldo, se não é produto de furto ou fraude, etc.

Por sua vez, existem empresas cujo objetivo de negócio é processar meios de pagamento em toda a sua complexidade. Para tal, disponibilizam esses serviços para serem consumidos de forma digital, utilizando todos os recursos que a infraestrutura de tecnologia da informação fornece.

Esse exemplo mostra como temos duas empresas, com seus respectivos objetivos de negócio muito bem definidos, interagindo entre si para resolver problemas em comum, tendo como meio a infraestrutura da tecnologia da informação.

Neste cenário de tecnologia, poderíamos enumerar vários componentes de infraestrutura que fariam parte dessa integração: rede, servidores, estruturas de armazenamento de dados e sistemas de segurança da informação, por exemplo.

Essa mesma lógica poderia ser aplicada na integração com uma empresa responsável pela logística dos pedidos, bem como com uma companhia cuja ênfase seja o atendimento ao consumidor. Novamente, veríamos um ecossistema formado por duas ou mais empresas, que se integram para executar um determinado processo de negócio.

Além de fomentar a integração entre as empresas, a transformação digital e o aumento do percentual da tecnologia da informação promoveram a criação das chamadas empresas “*techs*”. Empresas cujo objetivo não é produzir tecnologia em si, mas utilizá-la (principalmente da 3ª plataforma) como motor principal para alavancar seus negócios (Sousa Neto, 2019).

No setor de serviços, temos empresas que atuam em áreas como finanças (*fintechs*), educação (*edtechs*), recursos humanos (*RHtechs* ou *HRtechs*) e seguros (*insuretechs*). A incorporação de tecnologias como

inteligência artificial e Internet das Coisas (IoT) pela indústria criou o conceito de Indústria 4.0, enquanto as mesmas tecnologias, utilizadas no propósito de solucionar problemas dos centros urbanos, forjou a ideia de “cidades inteligentes” (*smart cities*).

Poderíamos citar ainda empresas startups que se utilizam de *big data* associado a grande capacidade computacional e de processamento presentes nas infraestruturas de tecnologia atuais para extrair valor para setores como saúde e agronegócio.



PARA SABER MAIS

Startups são empresas emergentes, ou iniciantes, que trabalham num cenário de grande incerteza, que buscam a solução de problemas ou o aprimoramento de modelos de negócio a partir da inovação e que têm na tecnologia da informação uma grande aliada (Sebrae, 2022).

Considerações finais

Infraestrutura de tecnologia da informação é o nome dado ao conjunto de componentes tecnológicos que apoiam e suportam a execução de processos de negócio. Estes são sequências de atividades executadas de uma determinada forma por pessoas ou papéis dentro de uma organização e que têm como objetivo resolver um determinado problema. Chamamos de visão integrada de TI a união de processos de negócio e infraestrutura.

A evolução tecnológica ao longo dos anos, fomentada pelo aumento da capacidade computacional, redução dos custos e aumento na capacidade das telecomunicações e das redes de computadores, culminou com a combinação de tecnologias ditas disruptivas.

Esse cenário fez com que a infraestrutura de tecnologia da informação ocupasse cada vez mais o protagonismo no planejamento estratégico das corporações, promovendo a transformação digital e a criação das organizações digitais.

Referências

AXELOS. **ITIL Foundation: ITIL 4 Edition**. Londres: TSO (The Stationery Office), 2019.

HAMMER, Michael; CHAMPY, James. **Reengineering the Corporation: A Manifesto for Business Revolution**. Nova York: Harper Business, 1993.

IDC. International Data Corporation. Página inicial. **IDC Corporate**, 2005. Disponível em: <https://www.idc.com/>. Acesso em: 18 mar. 2025.

INFRAESTRUTURA. In: DICIO, **dicionário online de português**. Porto: 7Graus, 2009. Disponível em: <https://www.dicio.com.br/infraestrutura/>. Acesso em: 18 mar. 2025.

LAAN, Sjaak. **IT Infrastructure Architecture – Infrastructure Building Blocks and Concepts**. 3. ed. [S. l.]: Lulu Press Inc., 2017.

MOORE, Gordon E. **Cramming more components onto integrated circuits**. Electronics, v. 38, n. 8, p. 114-117, 1965.

OMG. Object Management Group. **Business Process Model and Notation (BPMN)**. OMG Specification, 2011. Disponível em: <https://www.omg.org/spec/BPMN/>. Acesso em: 18 mar. 2025.

SEBRAE. O que é uma startup? **Sebrae**, 2022. Disponível em: <https://sebrae.com.br/sites/PortalSebrae/artigos/o-que-e-uma-startup,6979b2a178c83410VgnVCM1000003b74010aRCRD>. Acesso em: 18 mar. 2025.

SOUSA NETO, Manoel Veras de. **Gestão da tecnologia da informação: sustentação e inovação para a transformação digital**. Rio de Janeiro: Brasport, 2019.

TANENBAUM, Andrew S.; VAN STEEN, Maarten. **Distributed Systems: Principles and Paradigms**. 2. ed. Londres: Pearson Education, 2007.

Processamento de dados: centralizado e distribuído

Como vimos, a infraestrutura da tecnologia da informação é o conjunto de componentes tecnológicos que apoiam a execução dos processos de negócio de uma empresa. Entre as tecnologias surgidas na chamada “segunda plataforma” (ou “segunda geração”), destacam-se as que fizeram parte do processo de descentralização do processamento de dados, a computação distribuída.

Quando falamos de computação distribuída, automaticamente somos levados ao surgimento da arquitetura cliente/servidor, e no centro dela, como consta no próprio nome, temos os servidores.

Neste capítulo, abordaremos os diferentes tipos de servidores, suas aplicabilidades e as características que distinguem cada um. Apresentaremos também o conceito de *data centers* e como eles evoluíram desde a fase do processamento centralizado até se tornarem pilares na modernização da infraestrutura de tecnologia da informação das corporações.

1 Servidor: conceito, classificação, componentes e principais usos

Na tecnologia, a palavra “servidor” nos remete a enormes computadores, com grande capacidade computacional e que, geralmente, são instalados em locais específicos e preparados dentro das estruturas prediais das empresas.

Essa figura que habita nosso imaginário não está completamente errada. Segundo Laan (2017, p. 30), de forma resumida, um servidor é “uma capacidade computacional física ou virtual alocada em *datacenters*”.

Enquanto isso, Tanenbaum e Wetherall (2011) contextualizam o termo de forma semelhante, apresentando um servidor como um sistema computacional de capacidade avançada que pode ser físico (com *hardware* dedicado) ou virtual, acrescentando ainda que são projetados para fornecer serviços, dados ou recursos para outros sistemas computacionais em uma rede.

Aqui, adicionamos um conceito importante à nossa ideia inicial de enxergar servidores não apenas como sistemas de *hardware* com grande capacidade computacional, mas sim como componentes fornecedores

de serviços para outros componentes em uma rede. Damos a esses outros componentes o nome de “clientes”.

Em resumo, servidores são sistemas computacionais de *hardware* físicos ou virtuais que, dentro do modelo cliente/servidor, têm como objetivo fornecer um serviço para outro componente. A classificação dos tipos de servidores se dá principalmente a partir dos tipos de serviços que eles fornecem.

Os servidores são capacidades computacionais que executam poucas e específicas tarefas e fornecem um único tipo de serviço em uma rede, logo, a classificação a partir do tipo de serviço fornecido é muito utilizada (Laan, 2017).



IMPORTANTE

A classificação dos servidores a partir do seu tipo independe do seu modelo de implantação, podendo ser por meio de um *hardware* físico e dedicado ou por recurso virtualizado.

De acordo com Bass *et al.* (2012), alguns dos tipos de servidores mais utilizados na indústria da tecnologia da informação são:

- **Servidor de aplicações (*application server*):** é a combinação de sistemas de *hardware* e *software* que tem como objetivo fornecer a infraestrutura necessária para execução de aplicações corporativas, como, por exemplo, ERP(s), sistemas bancários ou sistemas que implementem ambientes de educação a distância.
- **Servidor web (*web server*):** é uma solução de *software* e *hardware* projetada com o objetivo de receber requisições de conteúdo, solicitadas por um cliente (por exemplo, um navegador) e entregar esse conteúdo utilizando um protocolo web padrão (protocolo HTTP, por exemplo). Os conteúdos entregues são do tipo

estáticos: texto em formato HTML (ou outros formatos padrões web), folhas de estilo (CSS) ou imagens.

- **Servidor de banco de dados (*database server*):** é um componente que combina *software* e *hardware* e tem como objetivo principal armazenar, gerenciar e fornecer acesso a um banco de dados. Ademais, serve como infraestrutura necessária para a execução dos SGBD(s) (sistemas gerenciadores de banco de dados), que visam garantir a atomicidade, consistência, isolamento e durabilidade das informações armazenadas neles.



NA PRÁTICA

Na prática, os servidores de aplicações, web e de banco de dados correspondem ao tripé que dá sustentação à abordagem cliente/servidor. É a partir da infraestrutura promovida por eles que conseguimos, por exemplo, implantar aplicações corporativas e acessar e consumir suas funcionalidades de qualquer outro dispositivo em uma rede.

Ainda sobre servidores que dão sustentação ao funcionamento da arquitetura cliente/servidor, que é a base de tudo que conhecemos na web, segundo Tanenbaum e Wetherall (2011), temos mais três que merecem destaque:

- **Servidor DNS (*domain name system*):** atua como um serviço de tradução, que traduz um endereço web mais amigável a um ser humano para um endereço de máquina de um servidor web ou um servidor de aplicações. Por exemplo, imagine que o endereço do seu site de notícias preferido fosse “185.47.63.95”. Na prática, todas as vezes que você quisesse ler suas notícias, em vez de inserir um endereço amigável, como “www.meusitedenoticias.com.br”, você teria que digitar uma sequência de números e pontos. Em resumo, um servidor DNS serve para armazenar uma grande tabela de “de/

para", como uma espécie de lista telefônica, que tem como objetivo facilitar a navegação na web.

- **Servidor proxy:** atua como um intermediário entre clientes e servidores, ou seja, uma requisição de conteúdo que sai de um cliente passa obrigatoriamente por um servidor *proxy* antes de chegar ao servidor de destino. A inclusão deste serviço em uma arquitetura de redes não é obrigatória, porém, é aconselhável, uma vez que ele auxilia na segurança, filtro de tráfego, registros de atividades e solicitações, além de otimizar o desempenho de aplicações a partir da implementação de mecanismos de *caching*.
- **Servidor FTP (*file transfer protocol*):** na troca de informações entre dois dispositivos em rede (por exemplo, na web), temos uma série de protocolos que garantem a comunicação eficiente entre esses dispositivos. Dentre eles, o mais conhecido é o protocolo HTTP (e suas variações), porém, ele não é o único. O protocolo FTP tem como objetivo permitir a transferência eficiente de arquivos entre dispositivos de uma rede, logo, um servidor FTP fornece toda a infraestrutura para apoiar essa troca.



PARA SABER MAIS

No universo corporativo, existem outros tipos de servidores que valem a pena o estudo: servidor de e-mail (*email server*), de arquivos (*file server*), de impressão (*print server*) e de backup (*backup server*).

Outra classificação de servidores que não anula a categorização a partir de sua funcionalidade é a classificação baseada em sua estrutura física. Nessa classificação, conta exclusivamente a forma de instalação e disposição do sistema de *hardware* do servidor.

Até o início dos anos 2000, os sistemas de *hardware* de um computador e dos servidores eram estruturas autocontidas, ou seja, em uma única unidade tínhamos todas as capacidades computacionais de processamento, armazenamento e comunicação (Laan, 2017).

Essa estrutura é chamada de sistema completo autônomo, por isso e pelo seu formato físico, os computadores e servidores eram chamados de pedestais ou torres e eram colocados no chão dos *data centers* (Laan, 2017). Na figura 1, é apresentado um servidor do tipo torre, ou em inglês *tower*, também encontrado na bibliografia como pedestal.

Figura 1 – Servidor do tipo torre



Com a necessidade cada vez maior no aumento da capacidade computacional, um assunto que até então era tratado de forma secundária, passou a ser prioridade nas discussões: a escalabilidade da infraestrutura dos servidores.

Escalabilidade refere-se à capacidade de um sistema, rede ou processo de lidar com o crescimento da demanda (seja em dados, usuários ou cargas de trabalho), mantendo ou até melhorando sua eficiência. Em termos de infraestrutura de servidores, escalabilidade significa poder aumentar a capacidade computacional conforme necessário, seja incrementando recursos de hardware ou adicionando novos servidores.

Segundo Stallings (2016), existem dois tipos de escalabilidade:

- **Vertical:** é aquela em que, para aumentarmos a capacidade computacional, aumentamos recursos a um sistema de *hardware*. Exemplo: se precisamos de mais memória em um servidor, adicionamos mais memória (física) àquele *hardware*.
- **Horizontal:** para aumentarmos a capacidade computacional, adicionamos mais um sistema de *hardware* para trabalhar em conjunto com os já existentes. De forma prática, adicionamos mais um servidor para dividir a carga de trabalho com os demais servidores que já existem na rede.



PARA SABER MAIS

O termo *cluster* refere-se a um conjunto de recursos computacionais (computadores ou servidores) independentes que atuam em conjunto, como se fossem um único sistema de *hardware* com o objetivo de aumentar a capacidade e a escalabilidade computacional.

Para servidores do tipo torre, a escalabilidade vertical pressupõe compra e inclusão de novos recursos de *hardware*, o que chamamos de *upgrade*, o que se torna caro e ineficiente a longo prazo. Enquanto escalar de forma horizontal significa adicionar mais torres a um *cluster* de servidores, necessitando assim de mais espaço físico, o que também é inviável.

Servidores do tipo rack são projetados para aumentar a escalabilidade e otimizar o uso do espaço físico. Nesse modelo, uma estrutura metálica é projetada e os servidores são encaixados nela como “gavetas”, formando um *cluster* de máquinas. Importante ressaltar que os servidores continuam tendo as mesmas capacidades computacionais e componentes de um servidor do tipo torre (Stallings, 2016).

Na figura 2, é apresentada uma estrutura de servidor do tipo rack, na qual é possível notar uma estrutura metálica que se assemelha a uma estante, cujo padrão geralmente é 19 polegadas, e dentro dela os servidores que se assemelham a gavetas.

Figura 2 – Servidor do tipo rack



A arquitetura de servidores em rack sem dúvida é uma grande aliada quando o assunto é escalabilidade e ocupação do espaço físico, todavia, a evolução nos levou a otimizar ainda mais este modelo: os servidores em lâmina, ou *blade systems*.

Servidores do tipo *blade* se assemelham aos do tipo rack sob o ponto de vista em que cada servidor é uma unidade independente de processamento e armazenamento, mas diferem em dois pontos específicos: cada servidor é um módulo projetado para ser inserido em uma plataforma comum (diferentemente das “gavetas” do rack) e estes servidores compartilham recursos, principalmente alimentação de energia e rede. Com servidores menores, podemos inserir mais recursos na plataforma comum, também chamada de chassi. Consequentemente teremos mais capacidade computacional em menor espaço físico. Além do mais, o compartilhamento de recursos de energia e rede faz com que o consumo e a gestão do cabeamento também sejam otimizados (Stallings, 2016).

Na figura 3, é apresentada uma estrutura de servidores organizados em lâminas (*blade system*). Nela é possível notar que cada servidor é uma “pequena gaveta” que se encaixa em uma estrutura (ou chassi) padrão.

Figura 3 – Servidor do tipo lâmina (*blade system*)



Por algumas vezes, citamos o termo “capacidade computacional” de um servidor. Ela pode ser definida como a quantidade de recursos que um sistema computacional possui para executar tarefas e pode ser

dividida em três categorias: capacidade de processamento, armazenamento e comunicação. Para cada categoria temos um *hardware* ou um conjunto de componentes capazes de executar aquela capacidade. Para a capacidade de processamento, temos os processadores (ou CPU(s)); para armazenamento, as unidades de memória e disco, e para comunicação, a responsabilidade fica por conta dos barramentos e dos componentes de rede (Stallings, 2016).

O processador, também chamado de CPU (*central processing unit*) é o que chamamos popularmente de “cérebro do computador”. Ele é um circuito integrado responsável por executar cálculos e tomadas de decisão e, para isso, atua como um orquestrador na alocação de outros recursos do computador, como a memória, por exemplo (Stallings, 2016).



PARA SABER MAIS

Dois dos principais fabricantes de processadores, Intel e AMD, utilizam um padrão arquitetural chamado x86 para suas CPU(s), tanto para 32 quanto para 64 bits. Todavia, diferem entre si pelo projeto físico de suas unidades, denominado microarquitetura. Ambos os fabricantes possuem uma linha de evolução dos seus processadores que vale a pena ser estudada (Veras, 2009).

Os processadores também podem ser classificados quanto ao seu uso e, para cada categoria, há um projeto de unidade diferente. Processadores de uso geral, ou de propósito geral, são aqueles capazes de executar tarefas mais genéricas, de qualquer tipo de *software*. Enquanto isso, processadores dedicados são projetados para execução de tarefas específicas, que necessitam de maior desempenho (Stallings, 2016).

Processadores de uso geral são os mais utilizados em computadores pessoais e em boa parte dos servidores. São exemplos de processadores dedicados: processadores para realização de cálculos aritméticos

complexos, execução de algoritmos de inteligência artificial e *machine learning*, mineração e processamento de criptoativos, bem como os processadores gráficos (utilizados em aplicações CAD, artes gráficas e jogos digitais). Os processadores utilizados nos servidores da arquitetura *main-frame* também são exemplos de processadores dedicados.

Segundo Stallings (2016), as unidades de armazenamento correspondem aos componentes que têm como objetivo guardar informações utilizadas na execução das tarefas. Essas unidades, também chamadas de memória, podem ser voláteis ou persistentes.

Ainda segundo o autor, memórias voláteis são aquelas cujas informações são armazenadas de forma temporária, por exemplo, pois uma vez que não há mais alimentação de energia, o dado armazenado é perdido. Enquanto memórias persistentes são aquelas cujos dados são armazenados de forma permanente, independentemente da condição de processamento ou de alimentação.

O mesmo autor define que a segunda categorização das memórias está relacionada ao seu objetivo dentro da arquitetura de um computador. A memória principal é aquela que armazena dados utilizados na execução das tarefas do processador e é acessada diretamente por ele, logo, possui um desempenho de velocidade alto, porém capacidade de armazenamento baixa.

Ainda de acordo com Stallings (2016), a memória principal é conhecida como memória de acesso randômico, ou RAM, do inglês *random access memory* e é do tipo volátil. Enquanto isso, memórias do tipo secundário possuem características opostas. Memórias secundárias são do tipo persistentes, ou não voláteis, e possuem grande capacidade de armazenamento e baixa velocidade de acesso. São destinadas ao armazenamento de maior quantidade de dados e de informações que demandem maior tempo de armazenamento.

São exemplos de memórias secundárias os discos rígidos (HD(s)), unidades de estado sólido (SSD(s)), memórias *flash* (como cartões SD e *pendrives*), fitas magnéticas e algumas capacidades de armazenamento em nuvem que veremos mais adiante.



IMPORTANTE


Existem tarefas e processamentos que eventualmente necessitam de mais espaço de memória RAM do que já existe. Para esses casos, parte da memória secundária pode ser alocada e utilizada pelo processador, muito embora essa área de memória seja mais lenta que a memória principal. Esse processo é chamado de *caching*.

Por fim, a terceira capacidade computacional, a de comunicação, é implementada pelos barramentos e pelos componentes de rede.

Os barramentos são filamentos que conectam os componentes da arquitetura de um computador e podem ser classificados como internos ou externos. Os internos têm como objetivo conectar o processador e as unidades de memória, enquanto barramentos externos são utilizados para conectar elementos externos, também chamados de periféricos, à estrutura interna do computador (Stallings, 2016).

Na figura 4, é apresentado um exemplo de barramento interno. Nele é possível ver um circuito microeletrônico com um processador ao centro e pequenos filamentos dourados saindo dele. Estes filamentos fazem parte do barramento que conecta este processador a outros componentes do computador.

Figura 4 – Barramento interno



Componentes de rede, como as placas (ou adaptadores) de rede, também chamados de NIC (*network interface card*), são sistemas de *hardware* responsáveis por estabelecer a conexão e a troca de informações, em nível de byte, entre dois dispositivos computacionais (Stallings, 2016).

Nesta sessão, discutimos o que são servidores, seus componentes, suas funcionalidades e classificações. Citamos a estrutura física necessária para comportar a instalação desses servidores e os centros de processamento de dados, também chamados de *data centers*.

2 Centro de processamento de dados (*data centers*)

A primeira ideia equivocada que podemos ter com relação a *data center* é imaginar que se trata somente de um lugar onde ficam os servidores.

um *data center* é um conjunto integrado de componentes de alta tecnologia que permite fornecer serviços de infraestrutura [...] tipicamente processamento e armazenamento de dados [...] para qualquer tipo de organização (Veras, 2009, p. 62).

Logo, podemos concluir que um servidor é parte de um centro de processamento de dados. Junto aos servidores, temos toda a infraestrutura de TI como sistemas de armazenamento (*storage*), componentes de rede, bem como elementos de infraestrutura não relacionados à tecnologia como: fornecimento de energia elétrica, ventilação e condicionamento de ar, sistemas de prevenção a acidentes (como incêndios, por exemplo) e elementos de segurança física e predial (Laan, 2017).

Data centers não são necessariamente estruturas gigantescas e exclusivas para empresas enormes ou apenas corporações de tecnologia. Podemos categorizar os centros a partir do seu tamanho: *data center* empresarial, médio porte ou menores, como locais, sala de servidores ou apenas armário de servidores (Veras, 2009).

Ainda é possível categorizar um *data center* a partir de sua propriedade. Os corporativos ou EDC (*enterprise data center*) pertencem e são operados pela própria organização, são também chamados de *data centers on-premises*. Enquanto isso, *internet data centers* (IDC) são estruturas que pertencem a corporações terceiras, geralmente com ênfase em tecnologia, que fornecem esse *data center* para outras organizações por meio de prestação de serviços (Veras, 2009).



IMPORTANTE

O modelo de terceirização de *data centers* a partir da internet (IDC), somado ao avanço da infraestrutura de redes e telecomunicações, ajudou a fomentar e expandir o modelo de computação em nuvem.

Em um mundo em que dados fazem parte dos bens mais preciosos de uma empresa, a construção de um *data center* não é das tarefas mais triviais. A começar pela definição da localização onde ele estará fisicamente.

Segundo Laan (2017), aspectos relacionados à localização geográfica são as primeiras preocupações. É necessário avaliar se o local está em área propensa a desastres naturais, como terremotos, tornados, tsunamis, enchentes e incêndios. Além disso, a área deve guardar distância segura de outros lugares que possam causar acidentes, como rodovias, aeroportos e outros tipos de indústria. A infraestrutura da região também deve ser avaliada. Pontos como garantia do fornecimento de energia elétrica e linhas de telecomunicações, com redundância, são fatores críticos de sucesso.

Ainda segundo o autor, uma vez escolhido o local que atenda às condições mínimas citadas anteriormente, é hora de pensar na infraestrutura predial do *data center*. A garantia da disponibilidade dos serviços passa inicialmente pela garantia do fornecimento de energia elétrica. É necessário um projeto completo de um sistema de fornecimento de energia ininterrupta.

O mesmo autor aponta que um *data center*, pela quantidade de equipamentos que abriga, é um local naturalmente quente. O calor pode provocar danos à infraestrutura de TI e causar inoperância de seus serviços, logo, é necessário um projeto de refrigeração e de circulação de ar.

Ainda segundo Laan (2017), a segurança da informação dos *data centers* começa pela segurança predial em que estão armazenados. O controle e monitoramento dos acessos autorizados e não autorizados são elementos fundamentais neste processo.

Até aqui, falamos de aspectos de infraestrutura que fazem parte do contexto de *data center*, mas que não são diretamente ligados à tecnologia da informação.

Para começar, o que garante a operacionalidade de um centro de processamento de dados é a sua conectividade, e isso se dá a partir de um projeto de redes que tem como objetivo garantir a conexão entre os componentes internos do *data center* e destes com o ambiente externo. Esse

projeto passa da correta seleção dos equipamentos de rede como *switches*, *hubs* e roteadores até o cabeamento estruturado, sempre orientado a uma abordagem que garanta o contingenciamento dessas conexões em caso de falhas (Veras, 2009).

O segundo ponto importante é a garantia da alta disponibilidade dos serviços do *data center*. Alta disponibilidade de serviços computacionais é a capacidade que ele tem de continuar operando sem interrupções significativas, mesmo diante de falhas ou problemas. O objetivo principal da alta disponibilidade é reduzir ao máximo o tempo de indisponibilidade dos serviços, garantindo que ele esteja funcionando o maior tempo possível.

Além do contingenciamento da rede, é necessário projetar o contingenciamento de servidores e de sistemas de armazenamento (*storage*) de tal forma que, caso um componente falhe, outro assume seu papel sem qualquer tipo de indisponibilidade ou perda de desempenho (Veras, 2009).

Segundo Veras (2009), a garantia da disponibilidade também passa pela forma que o *data center* responde em casos de desastres, e para isso é necessário fazer um plano de recuperação de desastres ou *DRP* (*disaster recovery plan*). Este plano contém políticas, processos, sistemas de *software* e mecanismos de *backup* e restauração, incluindo a possibilidade de migração total dos serviços para outro *data center*.

Ainda segundo o autor, os *data centers* também demandam serviços de TI próprios, como o monitoramento das operações e dos serviços, gerenciamento e manutenção (corretiva ou evolutiva) dos sistemas de *hardware* e *software* (como atualizações de sistemas operacionais, por exemplo). Tudo isso só é possível se houver um nível de suporte e automação que torne toda essa operação eficiente e eficaz.

Por fim, o mesmo autor aponta que, para que um *data center* se torne minimamente viável economicamente, é necessário elevar ao máximo

o uso dos recursos a partir de abordagens como a virtualização, que permite, por exemplo, que diversas aplicações e diversos sistemas operacionais utilizem os mesmos recursos de servidores, como processamento, memória e rede (Veras, 2009).



PARA PENSAR

Os custos de aquisição, construção, manutenção e operação (CAPEX e OPEX) de um *data center* são elevados. Para empresas que utilizam TI em larga escala, mas cujo negócio não é a produção de tecnologia, qual seria o melhor modelo pensando unicamente em custos? *Data center* corporativo (*on-premise*) ou terceirizado (IDC)?

A viabilidade econômica de um *data center* sempre foi uma preocupação para as corporações, sejam elas de TI ou não, e os indicadores de sucesso do modelo eram medidos unicamente pela disponibilidade e o desempenho. Porém, aspectos relacionados à sustentabilidade passaram a ter igual importância.

O movimento chamado de *data center* verde (*green data center*) passou a observar os impactos socioambientais da evolução dos *data centers* e das suas capacidades computacionais no meio ambiente e na sociedade, principalmente no que diz respeito ao consumo de energia e como a matriz energética sustentável é impactada por esse consumo (Veras, 2009).



PARA SABER MAIS

O The Green Grid (2025) é uma organização sem fins lucrativos, formada por algumas das principais empresas globais de tecnologia, que discute e promove políticas, normas e práticas sustentáveis para o consumo de recursos naturais por parte dos *data centers* e da infraestrutura de TI.

3 Processamento de dados distribuídos

Falamos sobre servidores e sobre a infraestrutura de TI associada aos centros de processamento de dados (*data centers*), porém, nada disso existiria nos moldes que discutimos se não fosse o modelo de processamento de dados distribuído.

O processamento de dados distribuído é uma abordagem computacional que abrange sistemas *hardware* e sistemas de *software* que tem como objetivo a execução de tarefas de forma colaborativa a partir da utilização de múltiplos computadores e servidores conectados em rede. Até meados da década de 1960, o processamento centralizado tinha como premissa que todas as tarefas fossem executadas em um único sistema computacional, por exemplo, um *mainframe*. O modelo distribuído, a partir de 1970, dividiu os dados e as tarefas entre várias máquinas (Tanenbaum e Van Steen, 2017). Alguns dos benefícios do modelo de processamento distribuído de dados são:

- **Desempenho:** a divisão das tarefas entre várias máquinas aumenta a capacidade de processamento;
- **Resiliência:** diferentemente do modelo centralizado, quando uma máquina falha, existe a possibilidade de outra assumir o seu lugar;
- **Escalabilidade:** como dissemos sobre *clusters*, temos aqui a possibilidade de adicionar mais computadores ou servidores para atender uma maior demanda de dados ou de tarefas.

Assim como toda tecnologia, o processamento distribuído não traz apenas benefícios. A mudança no paradigma do desenvolvimento das aplicações promoveu preocupações até então inexistentes, como a gestão da consistência dos dados e do aumento da complexidade dos sistemas de *software*. Ademais, o custo com a infraestrutura e a preocupação com a latência de rede também aumentaram (Tanenbaum e Van Steen, 2017).

Mesmo assim, o processamento de dados distribuído foi o alicerce que promoveu o desenvolvimento da web, da computação em nuvem e do processamento de grandes volumes de dados que são a base para execução de aplicações *big data*, de inteligência artificial e *machine learning*.

Considerações finais

Neste capítulo, trabalhamos os conceitos de servidores, o que são, quais seus objetivos dentro da TI e as classificações baseadas em sua disposição física e tipo de uso. Abordamos também a infraestrutura necessária para abarcar esses servidores e vimos que *data center* é muito mais que apenas um lugar para instalar um servidor. Trabalhamos a importância analítica de tudo que cerca a construção e operação de um centro de processamento de dados, levando em consideração aspectos econômicos e de sustentabilidade.

Por fim, apresentamos o modelo de processamento de dados distribuídos, que surgiu como uma abordagem antagônica ao processamento centralizado e que envolve os conceitos de servidores e *data centers*, e serve de base para todas as tecnologias emergentes atuais.

Referências

BASS, Len; CLEMENTS, Paul; KAZMAN, Rick. **Software Architecture in Practice**. 3 ed. Boston: Addison-Wesley Professional, 2012.

LAAN, Sjaak. **IT Infrastructure Architecture – Infrastructure Building Blocks and Concepts**. 3. ed. [S. l.]: Lulu Press Inc., 2017.

STALLINGS, W. **Computer Organization and Architecture: Designing for Performance**. 10 ed. Londres: Pearson Education, 2016.

TANENBAUM, Andrew S.; VAN STEEN, Maarten. **Distributed Systems: Principles and Paradigms**. 3 ed. Londres: Pearson Education, 2017.

TANENBAUM, Andrew S.; WETHERALL, David. **Redes de computadores**. 5 ed. São Paulo: Pearson Prentice Hall, 2011.

THE GREEN GRID. Página inicial. **The Green Grid**, 2025. Disponível em: <https://www.thegreengrid.org/>. Acesso em: 19 mar. 2025.

VERAS, Manoel. **Datacenter: componente central da infraestrutura de TI**. Rio de Janeiro: Brasport, 2009.

Sistemas operacionais

A Infraestrutura de tecnologia da informação não se resume a sistemas de *hardware*, mas sim a um conjunto de *hardware* e de sistemas de *software* que, juntos, apoiam a execução dos processos de negócio.

Os sistemas de *software* podem ser divididos em duas categorias: aplicações e *software* base. Aplicações correspondem a sistemas que de fato automatizam um processo de negócio e que fazem fronteira com o usuário final, como por exemplo, aplicativos empresariais e comerciais, *apps* para dispositivos móveis e jogos digitais. Já os *softwares* base (ou de base) são sistemas que servem de apoio para a execução das aplicações. Exemplos de *software base*: compiladores e interpretadores de código-fonte, *drivers* de dispositivos periféricos e sistemas operacionais.

Neste capítulo, abordaremos os conceitos fundamentais de sistemas operacionais, passando pela evolução no contexto histórico, seus objetivos e tipos até o detalhamento de sua arquitetura.

1 A evolução dos sistemas operacionais no contexto histórico

A evolução dos sistemas operacionais, no decorrer do tempo, nos ajuda a entender em alguns aspectos como a utilização dos computadores se massificou desde os computadores da primeira plataforma (ou primeira geração) até a popularização dos PCs.

Os primeiros computadores, que datam das décadas de 1940 e 1950, funcionavam sem sistemas operacionais, e os sistemas de *software* eram executados diretamente no sistema de *hardware* a partir de cartões perfurados.

Foi somente entre as décadas de 1950 e 1960 que tivemos o surgimento de um sistema de *software* que se assemelhasse a um sistema operacional, o Monitor Residente. Aqui temos um ponto importante, pois nos ajuda a entender a razão de existir um sistema operacional. O objetivo dele era atuar como um intermediário entre tarefas de sistemas de *software* que precisavam ser executadas e o sistema de *hardware* do computador (CPU, memória e disco).

Em 1964, o Instituto de Tecnologia de Massachusetts (MIT) desenvolveu o Multics, acrônimo para *multiplexed information and computing service*, um sistema operacional considerado como a base de evolução para o que temos atualmente. Sua relevância reside no fato de ter sido o primeiro a propor uma *interface* com os usuários de sistemas computacionais, além de representar uma evolução tecnológica por possibilitar que uma CPU fosse utilizada por mais de uma tarefa de *software* de forma compartilhada.

No período entre as décadas de 1970 e 1980, temos o surgimento dos microcomputadores e o desenvolvimento do Unix para ser o sistema operacional de gerenciamento dessa nova arquitetura de computadores. Enquanto isso, a IBM desenvolvia o IBM System/360 (também conhecido como OS/360) para operar em plataformas de *mainframe*. Observa-se aqui uma cisão entre os tipos de sistemas operacionais, baseada na necessidade de atender a diferentes arquiteturas de *hardware*.

A década de 1980 começou com o uso de computadores de forma mais massificada e, em 1981, a Microsoft lançou seu primeiro sistema operacional com uma *interface* voltada para usuários finais, o MS-DOS, que, embora baseado em linhas de comando, permitia que esses usuários interagissem com um computador sem a necessidade de ser um especialista em computação.

Em 1984, outro marco importante foi o lançamento do sistema operacional MacOS pela Apple. Esse evento foi relevante, pois marcou novamente uma cisão entre sistemas operacionais e sistemas de hardware, mas agora, no campo dos computadores pessoais. Cada computador, baseado em uma arquitetura de hardware, passou a ser gerenciado somente por um tipo de sistema operacional.

Em 1985, ocorreu mais um fato relevante. A Microsoft lançou seu sistema operacional com uma *interface* voltada para o usuário, o Windows. A interface do Windows fazia uma intermediação entre o usuário final e os comandos do MS-DOS, sem que esse usuário precisasse saber ou digitar qualquer linha de comando em um terminal.

No começo da década de 1990, Apple e Microsoft viram mais um concorrente surgir no mercado: o Linux, desenvolvido a partir do Unix, propôs um novo modelo de desenvolvimento e comercialização de sistemas operacionais baseado no código aberto e na distribuição descentralizada.

Nos anos seguintes, esses sistemas operacionais passaram a se adaptar à evolução tecnológica. A evolução das redes de computadores,

dos servidores, das capacidades computacionais e o surgimento da virtualização e da computação em nuvem fizeram com que os fabricantes desenvolvessem uma série de versões de seus sistemas operacionais que se adaptassem a cada avanço.

Por fim, surgiram os sistemas operacionais para atender a uma nova demanda de *hardware*: os dispositivos móveis. Entre os anos 2000 e 2010, o crescimento da computação móvel baseada em *smartphones* e dispositivos embarcados promoveu o surgimento de sistemas operacionais como Android, iOS, Windows Mobile, Raspberry Pi OS, entre outros (Tanenbaum & Bos, 2016).



PARA PENSAR

Com a constante evolução das capacidades computacionais e a massificação da utilização de sistemas baseados em inteligência artificial e *machine learning* (aprendizado de máquina), como serão as novas gerações de sistemas operacionais?

2 Objetivos de um sistema operacional


Compreender a evolução dos sistemas operacionais no decorrer do tempo nos ajuda a entender os objetivos desses sistemas dentro da infraestrutura de tecnologia da informação.

Abordamos que a motivação inicial para o desenvolvimento de um sistema operacional foi a necessidade de termos uma estrutura que fizesse a integração entre os sistemas de *software* e de *hardware*. Vimos também que os sistemas operacionais precisaram evoluir para se adaptarem às mudanças dos computadores e evoluções das tecnologias.

O primeiro grande objetivo de um sistema operacional é gerenciar o *hardware* de um computador. Recursos como CPU, memória, dispositivos de entrada e saída, periféricos e componentes responsáveis pela comunicação são complexos e necessitam de um sistema para orquestrar seu correto funcionamento. Além disso, o segundo objetivo é fazer a integração, servir de “intermediário” entre as aplicações, que podem ser acessadas por usuários finais, e os recursos de *hardware* necessários para a execução desses sistemas de *software* (Silberschatz *et al.*, 2015).

Na figura 1, é possível observar como o sistema operacional está posicionado na arquitetura de um sistema computacional. Observa-se que, no plano inferior, estão os recursos de *hardware* disponíveis, como CPU, memória, disco rígido, recursos de rede e periféricos. Já no extremo superior, encontram-se as aplicações acessadas pelos usuários finais, como navegadores, reprodutor de músicas e leitor de e-mails.

Figura 1 – Visão da arquitetura de um sistema computacional



Fonte: Tanenbaum & Bos (2016, p. 1).

Ainda na figura 1, podemos notar que as aplicações, muito embora utilizem recursos de *hardware*, não acessam esses recursos diretamente,

mas o fazem a partir do sistema operacional, que tem a incumbência de gerir o acesso a esses recursos de tal forma que não existam conflitos ou concorrência que impeçam o correto funcionamento do sistema como um todo.

Gerenciar os recursos de *hardware* de um sistema e servir como um intermediário entre as aplicações e os recursos computacionais que elas utilizam são os dois objetivos macro de um sistema operacional. O alcance desses objetivos se dá a partir da implementação de alguns serviços (Tanenbaum & Bos, 2016).

São eles:

- **Gerenciamento de arquivos:** responsável por todas as tarefas referentes à alocação de arquivos em disco. Implementa mecanismos de escrita, leitura, permissão de acesso, bem como gestão de espaço;
- **Gerenciamento de entrada e saída:** trata de toda interação com dispositivos de entrada e saída que geram sinais a serem tratados pela CPU, como por exemplo: teclado, sensores, periféricos e unidades de disco;
- **Gerenciamento de memória:** gerencia a alocação da memória principal, garantindo que não haja concorrência e conflitos no acesso aos dados pelas diversas tarefas de *software* e implementa mecanismo de virtualização;
- **Gerenciamento de processos:** de forma resumida, um processo é um programa em execução. O gerenciamento de processos de um sistema operacional implementa o ciclo de vida de um processo, que corresponde a alocar todos os recursos que ele precisa, deixá-lo pronto para execução, mantê-lo em execução e executar as tarefas necessárias quando este for encerrado, como por exemplo, desalocar os recursos provisionados;

- **Segurança:** a segurança em tecnologia da informação é tema amplo e nem sempre trivial. O sistema operacional é responsável pela implementação de mecanismos sofisticados que ajudam no controle de acesso aos recursos, criptografia, autenticação, bem como na construção de barreiras a ataques.



PARA SABER MAIS

Podemos resumir processo como um programa em execução, porém essa definição é incompleta. Um processo também pode ser sinônimo de *job*, programa de usuário ou *thread* e pode ser decomposto em partes como código (ou seção de texto), seção de dados e pilha de execução. Compreender o que é um processo e entender seu ciclo de vida é fundamental para entendermos o conceito de multiprogramação e sistemas operacionais multitarefas (Silberschatz *et al.*, 2015).

3 Arquitetura de sistemas operacionais


A arquitetura de um sistema pode ser definida como a organização dos componentes que compõem um sistema de *software* e como eles interagem entre si para atingir um determinado objetivo (Bass *et al.*, 2012).

Assim como em qualquer sistema de *software*, a arquitetura de um sistema operacional pode ser definida como a forma como seus componentes estão organizados e a maneira como eles se integram. Essa arquitetura é agnóstica ao fabricante do sistema operacional, ou seja, sendo Windows, Linux ou qualquer outro, todos implementam o mesmo modelo, variando apenas a forma de desenvolver cada componente.

Na arquitetura de um sistema operacional, os componentes de *software* são agrupados pelas suas responsabilidades. Se olharmos sob o ponto de vista do usuário final, um sistema operacional contém dois grandes agrupamentos: *shell* e *kernel*. Por outro lado, sob o ponto de vista

das aplicações, substituímos o *shell* por um conjunto de bibliotecas, também chamadas de API, como mostra a figura 2 (Tanenbaum & Bos, 2016).

Figura 2 – Visão arquitetural de um sistema operacional



O *kernel*, também conhecido como “coração do sistema operacional”, é a camada mais interna do sistema operacional, na qual temos todos os componentes que implementam os serviços que citamos anteriormente, por exemplo, a gestão dos recursos de *hardware* (Tanenbaum & Bos, 2016).


Ainda segundo Tanenbaum e Bos (2016), a camada do *kernel* é a que possui acesso mais restrito, ou seja, usuários ou aplicações não podem acessar suas funções diretamente. Para acessar as funcionalidades do coração do sistema operacional, usuários utilizam outros componentes, organizados em uma camada chamada *shell*, enquanto aplicações utilizam bibliotecas.

Os mesmos autores apontam que o *shell* é a camada mais externa do sistema operacional e é responsável por receber os comandos feitos pelo usuário e os traduzir para as funcionalidades expostas no *kernel*. Se perguntássemos a um usuário o que ele enxerga do sistema operacional, a resposta seria o *shell*.

Uma das grandes confusões que temos quando o assunto é *shell* está relacionada ao seu tipo. Temos duas categorias: o *shell* gráfico, ou também chamado de GUI (*graphical user interface*), e o *shell* por linhas de comando.

No *shell* por linhas de comando, o usuário não possui nenhum recurso para interagir com o sistema operacional que não sejam comando e códigos reconhecidos pelo sistema, como mostra a figura 3 (Tanenbaum & Bos, 2016).

Figura 3 – Shell por linha de comando



Ainda na figura 3, podemos ver a execução do comando “*ls -a*” e logo abaixo o texto “*. . .aws .azure .bash_history .bash_logout .bashrc .docker .motd_shown .profile .sudo_as_admin_successful*”, que nada mais é do que a lista dos diretórios de arquivos contidos na unidade de armazenamento.

O *shell* gráfico talvez seja um dos grandes responsáveis pela popularização no uso dos computadores pessoais. Com uma interface mais amigável, o usuário pôde interagir com o sistema operacional sem a necessidade de decorar linhas de comando, o que tornou o computador, como um todo, um recurso com melhor usabilidade.

Na linha do tempo que estudamos anteriormente, o MS-DOS é um exemplo de sistema operacional cujo *shell* era por linha de comando, enquanto o Windows e MacOS são sistemas com *shell* gráfico. Isso mostra a importância deste recurso na massificação do uso dos computadores.

Alguns pontos que costumam gerar confusão são:

- O *shell* gráfico não possui funcionalidades a mais ou a menos que o *shell* por linhas de comando (e vice-versa). A única diferença é que no modo gráfico, uma interface é responsável por “traduzir” a ação solicitada pelo usuário para um comando (tal como nas linhas de comando) e enviar para o *kernel*;
- “O Linux é apenas por linhas de comando enquanto o Windows possui apenas o *shell* gráfico”. Essa afirmação, embora seja muito popular, é incorreta, pois o Linux pode perfeitamente rodar uma interface gráfica (como GNOME, KDE, etc.), ao passo que o Windows também oferece recursos de linha de comando (cmd, PowerShell, WSL) sem necessidade de interface gráfica.
- Um dos fatores que caracteriza o *shell* gráfico é um consumo maior de recursos computacionais, como memória e vídeo, se comparado ao *shell* por linhas de comando. Se não temos a necessidade de um sistema operacional cuja interface seja amigável para o usuário, como por exemplo, um sistema operacional para servidores (veremos a seguir), então um *shell* por linhas de comando resolve (e bem) o problema.

Por fim, a biblioteca de um sistema operacional, ou também chamada de API, é um conjunto de componentes de software utilizados para fazer a integração entre as aplicações e o *kernel*. As bibliotecas atuam como *shell*. Todavia, enquanto o shell tem como cliente o usuário final, as bibliotecas possuem outras aplicações como usuárias de suas funções, que são acessadas a partir das linhas de código dessas aplicações (Tanenbaum & Bos, 2016).

4 Tipos de sistemas operacionais

Conforme vimos, sistemas operacionais estão diretamente ligados ao sistema de *hardware* que será operado por eles e pelas funções que têm de desempenhar dentro do sistema computacional.

A primeira categorização de sistemas operacionais está diretamente relacionada ao tipo de *hardware*. Com a evolução das plataformas tecnológicas, os sistemas operacionais precisaram adaptar seus serviços para manter sua eficiência considerando aspectos como:

- Melhora no gerenciamento dos recursos em casos que estes são mais limitados, como dispositivos móveis e embarcados;
- Otimização da utilização de recursos computacionais e do consumo de energia para dispositivos que utilizam bateria ou computadores que necessitam de grande capacidade de processamento para suas tarefas;
- Virtualização de recursos.

De acordo com Tanenbaum & Bos (2016), são versões de sistemas operacionais baseados no *hardware*:

- Sistemas operacionais para computadores pessoais: são os sistemas que possuem a maior quantidade de usuários. São exemplos dessa categoria o Linux, Windows e o MacOS.
- Sistemas operacionais para computadores portáteis e dispositivos móveis como *smartphones* e *tablets*: aqui temos sistemas que se preocupam com consumo de energia e o uso otimizado dos recursos computacionais como memória, processamento e armazenamento de arquivos. Destacam-se nessa categoria: Android e iOS para dispositivos móveis, e Windows, MacOS e Linux para *notebooks*, que se assemelham aos sistemas para computadores pessoais, mas que possuem funções diferenciadas relacionadas ao consumo de recursos com bateria, por exemplo.

- Sistemas operacionais para computação embarcada: sistemas embarcados são

destinados a computadores que não costumam ser vistos como computadores e não aceitam *softwares* instalados pelo usuário [...] por exemplo, aparelhos de televisão e carros (Tanenbaum & Bos, 2016, p. 45).

A principal diferença deste tipo de sistema operacional para um sistema destinado a dispositivos móveis está na implementação de mecanismos de segurança que garantem que não haverá execução de qualquer tipo de *software* indesejado. Destacam-se nessa categoria o Embedded Linux, o QNX e o VxWorks.

- Sistemas operacionais para servidores: são sistemas para uso específico em servidores – mencionados no capítulo 2 – e caracterizam-se pela otimização da divisão dos recursos de *hardware* com os múltiplos usuários e serviços. São destaques aqui o Linux e o Windows Server.



PARA SABER MAIS

Além dos citados, existem também outros sistemas que valem ser estudados, como sistemas operacionais de multiprocessadores, de tempo real, de nós sensores (*sensor-node*) e de cartões inteligentes (*smartcard*) (Tanenbaum & Bos, 2016).

A segunda classificação dos sistemas operacionais está relacionada a sua capacidade, ou não, de executar múltiplos processos simultaneamente. Os sistemas monotarefas são aqueles permitem a execução de apenas um processo em um determinado intervalo de tempo, em contrapartida, os multitarefas (ou *multithread*) são aqueles que, a partir de técnicas de compartilhamento, permitem a execução de múltiplos processos ao mesmo tempo.

O termo “*multithread*” refere-se à capacidade de um processo criar várias linhas de execução internas (*threads*). Embora tenha relação com a multitarefa, não é um sinônimo estrito.

Os sistemas monotarefas eram muito utilizados quando tínhamos menos recursos computacionais nos sistemas de *hardware* e por isso, enquanto um processo estivesse em execução, nenhum outro poderia ser executado até que este fosse concluído. O MS-DOS é um exemplo deste tipo de sistema (Tanenbaum & Bos, 2016).



NA PRÁTICA

Em um sistema operacional monotarefa não seria possível escrever um texto no seu editor favorito e escutar música em um reprodutor de músicas simultaneamente. Ou escreveríamos um texto, ou escutaríamos música.

Com a evolução da capacidade computacional – e aqui temos novamente a Lei de Moore – as CPUs passaram a ser subutilizadas. As aplicações e sistemas operacionais projetados para monotarefas ocupavam um percentual muito baixo da capacidade total de um processador.

Novamente, os sistemas operacionais precisaram se adaptar para, a partir da implementação do gerenciamento de processos (que vimos anteriormente), permitir a execução de mais de um processo de forma simultânea.



NA PRÁTICA

Exceção feita a sistemas com mais de um processador e CPUs com chips que possuem mais de um processador completo, o termo “simultâneo” não é de todo verdadeiro. Isso porque sistemas multitarefas de fato não executam dois processos ao mesmo tempo. Ocorre que, a partir de técnicas de escalonamento de processos e alocação de recursos, o tempo

de chaveamento de um processo em execução para outro é de menos de um nanossegundo, o que é imperceptível (Tanenbaum & Bos, 2016).

Por fim, temos a divisão dos sistemas operacionais baseada no seu modelo de comercialização e distribuição. Sistemas de código fechado são aqueles cujo *kernel* tem seu código-fonte protegido pela legislação, ou seja, sua alteração, comercialização ou mesmo visualização são proibidas. Por outro lado, sistemas de código aberto (ou *opensource*) têm o código de seu *kernel* público em repositório e sua alteração e distribuição são permitidas pela comunidade.

São exemplos de sistemas operacionais de código fechado os sistemas Microsoft Windows e Apple MacOS, enquanto um clássico exemplo de sistema *opensource* é o Linux.



PARA SABER MAIS

O Android, sistema operacional voltado para dispositivos móveis, como *smartphones*, é considerado um sistema do tipo *opensource*, porém com algumas ressalvas. O AOSP (*android open source project*) é o *kernel* do Android, é mantido pelo Google e está disponível publicamente para *download*, visualização e alteração. A principal ressalva é que no AOSP não temos todos os componentes necessários para o total funcionamento do sistema, sendo necessária a inclusão de outros componentes de fabricantes terceiros (Tanenbaum & Bos, 2016).

O Linux foi desenvolvido por Linus Torvalds, na década de 1980 e teve sua base no Unix. Seu primeiro lançamento ocorreu no início da década de 1990 e sua principal característica é ser um sistema operacional cujo código fonte é aberto e público (Tanenbaum & Bos, 2016).

Por ser um sistema *opensource*, um desenvolvedor poderia obter o código fonte, fazer determinadas melhorias e devolver esse código

atualizado para a comunidade, promovendo um ciclo de desenvolvimento que fez com que o Linux crescesse rapidamente.

O modelo de publicidade do código de um sistema operacional não deve ser confundido com o modelo de comercialização do produto. Sistemas operacionais da Microsoft e da Apple são de código fechado e requerem um custo de licença de uso. Por outro lado, existem versões do Linux, chamadas distribuições, que são de uso gratuito e existem versões pagas.

Isso acontece porque, controverso ou não, o modelo de código aberto não exige a gratuidade do uso. Um indivíduo, ou uma organização, pode obter o código, fazer as suas modificações, criar uma distribuição e cabe a ele decidir o modelo de licenciamento dessa nova versão.

Considerações finais

Neste capítulo, vimos que entender a linha de evolução dos sistemas operacionais no decorrer do tempo nos ajuda a compreender seus objetivos e sua arquitetura, e que a evolução da tecnologia e das capacidades computacionais fez com que esses sistemas também tivessem de evoluir.

Embora existam diferentes tipos de sistemas operacionais, seja pelos diferentes sistemas de *hardware*, pelo fabricante, por possuir uma interface gráfica ou por linhas de comando ou ainda pelo modelo de desenvolvimento e distribuição, todos possuem os mesmos objetivos e modelo arquitetural.

Referências

ANDROID. Android Open Source Project. **Android**, 2016. Disponível em: <https://source.android.com/>. Acesso em: 20 mar. 2025.

BASS, Len; CLEMENTS, Paul; KAZMAN, Rick. **Software Architecture in Practice**. 3 ed. Boston: Addison-Wesley Professional, 2012.

SILBERSCHATZ, Abraham; GALVIN Peter Baer; GAGNE Greg. **Fundamentos de sistemas operacionais**. 9 ed. Rio de Janeiro: LTC, 2015.

TANENBAUM, Andrew S.; BOS, Herbert. **Sistemas operacionais modernos**. 4 ed. São Paulo: Pearson, 2016.

Redes de computadores

Como vimos, as telecomunicações e as redes de computadores foram fundamentais para a evolução das tecnologias, sendo a base, por exemplo, da computação distribuída e logo, das plataformas da terceira geração, como computação em nuvem e Internet das Coisas (IoT).

Neste capítulo, veremos os conceitos fundamentais que envolvem as redes de computadores, bem como a arquitetura que garante a interoperabilidade dos dispositivos e sistemas de *software*, nos aprofundando em cada aspecto desta arquitetura.

1 Introdução ao conceito de redes de computadores

De forma resumida, o objetivo de uma rede de computadores é promover a conexão entre dois ou mais dispositivos de tal forma que estes possam compartilhar recursos. Muito embora possamos pensar que essa tecnologia surgiu nas décadas de 1980 e 1990, na verdade, seu projeto data de 1967 com a criação da ARPANET, rede que interligava os computadores do departamento de defesa dos EUA (Silva, 2021).

O primeiro conceito importante sobre redes é a classificação de acordo com a sua abrangência. As redes podem ter diversos tamanhos, logo, diferentes abrangências geográficas (Tanenbaum *et al.*, 2021). São elas:

- **LAN:** as redes locais (*local area network*) são as redes que abrangem a menor região, como empresas e residências.
- **MAN:** chamadas de redes metropolitanas (*metropolitan area network*), elas cobrem uma região maior que as LANs. Sua abrangência pode ser de uma cidade ou de um conjunto de cidades (região metropolitana).
- **WAN:** as redes do tipo WAN (*wide area network*) são as que possuem maior cobertura geográfica, podendo conectar desde cidades diferentes até países e continentes. A *internet* é um exemplo de rede WAN.



IMPORTANTE

Importante salientar dois aspectos a respeito da abrangência de uma rede: latência e infraestrutura.

A latência está relacionada a velocidade de comunicação entre os dispositivos, ou seja, quanto maior a distância entre esses dispositivos, em tese, a latência também é maior.

A infraestrutura necessária para as diferentes redes também muda significativamente. Por exemplo, enquanto em redes locais temos poucas quantidades de cabos e podemos lançar mão de conexões Wi-Fi, as WANs necessitam de cabeamento específico, como cabos submarinos e ópticos, para que a latência não prejudique a comunicação.

O segundo pilar que sustenta a ideia das redes de computadores são os protocolos de comunicação. Um protocolo nada mais é que um conjunto de regras e padrões que visam garantir a troca de mensagens entre dois dispositivos (Stallings, 2005).

Vamos imaginar o seguinte cenário: você precisa conversar com um colega de trabalho que não conhece. Seria razoável pensar que você pegue o telefone e ligue para o número deste colega. Algumas situações hipotéticas poderiam acontecer:

1. Você ligar para um número que não é o da pessoa – talvez a pessoa não use telefone;
2. O seu colega se comunicar apenas por linguagem de sinais;
3. A pessoa não falar o mesmo idioma que você;
4. Você falar e não ter resposta.

Dessa situação imaginária, podemos tirar alguns pilares que são fundamentais nos protocolos de comunicação:

- A definição dos envolvidos na comunicação: quem está enviando a mensagem e quem está recebendo a mensagem;
- A definição do meio de comunicação: você escolheu o telefone, mas sem a “combinação” prévia desse meio, a comunicação não acontecerá;
- A definição da linguagem: no nosso caso, a definição prévia do idioma falado vai definir a efetividade da comunicação;

- A definição de uma forma de confirmação que a mensagem de fato foi recebida: no nosso exemplo, a falta de resposta pode indicar alguma falha na comunicação.

Assim como nesse exemplo, os protocolos de rede são importantes para a definição e padronização de elementos que fazem, de fato, a comunicação entre dois ou mais dispositivos acontecer.

2 Modelo de referência OSI

Para que a comunicação efetivamente aconteça, um protocolo precisa ser definido e conhecido por todos os participantes dessa comunicação. Esses participantes podem ser fabricantes de *hardware*, fornecedores de sistemas operacionais e desenvolvedores de *software*.

Nesse cenário, se cada um definir uma forma de comunicação própria, um padrão de protocolo próprio, a interoperabilidade de uma rede seria bem reduzida. Significaria dizer, por exemplo, que um determinado tipo de *hardware* só conseguiria se conectar a outro *hardware* do mesmo fabricante.

Para evitar este tipo de problema e garantir a maior interoperabilidade possível, a ISO definiu um conjunto de regras a serem seguidas por todos fabricantes e desenvolvedores que, de alguma forma, quisessem operar no mercado de redes de computadores (Kurose e Ross, 2021).



PARA SABER MAIS

A International Organization for Standardization (ISO) é uma organização que reúne fabricantes de tecnologia, universidades e organizações governamentais de diversos países com o objetivo de definir normas e padrões comuns para o desenvolvimento de diversas atividades.

Segundo Kurose e Ross (2021), o modelo OSI (*open systems interconnection*) foi criado pela ISO para definir padrões para a comunicação aberta entre sistemas. Este modelo é o que chamamos de modelo de referência. Um modelo de referência define o que precisa ser feito (funções, serviços e estrutura), mas não obriga a forma exata de implementação. Na prática, ele estabelece quais elementos devem existir em cada camada, mas a maneira como serão implementados fica a critério de cada fornecedor.

Ainda segundo os autores, a organização do modelo OSI se dá a partir de uma estrutura de camadas. Cada camada é uma abstração, que tem poucas e bem definidas funções dentro do objetivo final, que é fazer dois dispositivos se comunicarem.

Podemos fazer uma analogia com uma linha de produção de veículos em que cada ilha de produção é responsável por produzir um determinado pedaço do carro. Este vai sendo incorporado, modificado e transportado por cada etapa da linha de produção.


Nessa linha, nenhuma etapa é pulada e a sequência das ilhas é bem definida e respeitada. Cada ilha faz poucas e bem determinadas atividades e no fim o objetivo é transformar matéria-prima em veículo.

Fazendo um comparativo da nossa analogia com o modelo OSI, podemos dizer que cada camada é como se fossem ilhas de produção, com uma sequência bem definida e com tarefas a serem executadas. Ainda seguindo esse raciocínio, o modelo de referência define qual é o objetivo de cada ilha e a sequência em que elas estarão dispostas, mas não define a forma como cada ilha irá desempenhar suas atividades para atingir o objetivo.

No modelo OSI, existem sete camadas dispostas, como mostra a figura 1. Ainda nessa figura, podemos notar a divisão das camadas entre inferiores e superiores. Nas camadas inferiores, temos uma maior associação a componentes de *hardware* e infraestrutura, pois é ali que os bits

e bytes das mensagens são enviados e recebidos de forma eletroeletrônica. Enquanto nas camadas superiores, mais ligadas a componentes de *software*, as mensagens são montadas e exibidas. Estas são as camadas mais próximas aos usuários e às aplicações (Tanenbaum *et al.*, 2021).

Figura 1 – Camadas do modelo OSI



3 Camada física

A camada física é a primeira camada na hierarquia do modelo OSI. Ela define os componentes eletroeletrônicos que servem de canal para o envio ou recebimento dos bits e bytes de uma mensagem.

Segundo Tanenbaum *et al.* (2021, p. 73): “a camada física é o alicerce sobre o qual a rede é construída”. Aqui serão implementadas funções que tratam de aspectos das propriedades físicas envolvidos na comunicação, como modulação digital, que converte sinais analógicos em bits digitais e vice-versa, bem como esquemas de multiplexação.

Os padrões que implementam essa camada estão muito associados aos meios físicos utilizados na conexão, como os tipos de cabeamento


utilizados, pois eles determinam outro fator importante: a capacidade do canal.

Também chamada de banda ou largura de banda, a capacidade é a quantidade de bits que são transmitidos e recebidos em um canal de comunicação e estão diretamente ligadas à natureza física do meio utilizado nessa comunicação. Por exemplo, cabos do tipo coaxiais possuem menor capacidade de transmissão se comparados a cabos do tipo par trançado que, por sua vez, perde para os cabos de fibra óptica (Tanenbaum *et al.*, 2021).

Algumas medidas como bits por segundo (bps), megabits por segundo (Mbps) e gigabits por segundo (Gbps) são muito utilizadas para medir a banda de uma rede.

Na figura 2, é apresentado um exemplo de um cabo do tipo par trançado, que é um dos meios de transmissão mais utilizados. Ainda na figura, perceba que, ao abrir a camada de proteção, temos oito pequenos filamentos de cores distintas.


Figura 2 – Cabo do tipo par trançado



Ainda seguindo no exemplo do cabo de par trançado, temos mais uma aplicação da padronização em redes. A forma como os pequenos filamentos são organizados dentro da ponteira, chamada de RJ-45 (*Registered Jack-45*), também possui uma sequência definida.

Na figura 3, é apresentada a sequência dos filamentos no RJ-45. Note que a sequência das cores muda nas duas imagens. Esses exemplos são dois dos padrões mais utilizados para montagem do cabeamento: o padrão T568A e T568B.

Figura 3 – Padrões T568A e T568B com RJ-45



Podemos concluir que tudo que garante a interoperabilidade é padronizado, até nos mínimos detalhes, como a sequência que os filamentos são dispostos em uma ponteira de um simples cabo de rede.



PARA SABER MAIS

Existem diversos padrões ligados ao meio físico relacionados a cabeamento, como o padrão SDH para fibra óptica, bem como para meios sem fio, como a transmissão por rádio, micro-ondas, infravermelho, via luz e satélites (Tanenbaum et al., 2021).

4 Camada de enlace

De acordo com Tanenbaum *et al.* (2021), a camada de enlace é a segunda camada do modelo OSI e tem como objetivo principal receber os bits e bytes da camada física e organizá-los em blocos, chamados de quadros, de tal forma que as informações contidas em um quadro fiquem corretas e íntegras para serem enviadas para as próximas camadas.

Ainda segundo os autores, além deste objetivo principal, a camada de enlace executa diversas funções:

- Tratamento de erros de transmissão: verifica se um quadro contém informações corretas ou defeituosas e implementa um controle de aviso para o transmissor sobre a qualidade dessa informação;
- Controle do fluxo dos dados: implementa um mecanismo de barreira para impedir que o recebimento de quadros mais rápidos encavale no recebimento dos mais lentos. Tudo isso sem que haja nenhuma perda de informação;
- Implementação de mecanismos de identificação e de controle de acesso do dispositivo ao meio físico.

O endereçamento MAC (*Mac Address*) é uma identificação única dada a qualquer dispositivo que tenha uma placa de rede. Para entendermos, podemos fazer uma analogia com o endereço de uma residência: nunca haverá duas residências com o mesmo CEP, número e complemento.

Cada fabricante que deseja estar aderente ao padrão recebe um identificador único para cada placa desenvolvida, de tal forma que nunca haverá duas placas com o mesmo endereço físico (MAC). Novamente, aqui vemos a importância dos padrões para a interoperabilidade das redes.

O protocolo IEEE 802 define qual é o padrão do endereçamento MAC para as mais diversas variações de rede: LANs, WANs, cabeadas e sem fio. Por exemplo, o protocolo IEEE 802.11 trata do endereçamento físico e do enlace para redes Wi-Fi, enquanto o IEEE 802.3 trata de redes cabeadas, chamado de padrão *ethernet*.



IMPORTANTE

O modelo de protocolo TCP/IP propõe uma simplificação do modelo de referência OSI. Nele, as camadas física e de enlace do modelo OSI são unificadas e chamadas de camada de rede. Não existe nenhuma redução de funcionalidades e objetivos e os protocolos também são os mesmos que vimos no OSI (Tanenbaum et al., 2021).

5 Camada de rede

A camada de rede é a terceira camada do modelo OSI e tem como objetivo fazer com que os dados saiam de um dispositivo de origem e trafeguem por diferentes redes, encontrando a melhor rota e garantindo que esses dados cheguem ao destinatário (Tanenbaum et al., 2021).

Em uma rede, grande ou pequena, um pacote contendo dados passa por diversos componentes desde a origem até o destino. Este pode passar por diversos tipos de cabeamento, redes não cabeadas e diferentes equipamentos que fazem a interconexão dessas redes, como *hubs*, *switches* e roteadores. Esse grande mapa contendo meios de comunicação, redes e aparelhos responsáveis por conectar tudo isso chamamos de topologia de rede.

Imagine o bairro onde você mora. O seu bairro possui muitas casas, interconectadas por ruas. Os diversos bairros da sua cidade também são ligados por ruas, projetadas para suportar mais tráfego. Por sua vez, as

cidades do seu estado são interligadas por rodovias, ferrovias ou hidrovias com uma capacidade de infraestrutura proporcionalmente maior do que as ruas do seu bairro.

Na topologia das redes, pequenas redes locais são como bairros, que podem se conectar com outras pequenas redes a partir de *hubs* ou *switches*, formando uma rede maior, que na nossa analogia seria uma cidade. Essas redes maiores podem se conectar a outras utilizando roteadores, formando assim uma rede maior.

A camada de rede do modelo OSI precisa conhecer a topologia da rede na qual o dispositivo se encontra, de tal forma a encontrar a melhor rota para entregar os pacotes de dados da origem para o destino. Os protocolos mais utilizados nessa camada são o IP (*internet protocol*) e o ARP (*address resolution protocol*). O protocolo IP (*internet protocol*), é um conjunto de endereços lógicos (não físicos, como o MAC) atribuídos aos dispositivos dentro de uma rede e as redes menores dentro de uma topologia de redes (Tanenbaum *et al.*, 2021).



PARA SABER MAIS

A atribuição dos endereços IP em uma rede pode ser feita de forma fixa ou dinâmica a partir de servidores DHCP. Existem duas versões do protocolo IP: a versão 4 (IPv4), que comporta um número menor de endereços, logo, menos dispositivos em uma rede, e o chamado IPv6, que propõe um padrão que comporta mais dispositivos.

O protocolo ARP (*address resolution protocol*) tem como função converter o endereço IP, que é um endereço lógico, para o endereço físico (MAC) do dispositivo, ou seja, ele é o responsável por, a partir desse armazenamento, descobrir qual *hardware* em uma rede corresponde a um determinado endereço IP (Tanenbaum *et al.*, 2021).

6 Camada de transporte

Segundo Tanenbaum *et al.* (2021), a quarta camada do modelo OSI é chamada de camada de transporte e tem como missão garantir que o pacote de dados seja entregue ao destinatário. Para assegurar o nível de confiabilidade na entrega, essa camada implementa a segmentação dos dados em pacotes menores a serem enviados ao destinatário, de tal forma que não haja qualquer tipo de sobrecarga tanto do canal quanto do próprio destinatário. A mesma camada, só que no destino, é responsável por rearranjar esses pacotes menores, montando novamente o dado enviado.

Ainda segundo os autores, o tratamento de erro é outra função que verifica se a mensagem foi recebida de forma correta e íntegra ou não. É na camada de transporte que é feita a confirmação do recebimento, da qualidade do dado, bem como o aceno da necessidade de retransmissão.

Os protocolos que mais representam a implementação da camada de transporte são o TCP (*transmission control protocol*) e o UDP (*user datagram protocol*). Ambos servem ao mesmo propósito, porém diferem quanto ao seu nível de complexidade. O UDP, mais simples, é também o que apresenta maior velocidade, porém um nível de confiabilidade mais baixa se comparado ao TCP, que possui mais implementações de controle que garantem a confiabilidade na entrega da informação.

O protocolo TCP é utilizado como base da navegação de páginas na web, para download de arquivos e no envio de e-mails, enquanto o protocolo UDP é usado para jogos on-line, chamadas de vídeo e streaming de áudio e vídeo, além de transmissões on-line.



PARA SABER MAIS

Existem outros protocolos que implementam a camada de transporte, como o SSL (*secure sockets layer*), TLS (*transport layer security*) e o SCTP (*stream control transmission protocol*), este muito utilizado em aplicações *streaming*, redes para dispositivos IoT e jogos on-line.

7 Camada de sessão

A quarta camada do modelo OSI é a camada de sessão, que tem como objetivo garantir que usuários em diferentes máquinas estabeleçam sessões de comunicação (Tanenbaum *et al.*, 2021).

Uma sessão de comunicação permite:

- Um controle de diálogo entre os participantes da troca de dados, de tal forma que haja um sincronismo de quem está enviando uma mensagem ou recebendo em um determinado momento do tempo;
- A implementação de um controle que impeça que dois participantes da comunicação tentem executar operações críticas ao mesmo tempo;
- O sincronismo entre os participantes de uma troca de mensagens de tal forma que, em casos de longas trocas com erros, a comunicação possa ser restabelecida do ponto em que parou.



PARA SABER MAIS

São exemplos de protocolos que implementam a camada de sessão o NFS (*network file system*) e o SMB (*server message block*) (AWS, 2023).

8 Camada de apresentação

A sexta e penúltima camada do modelo OSI é a primeira que não tem em suas atribuições a manipulação dos bites e bytes de uma mensagem. A camada de apresentação tem como objetivo trabalhar o formato sintático e semântico das informações que serão passadas para a camada de aplicação para que essa possa interpretá-las de forma correta (Tanenbaum *et al.*, 2021).

Entre as funções relacionadas à sintaxe e à semântica dos dados, está a conversão do formato dos dados a serem trafegados. Em computação, temos diversos padrões de codificação de caracteres, como o ASCII, UTF-8, ISO e EBCDIC, cada qual com a sua quantidade de caracteres e com a sua forma de representação. Caso um destinatário receba uma mensagem em uma codificação que não é a que ele entende, a camada de apresentação efetua a conversão para a codificação desejada.

É também na camada de apresentação que temos a implementação de algoritmos de compressão dos dados a serem transmitidos, de forma que não onere o canal. Esses dados podem ser textos, imagens e arquivos multimídia como som e vídeo.

Por fim, a criptografia e descriptografia dos dados transmitidos também acontece na camada de apresentação, sendo o protocolo SSL/TLS um dos mais utilizados nesse processo.

9 Camada de aplicação

A última camada do modelo OSI é a camada de aplicação e por ser a última camada é a fronteira entre os usuários e as camadas mais internas da rede. Ela tem como objetivo fornecer a infraestrutura necessária para que uma aplicação consiga enviar ou receber uma mensagem para outra aplicação (Kurose & Ross, 2021).



IMPORTANTE

Mais uma vez, a proposta do modelo de protocolo TCP/IP propõe uma simplificação do modelo de referência OSI. Nele, as camadas de sessão, apresentação e aplicação são unificadas e chamadas de camada de aplicação apenas. Novamente, não existe nenhuma redução de funcionalidades, de objetivos e os protocolos também são os mesmos que vimos no OSI.

Quando falamos em desenvolvimento de aplicações distribuídas, a interoperabilidade é fator crítico de sucesso, ou seja, sistemas desenvolvidos em diferentes linguagens de programação e com diferentes tecnologias devem ser capazes de trocar informações e serviços.

Por exemplo, imagine que você queira desenvolver o seu próprio navegador. Você escolhe a sua linguagem de programação favorita e desenvolve uma aplicação com uma caixa de texto para o usuário inserir uma URL e um botão chamado navegar.

No momento que o usuário clicar no botão navegar, espera-se que o seu navegador, a sua aplicação, faça uma requisição de conteúdo para uma aplicação hospedada em um servidor, cujo endereço é o que o usuário informou no campo URL.

Espera-se que, independentemente da linguagem de programação que a aplicação hospedada no servidor foi escrita, o conteúdo da requisição seja devolvido para o navegador e seu conteúdo exibido para o usuário final.

Essa troca de mensagens, de requisições e de respostas entre a aplicação do cliente, o seu navegador, e a aplicação do servidor só é possível pois o protocolo HTTP (*hypertext transfer protocol*), que implementa a camada de aplicação, fornece toda a infraestrutura necessária.



PARA SABER MAIS

O protocolo HTTPS (HTTP Secure) é a evolução do protocolo HTTP. Ele contém elementos de criptografia e segurança que aumentam a segurança do canal de comunicação entre clientes e servidores.

Existem outros protocolos que implementam a camada de aplicação, como o FTP, protocolo para troca de arquivos, SMTP, protocolo para troca de e-mails, e o DNS, que assim como o servidor de mesmo nome, é responsável pela tradução de domínios amigáveis em endereços IPs.

10 Introdução ao conceito de segurança de redes

O constante aumento no número de redes, cabeadas e não cabeadas, e da quantidade de dispositivos conectados, nas suas mais diversas formas, levou ao aumento da preocupação na proteção das informações trafegadas e da integridade dos sistemas que fazem parte dessa comunicação.

Segundo Kurose e Ross (2021), segurança de redes significa garantir que a comunicação entre dois dispositivos aconteça de forma segura. Isso implica dizer que alguns aspectos devem ser cumpridos integralmente, como:

- Garantir que somente o destinatário consiga interpretar uma determinada mensagem, mesmo que algum elemento indesejado nessa comunicação obtenha a mensagem;
- Garantir que uma mensagem recebida de uma determinada origem tenha sido de fato enviada por essa origem;
- Garantir que o destinatário que recebeu uma determinada mensagem é de fato o destinatário desejado;

- Garantir que o conteúdo da mensagem não foi alterado no caminho entre a origem e o destino;
- Garantir que todos os mecanismos disponíveis para a comunicação previstos no modelo de protocolo estejam de fato disponíveis.

A confidencialidade da informação é a garantia para que somente origem e destino consigam obter e interpretar os dados de uma mensagem. Para atingir esse requisito, algoritmos de criptografia, nas suas mais diversas variações, são os mais utilizados (Kurose & Ross, 2021).

A autenticação do ponto final, nas diversas implementações de protocolos de autenticação, garante que origem e destinatário são de fato quem dizem ser, enquanto implementações na camada de transporte e enlace podem garantir que o conteúdo de uma mensagem em trânsito não foi alterado (Kurose & Ross, 2021).

Garantir que todos os mecanismos de comunicação estejam de fato disponíveis é garantir a segurança operacional dos mecanismos de rede. Implementar mecanismos que impeçam que recursos da rede estejam sendo consumidos de forma indevida, de forma proposital ou não, é o primeiro passo para garantir que estes mesmos recursos estejam disponíveis para os usuários legítimos.

Para garantir a segurança operacional, temos à disposição diversas alternativas como *firewalls*, IPSEC, redes privadas virtuais e mecanismos que garantem a segurança em redes sem fios, que sempre são pontos de vulnerabilidade na topologia (Tanenbaum *et al.*, 2021).

Considerações finais

O tema redes de computadores é extenso e envolve muitos assuntos. Neste capítulo, nos propusemos a olhar os padrões que existem e que nós, enquanto usuários e desenvolvedores, muitas vezes não sabemos. Aqui, vale a pena se aprofundar um pouco mais em cada camada do

modelo OSI e entender os detalhes de suas implementações. A mesma ideia aplica-se à disciplina de segurança, particularmente aplicada ao contexto de redes de computadores.

Referências

AWS. Amazon Web Services. O que é o modelo OSI? **AWS**, 2023. Disponível em: <https://aws.amazon.com/pt/what-is/osi-model>. Acesso em: 24 mar. 2025.

KUROSE, Jim; ROSS, Keith. **Redes de computadores e a internet**: uma abordagem top-down. Porto Alegre: Bookman, 2021. *E-book*.

SILVA, Antonio Eduardo Marques da. **Redes de computadores**: teoria e prática. São Paulo: Editora Senac São Paulo, 2021.

STALLINGS, William. **Redes e sistemas de comunicação de dados**. 5 ed. Rio de Janeiro: Elsevier, 2005.

TANENBAUM, A. S.; FEAMSTER, N.; WETHERALL, D. J. **Redes de computadores**. Porto Alegre: Bookman, 2021. *E-book*.

Virtualização

Neste capítulo, veremos como a evolução das plataformas tecnológicas possibilitou a otimização do uso dos recursos computacionais até o ponto da criação de uma nova tecnologia, a virtualização.

Abordaremos as possibilidades de virtualização de sistemas de *hardware*, indicando as vantagens e desvantagens de sua adoção. Por fim, discutiremos aspectos introdutórios do conceito de containerização, que promoveu uma mudança nos paradigmas de desenvolvimento de *software*.

1 Introdução ao conceito de virtualização de *hardware*

Como vimos anteriormente, a evolução das capacidades computacionais das plataformas tecnológicas fomentou abordagens de otimização destes recursos, como por exemplo, a capacidade de multiprocessamento dos sistemas operacionais.

Porém, o avanço dos sistemas de *hardware* continuou, conforme previsto pela Lei de Moore, e apenas a capacidade de execução de mais de um processo desempenhada pelos sistemas operacionais não impediu que os recursos computacionais fossem novamente subutilizados.

A baixa utilização de recursos como memória e CPU, associada aos altos custos de aquisição e de gestão deles, foram os motivadores de uma abordagem que tinha como objetivo a otimização do seu uso: a virtualização.

O modelo de virtualização é baseado na ideia de termos mais de um sistema de aplicação, e incluem-se aqui aplicações e sistemas operacionais, sendo executados isoladamente no mesmo sistema de *hardware*. Um contraponto ao modelo anterior, em que tínhamos apenas um sistema operacional por *hardware* e, acima dele, múltiplas aplicações (Sousa Neto, 2016).

A abordagem baseada em mudanças na arquitetura de *hardware*, principalmente dos processadores, e no desenvolvimento de sistemas de *software* cria “a ilusão de múltiplas máquinas no mesmo *hardware* físico” (Tanenbaum & Bos, 2016, p. 16).

Para entender melhor, imaginemos a seguinte situação: você foi convidado para fazer um teste às cegas de um computador. Os únicos dispositivos que você tem contato são: um monitor, um teclado e um mouse. Você é capaz de utilizar o sistema operacional, abrir e fechar aplicações

e verificar a capacidade de CPU, memória e disco deste computador apenas pelas funcionalidades básicas do sistema operacional.

Porém, nesse teste, ao ser questionado se o computador que está utilizando é físico ou virtual, você seria incapaz de responder apenas com os recursos e periféricos que tem acesso. É aqui que está o grande ponto.

Na virtualização de uma máquina, o *hardware*, principalmente a CPU, é projetado para suportar múltiplos ambientes sendo executados de forma isolada e um sistema de *software* é responsável por orquestrar a criação e o funcionamento desses ambientes. Juntos, *hardware* e *software* emulam uma máquina completa, que a olho nu é impossível de ser classificada como física ou virtual (Tanenbaum & Bos, 2016).

A virtualização de máquinas é uma das aplicações do conceito de virtualização, mas não é a única. Podemos emular qualquer capacidade de *hardware*, como dispositivos de armazenamento (*storage*) e redes, conforme veremos com detalhes a seguir.

Para a infraestrutura de TI, a virtualização é um marco importante, pois com a otimização no uso dos recursos computacionais, o modelo de *data centers* externos (ou de terceiros) caminhou mais alguns passos em direção a um modelo economicamente viável. As empresas fornecedoras de serviços de *data center* passaram a oferecer serviços em escala.

Esse movimento de aumento de eficiência do consumo não só computacional, mas também de infraestrutura predial, contribuiu para a viabilidade financeira de um outro modelo computacional: a computação em nuvem (Sousa Neto, 2016).

2 Vantagens e desvantagens da virtualização

O primeiro ponto positivo na adoção da virtualização está, claro, ligado à sua razão de existir: a otimização no uso dos recursos computacionais

e, por conseguinte, aumento na eficiência nos custos de aquisição e operacionais dos sistemas de *hardware*.

Com a virtualização, reduzimos o volume de compras de dispositivos e a gestão do recurso virtualizado, feita a partir de um único sistema de *software* centralizado. Isso se torna mais eficiente do que a gestão de inúmeros sistemas de *hardware* de forma descentralizada (Sousa Neto, 2016).

Ainda segundo o autor, com menos recursos físicos de *hardware*, menor é o consumo da infraestrutura predial necessária para abarcar esses dispositivos. Aqui, falamos da redução do espaço físico e consequentemente dos aspectos que já mencionamos anteriormente, como consumo de energia, refrigeração e segurança.

Sob o ponto de vista dos sistemas de *software*, a virtualização possibilita a criação de ambientes isolados sem a necessidade de compra de um recurso físico para cada um deles. Ambientes de desenvolvimento, testes e produção totalmente separados são um grande problema com relação à uniformidade e principalmente aos custos. Com a virtualização, podemos padronizar as configurações de *hardware* de cada ambiente com um custo-benefício melhor do que comparado ao modelo de aquisição de recursos físicos (Sousa Neto, 2016).

Por fim, segundo o mesmo autor, a virtualização: “simplifica a implantação de técnicas de alta disponibilidade e recuperação de desastres” (Sousa Neto, 2016, p. 51).

Ao falarmos sobre as desvantagens do modelo de virtualização, a primeira observação fica por conta da necessidade de atualização dos sistemas de *hardware*. Não são todos dispositivos, principalmente servidores e PCs, que têm sua arquitetura projetada para permitir a virtualização, logo, um custo inicial de troca desses dispositivos deve ser considerado.

O segundo ponto é relacionado ao evidente aumento no consumo dos recursos do *hardware* físico. Capacidades como armazenamento em disco e de CPU podem ser afetadas diretamente pelo mal particionamento e, muito embora não existam métricas reais de desempenho de máquinas virtuais que possam ser comparadas seguindo os mesmos critérios em uma máquina física, a capacidade computacional pode ser afetada negativamente.

Por fim, os sistemas de *software* também são pontos frágeis na virtualização. Em primeiro lugar, os sistemas devem ser aptos a trabalhar no modelo virtualizado, tanto sistemas operacionais quanto aplicações precisam de adaptações.

As vulnerabilidades das aplicações requerem atenção especial quando falamos em virtualização. Isso porque a vulnerabilidade em um sistema, como por exemplo um sistema operacional, pode impactar o sistema como um todo (Sousa Neto, 2016).



PARA SABER MAIS

Ataques do tipo *ransomware* se caracterizam pela criptografia e sequestro dos dados das máquinas afetadas, sendo que em muitos casos é exigido o pagamento de algum tipo de compensação financeira em criptomoeda para a devolução das informações.


Em fevereiro de 2023, um ataque de *ransomware* conhecido como “ESXiArgs” afetou milhares de servidores virtuais, possibilitando a execução remota de códigos maliciosos. Esse ataque explorou uma vulnerabilidade de um fornecedor de máquinas virtuais. Muito embora essas falhas fossem identificadas e conhecidas, muitos servidores não estavam atualizados com as devidas correções, gerando uma reação em cadeia que possibilitou o ataque (Aver, 2023).

3 Virtualização de máquinas

A virtualização de máquinas, que engloba computadores pessoais e servidores, é a aplicação do conceito de virtualização dos mais utilizados na infraestrutura de TI. Esse modelo tem como objetivo permitir a criação de capacidades computacionais virtuais completas com CPU, memória, disco e sistema operacional dentro de um único sistema de *hardware* físico.

Essas capacidades computacionais virtuais, ou ambientes virtuais, coexistem no mesmo dispositivo físico e operam de forma completamente independente. A criação e gestão dessas capacidades são feitas por um sistema de *software*, que atua sob o sistema de *hardware* e faz o particionamento desses recursos para os diversos ambientes.

Figura 1 – Arquitetura de máquinas virtuais



A figura 1 mostra a arquitetura do modelo de virtualização de máquinas. Nela, é possível notar alguns pontos importantes:

- Temos apenas um recurso físico de *hardware*, indicado como máquina física;

- Os recursos físicos de *hardware* são os recursos da máquina física: CPU, memória, disco e rede;
- Acima dos recursos de rede, temos o *software* de virtualização. Ele é responsável pelo particionamento dos recursos físicos, criação e gestão dos ambientes virtuais;
- Na figura 1, temos exemplificada a criação de três ambientes virtuais, ou seja, três máquinas virtuais;
- Cada máquina virtual possui a sua própria capacidade computacional: CPU, memória, disco e rede. A soma dos recursos de cada máquina virtual não pode ultrapassar a capacidade do dispositivo físico. Por exemplo, se o *hardware* físico possuir 16 GB de memória RAM, a soma das memórias das três máquinas virtuais não pode ultrapassar 16 GB. A divisão dos recursos entre as máquinas não precisa ser necessariamente igual;
- Cada máquina virtual possui o seu próprio sistema operacional e pode variar de máquina para máquina. Por exemplo, nada impede que a máquina virtual A rode com sistema operacional Windows, enquanto as máquinas B e C executem o Linux. Aqui dois pontos importantes: a gestão de cada sistema operacional é independente, ou seja, a atualização em uma máquina virtual não será refletida no sistema operacional de outra, mesmo que sejam sistemas iguais; o custo de licença é individualizado, portanto, se tivermos três máquinas virtuais com três sistemas operacionais (mesmo que idênticos), então teremos o custo de três licenças;
- Nenhuma aplicação, ou conjunto de aplicações, executada individualmente nas máquinas virtuais, possui qualquer tipo de dependência técnica com demais aplicações de outros ambientes virtuais.

O *software* de virtualização, também chamado de *Hypervisor*, é um sistema como qualquer outro, ou seja, possui um fabricante e um modelo

de licenciamento e comercialização próprio e pode ser implantado a partir de dois modelos.

No modelo *hosted*, o *Hypervisor* é instalado em cima do sistema operacional da máquina física. Nesse caso, obrigatoriamente estaríamos sujeitos à licença de um sistema operacional, chamado *host*, e eventualmente ao custo de seu uso. O *hosted* não é uma boa abordagem para casos em que precisamos de um ambiente com alta necessidade de processamento.

Na abordagem *baremetal*, elimina-se o sistema operacional *host* e o sistema de virtualização é instalado diretamente sobre o *hardware* da máquina física. É o modelo com maior desempenho, segurança e eficiência na gestão de recursos, razão pela qual é o mais utilizado em *data centers* e provedores de computação em nuvem (Sousa Neto, 2016).



PARA SABER MAIS

Alguns exemplos de software de virtualização incluem VMware vSphere ESXi, Microsoft Hyper-V, Oracle VirtualBox, Citrix Hypervisor e Proxmox VE, cada um com suas características e focos de uso.

4 Virtualização de armazenamento

Sistemas de armazenamento, também chamados de *storage*, são um conjunto de sistemas de *software* e *hardware* cujo único objetivo é armazenar dados de forma eficiente. Essa tarefa envolve também aspectos como implementação de mecanismos eficientes de recuperação e leitura, gestão do acesso e segurança desses dados (Tanenbaum & Bos, 2016).

Segundo Sousa Neto (2016, p. 84), "um *storage* pode ser visto como um servidor de discos. Assim, quando um servidor se conecta a ele, só

enxerga uma coleção de discos". Pela tecnologia da conexão, o acesso dos dados de um *storage* a partir de um servidor é feito com uma alta velocidade de transmissão.



PARA SABER MAIS

Existem três tipos de *storage*: JBOD (*Just a Bunch Of Disks*, ou, "apenas um apanhado de discos"), RAID (*Redundant Array of Inexpensive Disks*, ou, "conjunto de discos baratos e com redundância") e *storages* inteligentes (Sousa Neto, 2016).

Na virtualização dos sistemas de armazenamento, a proposta é juntar dispositivos de armazenamentos diferentes, como discos por exemplo, e disponibilizá-los de forma unificada como se esse conjunto fosse, na verdade, uma única unidade de armazenamento.

Neste modelo, o *software* de virtualização cria unidades virtuais a partir do agrupamento de unidades físicas de armazenamento, que podem estar inclusive em diferentes equipamentos. Ele também é responsável pelo gerenciamento do espaço físico das unidades e da disponibilização de mecanismos de acesso e movimentação dos dados.

5 Virtualização de redes

A criação da topologia física que reflita a estrutura organizacional pode se tornar complexa e cara, envolvendo muitos plugues, cabos e equipamentos de conexão como *hubs* e *switches*. Esse esforço se torna ainda maior, à medida que as constantes mudanças das corporações precisam ser refletidas na forma como as redes e sub-redes estão divididas (Tanenbaum *et al.*, 2021).

Ainda segundo Tanenbaum *et al.* (2021), o conceito de redes locais virtuais ou *virtual LAN* (VLAN), padronizado pelo IEEE 802, tem como objetivo permitir a criação de redes virtuais dentro de uma rede física. Nessas redes, dispositivos são conectados e interligados sem a necessidade de cabeamento ou dispositivos físicos de conexão.

Neste modelo, *switches* especiais são projetados para segregação dessas redes virtuais, enquanto um sistema de virtualização é responsável pela atribuição do endereçamento, do roteamento de pacotes e das demais responsabilidades previstas no modelo OSI, incluindo a identificação única da rede virtual no cabeçalho do pacote trafegado entre origem e destino (Tanenbaum *et al.*, 2021).



PARA SABER MAIS

Seguindo a mesma ideia de padronização de tudo que envolve redes e protocolos de comunicação com o objetivo de garantir interoperabilidade, o padrão IEEE 802.1 Q define os padrões para VLAN, que inclui um novo formato nos quadros *Ethernet* (Tanenbaum *et al.*, 2021).

As mesmas dificuldades na disposição da topologia física de uma rede local podem ser vistas em redes de maior alcance geográfico. Empresas que possuem unidades operacionais ou *data centers* em diferentes localidades precisam dispor de um mecanismo de conexão eficiente.

As redes privadas tinham como objetivo conectar dispositivos em diferentes regiões geográficas a partir de uma infraestrutura física especializada, composta principalmente por cabos chamados de linhas (ou *links*) dedicados que, além de possuírem custo elevado, não garantiam disponibilidade, pois estavam sujeitos ao meio ambiente e pela mesma razão não tinham um bom grau de segurança (Tanenbaum *et al.*, 2021).

Ainda segundo Tanenbaum *et al.* (2021), as redes WANs públicas, como a internet, resolveram parte do problema. A conectividade entre os dispositivos se tornou mais eficiente em termos de disponibilidade, latência e custos em comparação com a rede privada, porém aumentou a exposição dos dispositivos no que diz respeito à segurança.


O conceito de Rede Privada Virtual, ou *Virtual Private Network* (VPN), surgiu para conectar dispositivos que estão em uma rede privada ou pública de forma segura, utilizando mecanismos de segurança como autenticação, criptografia e certificação digital.



PARA SABER MAIS

O IPsec (*Internet Protocol Security*) é um protocolo que tem como objetivo aumentar a segurança na comunicação de uma rede baseada no protocolo IP. Este protocolo é uma das tecnologias utilizadas como base para garantir a segurança em redes privadas virtuais (Tanenbaum *et al.*, 2021).

A figura 2 mostra a topologia de uma rede privada virtual, para um caso fictício em que temos duas localizações geográficas: Londres e Paris, cada uma com o seu *data center*. Temos ainda dois dispositivos denominados “residência” e “viagem” que representam estações de trabalho que se conectam à rede de forma segura mesmo não estando fisicamente nessas regiões.



Fonte: adaptado de Tanenbaum *et al.* (2021, p. 533).

Ainda na figura 2, podemos ver duas imagens denominadas A e B. Elas representam a mesma topologia, porém vistas sob pontos de vista diferentes. Na imagem A, temos a conexão entre componentes da rede (dispositivos e roteadores) feitas a partir de um túnel de conexão segura implementado pela VPN. Enquanto a imagem B traz a topologia da mesma rede sendo vista de dentro. Perceba que, sob o ponto de vista interno, os elementos estão conectados como se não houvesse qualquer tipo de virtualização, como se eles estivessem se comunicando por meios físicos (Tanenbaum *et al.*, 2021).

6 Introdução ao conceito de containerização

Como vimos, as máquinas virtuais consistem na emulação de um dispositivo físico completo, com CPU, memória, disco, interface de rede e seu próprio sistema operacional. Sob o ponto de vista das aplicações e do desenvolvimento de software, essa abordagem rompeu paradigmas e criou possibilidades.

Com as VMs, passamos a ter ambientes de execução das aplicações idênticos, totalmente segregados e com a facilidade de executá-los na mesma máquina física ou eventualmente em máquinas diferentes. Não que isso fosse uma grande novidade, pois podíamos ter ambientes segregados físicos, mas estes eram muito mais caros de se criar, de se manter e, principalmente, muito difíceis de se padronizar.

Em desenvolvimento de software, é importante termos ambientes segregados para atividades de codificação, testes e uso final. Isso porque essas atividades podem ocorrer em momentos distintos dentro do ciclo de vida de um projeto e as preocupações em cada uma delas são distintas. Nesse cenário, poderíamos ter, por exemplo, uma alteração de código mal testada que gerasse um erro ou uma indisponibilidade para o usuário final.

A uniformidade desses ambientes é outro fator crítico de sucesso. O comportamento de um sistema de software pode variar a depender das características de hardware e do sistema operacional em que ele é executado.

Por tudo isso, ambientes segregados físicos são possíveis, sem dúvida, porém muito onerosos em todos os aspectos, e a virtualização é uma abordagem que auxilia na resolução desse tipo de problema.

Mas como tudo em tecnologia, existia algo que ainda poderia ser melhorado no uso da virtualização voltado à execução de aplicações. Em um contexto de aplicações que não precisassem acessar recursos específicos de um sistema operacional, qual seria a necessidade de termos um ambiente, mesmo que virtual, completo com CPU, memória, disco, rede e sistema operacional?



IMPORTANTE


Existem aplicações que demandam recursos específicos do sistema operacional e outras não. Para cenários em que a dependência desses recursos existe, as máquinas virtuais são boas alternativas para a criação e segregação de ambientes.

A containerização é uma abordagem muito similar às máquinas virtuais, com a diferença que ela abstrai também a camada do sistema operacional. Um contêiner é composto tão e somente pelos componentes de *software* de uma aplicação, somados às suas dependências (como bibliotecas e outros arquivos), que compartilham o *kernel* do sistema operacional em que são executados (Vitalino; Castro, 2018).

A figura 3 mostra a diferença da arquitetura das máquinas virtuais e do modelo de containerização. Repare que nos contêineres temos apenas as aplicações e suas dependências (descritas como bibliotecas),

enquanto na virtualização, cada máquina virtual contém as aplicações, seus componentes e um sistema operacional.

Figura 3 – Arquitetura de máquinas virtuais versus arquitetura com contêineres



Ainda na figura 3, é possível notar que os contêineres, diferentemente das máquinas virtuais, não possuem recursos computacionais próprios (CPU, memória e disco). Segundo Vitalino e Castro (2018, p. 13): “são estruturas enxutas pois contêm somente o necessário para o funcionamento da aplicação”.

O modelo de contêineres, se comparado à virtualização, utiliza de forma mais eficiente os recursos computacionais da máquina física e a criação e inicialização são também mais rápidas, uma vez que não temos a necessidade de provisionamento e divisão dos recursos físicos e tampouco da instalação e execução do sistema operacional (Vitalino; Castro, 2018).

Ainda segundo os autores, a portabilidade dos contêineres entre máquinas diferentes é maior do que as máquinas virtuais (que já são boas), o que contribui na resolução de problemas relacionados a ambientes no ciclo de vida de um projeto de *software*.

Em contrapartida, os contêineres possuem um grau de isolamento menor que as máquinas virtuais. Na prática, quer dizer que se o sistema operacional possuir uma vulnerabilidade ou de alguma forma for comprometido, isso afetará os contêineres e vice-versa.



NA PRÁTICA

Na prática, não temos um modelo melhor ou pior. O critério para adoção de máquinas virtuais ou contêineres deve se basear pelas características dos problemas que queremos resolver. Por exemplo, se nossas aplicações precisarem de recursos exclusivos de um determinado sistema operacional, então a virtualização é a melhor solução, enquanto isso, se nosso problema for demandas de ambientes mais efêmeros, que possam ser criados e destruídos com maior facilidade e velocidade, então a containerização é a melhor saída.

Assim como temos diversos fornecedores de *software* que implementam o conceito do *Hypervisor* na virtualização, o *software* de containerização também possui as suas alternativas. A mais famosa e utilizada é o *Docker*, mas é importante não confundirmos o conceito com a tecnologia que o implementa.

Segundo Vitalino e Castro (2018), o *Docker* é composto por:

- *Docker Engine*: motor responsável pela execução dos contêineres dentro da máquina física.
- Imagens (ou *Docker Images*): pacote contendo todos os componentes que uma aplicação precisa para ser executada.
- Contêiner: são as imagens em execução pelo *Docker Engine*.
- Repositório (ou *Docker Hub*): repositório público e *opensource* que contém um conjunto de imagens prontas para serem utilizadas e pode ser acessado via internet no modelo cliente/servidor.
- *Docker Compose*: componente responsável por fazer a orquestração de múltiplos contêineres em execução pelo *Docker Engine*.

É importante diferenciarmos o conceito de imagem e contêiner. Uma imagem é composta por uma coleção de componentes que uma

aplicação precisa para ser executada. Nela podemos ter executáveis, binários, bibliotecas e principalmente o código e os dados da aplicação. Enquanto isso, um contêiner é a instância em execução de uma imagem.

Os contêineres são estruturas voláteis, podendo ser criados, modificados após a sua inicialização e destruídos com facilidade. Enquanto isso, imagens são perenes, não mudam após a criação de um contêiner, por isso, uma imagem pode ser utilizada para a criação de múltiplos contêineres.

Imagine uma fábrica de chocolates? Uma imagem é como uma forma utilizada para a produção de vários bombons. Cada bombom é resultado de uma forma preenchida com chocolate que, por analogia, são os contêineres.

Considerações finais

Neste capítulo, vimos como a virtualização é uma importante ferramenta para otimização na utilização dos recursos computacionais e como essa tecnologia contribuiu no fomento de outras tecnologias como *data centers* compartilhados e computação em nuvem.

Abordamos que, muito embora a virtualização de máquinas seja muito utilizada, qualquer sistema de *hardware* pode ser virtualizado e utilizado em escala como sistemas de armazenamento e redes de comunicação.

Por fim, vimos que a evolução na abordagem da virtualização contribuiu para a criação do conceito de containerização, que mudou não só aspectos de infraestrutura de TI, mas paradigmas na indústria de desenvolvimento de *software*.

Referências

AVER, Hugh. Os sistemas de virtualização e servidores Linux estão sendo atacados.

Kaspersky, 2023. Disponível em: <https://www.kaspersky.com.br/blog/linux-vmware-esxi-ransomware-attacks/21162/>. Acesso em: 3 abr. 2025.

SOUSA NETO, M. V. de. **Virtualização: tecnologia central do datacenter**. Rio de Janeiro: Brasport, 2016. *E-book*.

TANENBAUM, Andrew S.; BOS, Herbert. **Sistemas operacionais modernos**. 4 ed. São Paulo: Pearson, 2016.

TANENBAUM, A. S. *et al.* **Redes de computadores**. São Paulo: Bookman, 2021. *E-book*.

VITALINO, Jeferson Fernando Noronha; CASTRO, Marcus André Nunes. **Descomplicando o Docker**. 2. ed. Rio de Janeiro: Brasport, 2018.

Computação em nuvem

Neste capítulo, abordaremos os conceitos fundamentais da computação em nuvem (*cloud computing*) e os pontos que baseiam a decisão, ou não, da utilização da tecnologia. Apresentaremos também os tipos de *cloud* e os modelos de serviço oferecidos nesse tipo de plataforma.

Por fim, trataremos de aspectos introdutórios e importantes no que diz respeito à segurança na computação em nuvem.

1 Introdução ao conceito de *cloud computing*

Como vimos anteriormente, a evolução das capacidades computacionais, somada a técnicas de otimização do consumo destes recursos e tudo isso associado ao aumento da capacidade das redes e das telecomunicações, contribuíram para o surgimento e afirmação de um modelo de *data center* alternativo àquele em que toda a infraestrutura é responsabilidade da empresa: os *data centers on-premise*.

No modelo terceirizado, ou externo, as mesmas capacidades de um *data center* local (*on-premise*) são oferecidas por uma empresa que, via de regra, é especializada na forma de serviço. Além de eliminar todos os cuidados e custos envolvidos no modelo local, o custo reduzido e baixa latência das redes de comunicação fazem com que as empresas consumidoras desses serviços não tenham a percepção de que o modelo de fato é externo à sua infraestrutura.

Mas o que seria um serviço no contexto da tecnologia da informação?

Segundo Sousa Neto (2012), um serviço é um benefício que uma empresa entrega a outra e, no caso da tecnologia da informação (TI), é uma capacidade computacional gerenciada e firmada contratualmente que uma empresa de tecnologia fornece a outra que não é de TI, com o objetivo de apoiar na execução dos seus processos de negócio. É o conceito de TI como serviço, ou TI as a service (TlaaS).

O modelo de computação em nuvem é resultado da evolução deste cenário, somada ao aumento do nível de maturidade da computação distribuída e da arquitetura cliente/servidor. Nela, as capacidades computacionais de um *data center* são oferecidas como um serviço a ser consumido, na maioria dos casos, via internet.

O desconhecimento de onde exatamente esses *data centers* estão, somado a representações gráficas de diagramas de rede em que uma

“nuvem” era utilizada para representar uma rede de telecomunicações que conectava sistemas de forma abstrata, ou seja, sem aprofundamento nos detalhes de sua infraestrutura, gerou o termo “nuvem”.

Inicialmente, o conceito de computação em nuvem abarcava apenas serviços computacionais para processamento e armazenamento de dados. Com a evolução, esse modelo se expandiu para um conjunto de recursos virtuais de fácil acesso e utilização não apenas de *hardware*, mas de *software* e de plataformas de desenvolvimento (Sousa Neto, 2012).



PARA PENSAR

Se a utilização de *data centers* externos e por conseguinte a computação em nuvem promove a redução dos custos para empresas que consomem esses serviços, então como este modelo é economicamente viável para as empresas fornecedoras (como Google, Amazon e Microsoft)?

A resposta está na virtualização.

As empresas buscam extrair o máximo dos benefícios da virtualização em todas as suas modalidades: máquinas, armazenamento e rede. De tal forma que os sistemas de *hardware* tenham o menor tempo de ociosidade possível sem o comprometimento dos serviços.

A virtualização também garante o isolamento dos ambientes dentro de um mesmo dispositivo físico, que abre a possibilidade de múltiplos clientes consumirem o mesmo recurso de *hardware* sem que haja qualquer tipo de interferência entre eles.

O conceito de múltiplos clientes acessando o mesmo recurso, ou multi-inquilinos (*multitenancy*), juntamente com a eficiência no uso do *hardware*, promove uma economia em escala, ou seja, quanto mais clientes utilizando, menor o custo para cada um deles e mais viável economicamente é para as empresas fornecedoras.

Atualmente, os provedores de serviços de computação em nuvem têm em seu cardápio serviços que vão desde capacidade computacional, com máquinas virtuais e containerização, serviços de armazenamento, conectividade com redes virtuais, bancos de dados dos mais diversos tipos até serviços de processamento de modelos de aprendizado de máquina e inteligência artificial. Tudo isso envolto em uma grande plataforma de gestão e controle.

2 Vantagens e desvantagens no modelo de computação em nuvem

Uma das principais vantagens da computação em nuvem é a elasticidade no uso dos recursos computacionais. Para entendermos o que é isso, vamos pensar em um caso de uso. Imagine que você tenha de desenvolver e manter um site de comércio eletrônico no modelo de *data center on-premise*.

De início, você estima a quantidade de servidores e de infraestrutura necessária baseada em uma quantidade inicial de usuários. Com isso, é possível adquirir toda a capacidade computacional necessária para iniciar a operação de desenvolvimento, manutenção e uso da plataforma.

No primeiro ano das operações, ocorreram eventos sazonais como Dia das Mães, Natal e principalmente uma *Black Friday* que geraram um aumento do número de usuários e, por conseguinte, aumento na demanda por recursos computacionais da aplicação. Como a infraestrutura foi dimensionada para um número inferior de usuários, mesmo utilizando virtualização, a plataforma apresentou instabilidades, erros, problemas na operação, usuários insatisfeitos e queda na audiência do site.

Visando minimizar esses transtornos, no ano seguinte você adquire mais infraestrutura física, virtualiza o que for possível e para os períodos de eventos com maior uso, a plataforma se mostra estável. Os problemas foram resolvidos.

Agora, você tem uma outra situação para pensar. Toda a infraestrutura comprada fica subutilizada fora dos eventos sazonais e o custo para manutenção, além do custo de aquisição, se mantém em todo o período. Nesse cenário, a virtualização ajuda, mas não resolve o problema, como aponta Sousa Neto (2012).

Elasticidade de recursos computacionais é a capacidade de obter e descartar recursos conforme a necessidade de forma rápida e fácil. Esse é um dos grandes trunfos da computação em nuvem: a entrega de recursos sob demanda (Sousa Neto, 2012).

Ainda no nosso exemplo, podemos extrair outros benefícios do uso da computação em nuvem:

- Baixo investimento inicial em dispositivos físicos;
- Menor custo de gestão dos sistemas de *hardware*: a ênfase passa do gerenciamento de *data centers* para a entrega de valor ao cliente final;
- Maior previsibilidade quanto aos custos e provisionamento de recursos: passamos agora a não especular sobre a demanda e sobre a infraestrutura;
- Pagamento apenas por aquilo que se usa.

A AWS (2015) colabora com toda essa ideia na definição de computação em nuvem como:

É a entrega de recursos de TI sob demanda por meio da Internet com definição de preço de pagamento conforme o uso. Em vez de comprar, ter e manter data centers e servidores físicos, você pode acessar serviços de tecnologia, como capacidade computacional, armazenamento e bancos de dados, conforme a necessidade (AWS, 2015).

O aumento da velocidade na disponibilização de recursos também é outro fator positivo. Com isso, é possível criar ambientes inteiros com

agilidade maior do que a criação a partir da virtualização. Isso facilita, entre outras coisas, o processo de experimentação. Criar um ambiente e colocar uma versão de testes e experimentos, tão importante no processo de desenvolvimento de produtos, é muito mais fácil.

Por fim, no modelo de computação em nuvem, os fornecedores possuem diversos *data centers* espalhados pelo mundo. Com isso é possível, por exemplo, disponibilizar um produto desenvolvido no Brasil para usuários no leste asiático em minutos e sem que nos preocupemos com a latência que pode afetar a experiência do uso.

Mas como tudo em TI, não é só a partir dos benefícios que devemos analisar e, principalmente, adotar uma tecnologia.

Assim como observamos na virtualização, a computação em nuvem tem total dependência do fornecedor da tecnologia, o que chamamos de *lock-in*. Além da mudança cultural nas empresas que esse incômodo pode gerar, existe o alto custo que uma mudança de fornecedor pode acarretar, principalmente custos ligados a migração dos dados (Rose, 2020).

Ainda segundo Rose (2020), são pontos a serem considerados na adoção da computação em nuvem:

- **Dependência da rede e de uma boa conexão:** muito embora tenhamos grande capacidade das telecomunicações, casos de uso que dependem de baixíssima latência de rede devem ser analisados quanto a adoção ou não da plataforma em nuvem;
- **Baixo, porém existente, risco de quebra de privacidade:** se comparado a outros modelos computacionais, a computação em nuvem possui mais recursos de segurança para garantir a integridade e a confiabilidade dos dados. É importante a seleção de um fornecedor com parâmetros mínimos de qualidade no aspecto de segurança de dados;

- **Disponibilidade dos recursos:** eventualmente, nem todos os recursos computacionais necessários são ofertados por um fornecedor ou estão disponíveis, ou em alguns casos, estão disponíveis, mas em regiões geográficas distantes, o que pode inviabilizar uma demanda;
- **Elevação do custo final:** conforme falamos, a criação de novos recursos é simples e rápida. Esse movimento incontrolado e sem gerenciamento, somado à dependência de um único fornecedor, pode levar ao aumento exponencial dos custos.



PARA SABER MAIS

FinOps é uma abordagem que visa o gerenciamento dos custos e uso eficiente dos recursos, em termos financeiros, da computação em nuvem a partir de um conjunto de disciplinas e atividades executadas de forma estruturada (IBM, 2023).

3 Tipos de *cloud*

Existem três tipos de modelos de implantação de computação em nuvem nas empresas: nuvem pública, privada e híbrida (Google Cloud, 2023).

No modelo de nuvem pública, o mais popular dos modelos de implantação, todos os recursos computacionais são geridos e oferecidos pelo provedor, enquanto ao consumidor cabe apenas o acesso e consumo destes recursos a partir da internet. Esses recursos são compartilhados entre os diversos clientes do consumidor, o que faz com que os custos sejam reduzidos, beneficiados pela economia em escala que citamos anteriormente.

Enquanto isso, no modelo privado, os recursos são dedicados a um único cliente. Nesse modelo, podemos ter as capacidades computacionais do consumidor instaladas e mantidas na infraestrutura do fornecedor ou localmente no cliente (*on-premise*).

O modelo de nuvem privada local, em que a infraestrutura é instalada e mantida no cliente, pode parecer estranho à primeira vista. Nele é como se a organização “entregasse a chave” do seu *data center on-premise* para um fornecedor e em troca recebesse todos os serviços da computação em nuvem que teria se estivesse acessando a infraestrutura desse fornecedor.

Se comparada à nuvem pública, a nuvem privada é mais cara, pois não se beneficia da economia em escala, sendo utilizada em casos em que o cliente trabalha com dados sensíveis ou atua em um ramo de alta regulação, como instituições financeiras e órgãos governamentais.

Por fim, o modelo de nuvem híbrida é aquele que mescla em sua arquitetura recursos de uma nuvem pública com capacidades computacionais hospedados em uma rede privada. Esse modelo é eficiente para empresas que necessitam de controle total para alguns recursos, mas não para outros, podendo, portanto, se beneficiar de ambos os modelos.



IMPORTANTE

Em algumas literaturas você poderá encontrar o termo *Multicloud* como um exemplo de abordagem híbrida de nuvem.

Multicloud é o modelo de utilização de mais de um fornecedor de recursos de nuvem pública ou privada que podem ou não se integrar, enquanto o modelo híbrido é a composição de nuvens públicas e privadas que se conectam.

A ideia de utilizar múltiplos provedores é diminuir a dependência de um único fornecedor.

4 Modelos de serviço de *cloud*

Os serviços computacionais oferecidos por um provedor podem ser classificados a partir do nível de controle e gerenciamento que um cliente queira ter destes recursos, guiado, é claro, pelas soluções que pretende desenvolver.

O mesmo fornecedor pode oferecer serviços relacionados a qualquer uma das categorias que veremos a seguir, ou seja, um provedor pode ter (e é comum que tenha) em seu cardápio de serviços, capacidades computacionais de todos os tipos (Google Cloud, 2023).

São três os principais tipos de modelos de serviço de *cloud*: infraestrutura como serviço – *Infrastructure as a Service* (IaaS), plataforma como serviço – *Platform as a Service* (PaaS) e *software* como serviço – *Software as a Service* (SaaS).

No modelo IaaS, o provedor fornece recursos de infraestrutura virtual no formato mais básico. Aqui, o fornecedor é responsável apenas por manter a infraestrutura física, enquanto o consumidor é responsável pelos sistemas de *software*, dados e principalmente pelas aplicações base (*drivers* e sistema operacional) do ambiente virtual (Sousa Neto, 2012).

Os recursos de infraestrutura como serviço podem ser servidores, sistemas de armazenamento e redes virtuais.

Por exemplo, se você precisar de uma máquina virtual para hospedar uma aplicação, um provedor fornecerá este recurso com os atributos computacionais que você requisitar (CPU, memória e disco). É responsabilidade dele gerenciar o sistema de *hardware* desse ambiente, mantê-lo atualizado e disponível. Enquanto isso, será sua responsabilidade instalar sua aplicação, todas as bibliotecas que ela necessita, gerenciar os dados dela (como rotinas de *backup*) e principalmente adquirir e manter o sistema operacional.



PARA SABER MAIS

Para saber mais sobre capacidades computacionais oferecidas no modelo IaaS, procure por EC2 e S3 no site da AWS (<https://aws.amazon.com/pt/>) ou *Virtual Machines* e *Blob Storage* no site da Microsoft Azure (<https://azure.microsoft.com/pt-br>). Estes serviços oferecem recursos de máquinas virtuais e armazenamento respectivamente.

Agora, imagine que você tenha desenvolvido uma aplicação Java e precise apenas de um servidor para publicá-la. Você não quer (e não pode) ter que se preocupar com a instalação e atualização de sistemas operacionais.

No modelo de plataforma como serviço (PaaS), o provedor fornece um ambiente pronto para hospedagem de aplicações ou bancos de dados sem que o cliente precise gerenciar a infraestrutura física ou as aplicações base, que ficam sob a responsabilidade do fornecedor (Sousa Neto, 2012).



PARA SABER MAIS

Para saber mais sobre capacidades computacionais oferecidas no modelo IaaS, procure por *Elastic Beanstalk* e RDS no site da AWS (<https://aws.amazon.com/pt/>) ou *App Service* e *SQL Database* no site da Microsoft Azure (<https://azure.microsoft.com/pt-br>). Estes serviços oferecem recursos de implantação de aplicações na nuvem e serviços de bancos de dados relacionais respectivamente. Sendo que, para os serviços de banco de dados, a responsabilidade pelas rotinas de cópia de segurança (*backup*) é do fornecedor.

No tipo de serviço SaaS, *software* como serviço, as aplicações hospedadas na nuvem são oferecidas como serviço para os usuários, sendo

de responsabilidade do provedor provisionar e manter a infraestrutura física, sistemas operacionais, aplicações e dados, enquanto o cliente apenas acessa essas aplicações a partir de outros sistemas, como navegadores, por exemplo (Sousa Neto, 2012).

Neste modelo, temos uma clara mudança do público-alvo. Enquanto nos modelos IaaS e PaaS os clientes do serviço são de TI (infraestrutura e desenvolvedores), no modelo SaaS o público consumidor são usuários finais de sistemas de *software*.

Outro aspecto que varia entre os tipos de serviço é a flexibilidade. No IaaS, o desenvolvedor tem total flexibilidade para modificar e gerenciar os recursos da forma como bem entender. Enquanto no PaaS, essa flexibilidade diminui e no SaaS é quase nula.



NA PRÁTICA

O ambiente virtual de aprendizado que você utiliza, bem como o seu *web-mail* ou o *drive* virtual de arquivos que você usa para compartilhar arquivos e fotos com seus familiares e amigos são exemplos de serviços do tipo SaaS.

O modelo de computação sem servidor (*Serverless*), ou também chamado de função como serviço – *Function as a Service* (FaaS), foi o último tipo a ser criado e atualmente é muito utilizado principalmente na execução de alguns tipos de APIs.

Na computação *Serverless*, o desenvolvedor se preocupa apenas em escrever um trecho de código que possa ser executado. Não há aqui nenhum tipo de preocupação com servidores ou infraestrutura física, como temos no modelo PaaS. O provedor é responsável por provisionar e gerenciar todos os recursos necessários para execução deste programa.

O conceito de FaaS mudou o paradigma de desenvolvimento de *software* quando o caso de uso pede execução deste sistema, ou parte dele, sob demanda, ou seja, o código é executado apenas quando necessário. O desenvolvedor se preocupa apenas em escrever o código e definir os gatilhos de sua execução.



PARA SABER MAIS

Para saber mais sobre serviços *Serverless*, procure por *Lambda Functions* no site da AWS (<https://aws.amazon.com/pt/>) ou por *Azure Functions* no site da Microsoft Azure (<https://azure.microsoft.com/pt-br>).

Além do aspecto “nível de gerenciamento”, os modelos de serviço se distinguem pelo modelo de precificação. Cada fornecedor possui formas e modelos de precificação diferentes, que utilizam como forma de atrair mais usuários.

Por exemplo, em um provedor você poderá pagar menos se reservar uma determinada infraestrutura por um intervalo mínimo de tempo. Este mesmo modelo pode não estar disponível para outro fornecedor.

Não vamos entrar nesses detalhes aqui, pois a variação dos modelos para cada provedor é alta e pode mudar de um dia para o outro em função do mercado, que é altamente concorrido.

Aqui, é importante sabermos que na maioria dos casos, serviços de IaaS têm seus custos atrelados à capacidade de infraestrutura provisionada. A precificação do tipo PaaS é baseada no consumo dos recursos utilizados para hospedagem e execução das aplicações, enquanto a cobrança para FaaS é baseada apenas nos recursos utilizados na execução das funções, eliminando o pagamento de valores relativos à ociosidade da infraestrutura.



IMPORTANTE

Olhando apenas para os custos, o modelo *Serverless* parece ser o mais eficiente não é mesmo? Afinal de contas, não precisamos pagar pelo tempo ocioso das capacidades computacionais.

Acontece que o tempo de provisionamento da infraestrutura para execução de um código em FaaS é maior se comparado aos modelos PaaS e IaaS, o que seria um grande problema se sua aplicação obrigatoriamente necessitasse do menor tempo de resposta possível.

Conclusão: é importante mapear exatamente os requisitos das aplicações e estimar a capacidade computacional presente e futura para somente depois decidir qual modelo de serviço *cloud* utilizar.

5 Introdução ao conceito de segurança na abordagem de computação em nuvem

Conforme falamos anteriormente, segurança da informação é tema amplo, com muitas abordagens, metodologias e tecnologias que merecem e precisam ser aprofundadas. Quando o assunto é computação em nuvem, a regra é a mesma, com ainda um adendo: os diferentes modelos de segurança implementados pelos diferentes fornecedores.

Contudo, existem linhas comuns entre os diversos provedores e aspectos básicos que abordaremos aqui, ou seja, aquilo que você precisa saber para começar a trabalhar com computação em nuvem.

Na computação em nuvem temos sempre duas partes: o provedor da tecnologia e dos serviços e o cliente que consome ou utiliza-os. Logo, é razoável concluir que ambos tenham responsabilidades, mesmo que distintas, na proteção da infraestrutura, das aplicações e principalmente da integridade dos dados.

O modelo adotado por todos os principais provedores de serviços *cloud* é chamado de modelo de responsabilidade compartilhada na nuvem e define quais pontos da segurança são gerenciados pelo fornecedor e quais são de responsabilidade do cliente.

A ideia aqui é que se cada um cumprir a sua parte, incidentes relacionados à segurança dos serviços terão menor probabilidade de acontecer. Entre as atribuições dos fornecedores, estão:

- **Segurança da infraestrutura física predial dos *data centers*:** quando abordamos o tema *data center*, falamos sobre aspectos importantes como infraestrutura elétrica, refrigeração, telecomunicações e itens de segurança, que vão desde a implantação de controle de acesso às instalações até a escolha de lugares com menor propensão a desastres naturais. No modelo de responsabilidade compartilhada, todos os itens da estrutura física de um *data center* são de responsabilidade exclusiva do fornecedor;
- **Segurança dos sistemas de *hardware*:** atualização de servidores físicos para mitigar e reduzir vulnerabilidades e implementação de mecanismos de segurança em redes, como *firewalls* por exemplo, são exemplos de atribuições dos provedores de serviços na nuvem;
- **Gestão da virtualização:** implementação e gerenciamento de mecanismos que garantam a integridade e segregação dos ambientes virtualizados, bem como a atualização dos sistemas de *software* que criam esses ambientes, a fim de eliminar vulnerabilidades que possam causar um efeito cascata no *host* e nos ambientes – uma possível falha de segurança no *host* pode causar uma falha nos ambientes virtualizados e vice-versa;

Em contrapartida, são responsabilidades exclusivas do cliente:

- **Controle de autenticação e autorização dos usuários aos serviços:** é atribuição do cliente conceder acesso ao provedor, bem

como a implementação de mecanismos de senha e autenticação fortes, como por exemplo, o uso de múltiplos fatores de autenticação. Ainda é responsabilidade do cliente garantir que somente usuários autorizados possam consumir ou acessar um determinado recurso ou serviço;

- **Criptografia dos dados:** implementação de mecanismos de criptografia para dados em trânsito, ou seja, aqueles que estão no lado cliente e que eventualmente vão para nuvem e vice-versa, bem como dados que estão armazenados na nuvem, por exemplo, em bancos de dados e serviços de armazenamento;
- **Código da aplicação:** é de responsabilidade do cliente manter as aplicações aderentes às boas práticas de segurança e de código seguro de tal forma que elas não se tornem um elo vulnerável na nuvem.



PARA SABER MAIS

A *Amazon Web Services*, provedora de serviços em nuvem, definiu dois termos para tratar de seu modelo de responsabilidade compartilhada: “segurança DA nuvem”, para itens e aspectos que são de exclusiva responsabilidades dela, e “segurança NA nuvem”, para pontos que são de atribuições específicas do cliente (AWS, 2013).

Existem variações do modelo de responsabilidade compartilhada que podem mudar de acordo com o tipo de implantação da nuvem e a partir dos tipos de serviços oferecidos e consumidos.

Na implantação do tipo nuvem pública, por exemplo, as responsabilidades seguem o modelo que foi apresentado acima, enquanto em uma nuvem privada podem variar de acordo com o que foi acordado entre as partes sobre quem gerencia a infraestrutura. Por exemplo, se estivermos

falando de um *data center on-premise*, a responsabilidade relacionada à segurança física predial é do cliente.

Ainda no modelo de responsabilidade compartilhada, podemos ter a variação das atribuições a partir do tipo de serviço consumido na nuvem:

- **Serviços IaaS:** são atribuições do provedor a segurança física dos *data centers*, dos sistemas de *hardware* (servidores, redes, etc.) e dos sistemas de virtualização. No entanto, é responsabilidade do cliente o controle de acesso, a segurança das aplicações e dos dados e principalmente a segurança dos sistemas base, como sistemas operacionais, *drivers* e ambientes de execução dos aplicativos, como por exemplo, servidores de aplicações;
- **Serviços PaaS:** aqui, as responsabilidades são semelhantes ao modelo IaaS, com a diferença que a preocupação com os sistemas base passa do cliente para o provedor, ficando para ele apenas o controle de acesso e a segurança das aplicações e dos dados;
- **Serviços SaaS:** neste modelo, o cliente é responsável apenas pelos dados e pela gestão dos acessos. Todo o restante é de responsabilidade do fornecedor.



NA PRÁTICA

Quando o assunto é segurança envolvendo serviços de computação em nuvem, é sempre importante estudar quais são as responsabilidades do cliente e do provedor a depender dos casos de uso.

Todo fornecedor tem um manual de boas práticas de segurança, que é leitura obrigatória para todo profissional que precise consumir ou utilizar um produto na nuvem.

Considerações finais

Neste capítulo, vimos que o aumento nas capacidades computacionais e de telecomunicações, somados à virtualização e ao aumento no nível de maturidade dos modelos de computação distribuída, contribuiu para a solidificação do modelo de computação em nuvem.

Abordamos que a utilização desse modelo é benéfica para as corporações em muitos aspectos, mas como tudo em tecnologia, existem contrapontos que precisam ser observados e analisados.

Estudamos os tipos de implantação de computação em nuvem: pública, privada ou híbrida, e que cada um deles possui um caso de uso específico. Vimos também os tipos de serviços que podem ser oferecidos pelos provedores: IaaS, PaaS e SaaS, além do modelo *Serverless*.

Por fim, contextualizamos aspectos iniciais quando o assunto é segurança no consumo e fornecimento de serviços e produtos na nuvem. Estes aspectos estão agrupados no modelo de segurança compartilhada, que aponta as responsabilidades do provedor e do cliente na computação em nuvem.

Referências

AWS. Modelo de responsabilidade compartilhada. **AWS**, 2015. Disponível em: <https://aws.amazon.com/pt/compliance/shared-responsibility-model/>. Acesso em: 7 abr. 2025.

AWS. O que é a computação em nuvem? **AWS**, 2013. Disponível em: <https://aws.amazon.com/pt/what-is-cloud-computing/>. Acesso em: 7 abr. 2025.

GOOGLE CLOUD. Quais são os diferentes tipos de computação em nuvem? **Google**, 2023. Disponível em: <https://cloud.google.com/discover/types-of-cloud-computing?hl=pt-BR>. Acesso em: 7 abr. 2025.

IBM. O que é FinOps? **IBM**, 2023. Disponível em: <https://www.ibm.com/br-pt/topics/finops>. Acesso em: 7 abr. 2025.

ROSE, C. A. F. de. **O que é esta tal de nuvem e o que pode fazer por você?** Porto Alegre: EdIPUCRS, 2020. *E-book*.

SOUSA NETO, Manoel Veras de. **Cloud computing: nova arquitetura da TI**. Rio de Janeiro: Brasport, 2012. *E-book*.

Governança de infraestrutura de TI

A governança desempenha um papel essencial na organização e no direcionamento das empresas. Sob o ponto de vista da tecnologia da informação, esse conceito vem se tornando cada vez mais importante, dado que a evolução da TI levou-a a ocupar um papel estratégico nas estruturas corporativas.

Para que a governança seja de fato eficiente, é fundamental compreendermos seus principais pilares, que incluem alinhamento estratégico, entrega de valor, gerenciamento de riscos, otimização de recursos e mensuração de desempenho. Essas características, aplicadas no contexto da tecnologia da informação, buscam garantir que os processos e as operações de uma corporação, que são apoiadas pela TI, sejam executados de maneira eficiente e eficaz.

Neste capítulo, abordaremos os conceitos de governança e sua forma de utilização na tecnologia da informação. Apresentaremos como as políticas, processos, metas e métricas da governança são utilizadas no contexto da tecnologia da informação e qual é a sua importância na gestão da infraestrutura de TI.

1 Introdução ao conceito de governança

Para entender o que é governança de TI, primeiro precisamos compreender governança fora do contexto da tecnologia da informação. Para isso, vamos olhar para esse tema e responder às seguintes perguntas: o que é governança? Como funciona? Por que é importante? Quais são as desvantagens? Quais tipos de empresas aplicam esse conceito? E por fim, quais são os caminhos futuros para a governança?

Podemos definir a governança corporativa como um sistema que reúne políticas, processos, práticas e estruturas organizacionais voltadas à condução ética, transparente e eficiente das empresas. É uma abordagem que reúne boas práticas e processos que têm como objetivo fomentar a gestão eficiente, ética e transparente de uma empresa, de modo que ela seja administrada de forma responsável.

A governança corporativa funciona por meio da definição de políticas que incluem aspectos como: processos corporativos, prestação de contas, transparência, equidade, responsabilidade corporativa, definição clara de papéis e responsabilidades dos integrantes da equipe, bem como a adoção de códigos de conduta e políticas de conformidade.

Nessas diretrizes, inclui-se também a fiscalização do cumprimento, no dia a dia, de todas as políticas, a partir da criação de conselhos administrativos e de comitês de auditoria interna, cujos membros são da própria organização, ou externa, geralmente composta por empresas terceiras.

A importância da governança está nas boas práticas de gestão que as políticas se dispõem a definir. Elas procuram diminuir os riscos originados de tomadas de decisões mal fundamentadas, e a diminuição desses danos proporciona maior estabilidade nas operações e melhor posicionamento da empresa no mercado. A governança também é o caminho para a implementação da melhoria dos processos corporativos, que buscam não apenas a eficácia das operações da empresa, mas também a eficiência na forma como ela realiza suas atividades.



PARA SABER MAIS

A melhoria de processos é uma disciplina ampla que tem como objetivo mapear e aprimorar, de maneira contínua, a forma como uma organização realiza suas atividades, de tal forma que esse ciclo virtuoso a faça tornar-se mais estável e produtiva.

Entre algumas abordagens que fazem parte dessa disciplina, destacam-se o *Lean*, Six Sigma, 5S e o Ciclo PDCA.

Apesar das vantagens, a implementação de políticas de governança também pode apresentar desvantagens. O alto custo e o possível aumento da burocracia são os efeitos mais sentidos. Além disso, a governança propõe mudança cultural, que naturalmente, pode gerar resistência.

A governança pode ser utilizada por empresas de todos os portes e de todos os ramos de atividade. Todavia, companhias listadas em bolsa de valores e empresas ligadas à missão crítica, como por exemplo, sistemas de apoio à vida, devem obrigatoriamente se submeter a normas mais rigorosas de governança.



PARA SABER MAIS

Todas as empresas, norte-americanas ou não, que possuem ações listadas nas bolsas de valores dos Estados Unidos devem estar aderentes à Lei Sarbanes-Oxley, ou apenas SOx.

A SOx foi sancionada em 2002 e tem como objetivo melhorar a governança corporativa das empresas de capital aberto, de tal forma a garantir a transparência na gestão empresarial e reduzir os riscos de suas operações, transmitindo maior confiança aos seus acionistas e ao mercado em geral.

O futuro da governança passa pela TI, considerando como ela se tornou um pilar estratégico das companhias. Temas como digitalização, inteligência artificial e consumo sustentável de recursos dos *data centers*, se somam a políticas voltadas ao social e ao meio ambiente, como ESG, por exemplo (Instituto Brasileiro de Governança Corporativa, 2023).



PARA SABER MAIS


Environmental, Social and Governance (ESG) é uma abordagem com ênfase no desempenho ético e sustentável das empresas baseada em um tripé: ambiental (*environmental*) – conjunto de políticas relacionadas ao meio ambiente e sustentabilidade; social (*social*) – medidas para relacionamento com as pessoas (colaboradores, consumidores e sociedade); governança (*governance*) – políticas relacionadas à governança corporativa.

Conforme comentado anteriormente, a relação da governança corporativa e da tecnologia da informação avança à medida em que a TI passa a ter maior papel estratégico dentro das empresas.

Nesse contexto, segundo Fernandes e Abreu (2014, p. 48): “os sistemas de controle e risco e de direitos decisórios da Governança Corporativa criam as restrições de operações dos serviços e projetos de TI”.

A figura 1 mostra como a inferência da governança corporativa na tecnologia da informação cria uma camada de gestão entre elas, chamada de governança de TI.

Figura 1 – Relação entre governança corporativa e governança de TI



Fonte: adaptado de Fernandes e Abreu (2014, p. 49, figura 2.2).

Ainda na figura 1, podemos notar que as decisões sobre políticas e investimentos em TI são discutidas nos comitês executivos dentro do modelo da governança corporativa e demandadas para a governança da tecnologia da informação. Ou ainda, como exemplifica Fernandes e Abreu (2014, p. 49): “se o controle de riscos apontar que é um risco não haver um método de gerenciamento de projetos de TI, então a TI deve implementar esse método”.

2 Pilares da governança de TI

Segundo a norma ISO/IEC 38500 (International Organization for Standardization, 2024), a governança de TI é definida como um conjunto de práticas que direciona e controla a utilização atual e futura da tecnologia da informação de tal forma que ela seja utilizada de forma eficaz e, principalmente, alinhada com os objetivos estratégicos da organização.

A governança de TI, ainda segundo a norma, deve seguir seis princípios fundamentais:

- **Responsabilidade:** assegurar que papéis e responsabilidades sejam bem definidos e compreendidos.
- **Estratégia:** garantir que a TI apoie e amplie os objetivos organizacionais.
- **Aquisição:** certificar-se de que investimentos em TI são justificados e entregam benefícios.
- **Desempenho:** acompanhar o uso da TI para garantir que ela seja eficiente e atenda às necessidades da companhia.
- **Conformidade:** garantir que a TI esteja em conformidade com leis, regulamentos e políticas internas.
- **Comportamento humano:** considerar fatores humanos, como cultura organizacional e capacitação.



PARA SABER MAIS

As normas ISO/IEC são padrões internacionais desenvolvidos pela *International Organization for Standardization* (ISO) e pela *International Electrotechnical Commission* (IEC) que estabelecem boas práticas que visam garantir a qualidade, segurança, interoperabilidade e eficiência em processos, produtos e serviços em diversas áreas da tecnologia da

informação e da engenharia eletrônica. A ISO/IEC 38500 é uma norma que define princípios e diretrizes para a governança corporativa de tecnologia da informação (International Organization for Standardization, 2024).

A essência da governança de TI está em aproximar a tecnologia da informação das necessidades dos processos de negócio que ela apoia. Por exemplo, a aquisição de novos servidores ou de uma nova tecnologia de rede deve ser justificada quanto aos benefícios que trarão para a companhia e não apenas pelos desejos de TI, que podem muitas vezes ser influenciados por elementos externos aos objetivos da companhia.

Para manter a TI sempre próxima aos objetivos corporativos, Fernandes e Abreu (2014) propõem que a governança de TI deve ser composta por quatro etapas:

- **Alinhamento estratégico e compliance:** tem como objetivo definir as diretrizes estratégicas da TI, tendo como base a estratégia da corporação e requisitos legais, como por exemplo, aderência à SOx.
- **Decisão, compromisso, priorização e alocação de recursos:** define as responsabilidades da TI em termos de arquitetura, investimentos e serviços de infraestrutura. Vale ressaltar que, segundo o *The Open Group* (2011), a arquitetura de TI é a descrição da estrutura organizacional da infraestrutura técnica necessária (*hardware* e *software*) para apoiar os serviços de negócios, dados e aplicações.
- **Estrutura, processos, operação e gestão:** nessa etapa, são definidas as operações de sistemas e infraestrutura, suporte técnico e segurança da informação.
- **Gestão do valor e do desempenho:** define os indicadores que serão coletados, gerados e analisados para verificar o grau de contribuição da TI para os objetivos de negócio.

Você pode estar se perguntando em que ponto o processo de governança de TI, as leis de regulamentação (como a SOx) e a infraestrutura de TI se cruzam na vida prática.

A Lei de SOx, por exemplo, tem como grande objetivo garantir a transparência, integridade e confiabilidade das informações financeiras das empresas. Significa dizer que, em termos de requisitos de tecnologia, a qualidade da informação é um tema muito importante.

Ao fazermos a quebra desse requisito em objetivos menores, mais atingíveis, portanto, sairemos com algumas missões como: garantir que a informação esteja disponível, atualizada e correta quando for necessária.

Para termos chance de sucesso, o ideal seria não “reinventarmos a roda”, mas buscarmos um guia de boas práticas de tal forma a minimizar a possibilidade de cometer os mesmos erros que outras pessoas já cometeram.

Aqui entra a governança de TI, para nos ajudar a definir políticas e procedimentos práticos que garantam a disponibilidade da infraestrutura, gerir incidentes e problemas em ambiente de produção, gerenciar os ativos de infraestrutura, diminuir riscos inerentes à segurança da infraestrutura, entre outros.

Tudo isso para, voltando a necessidade inicial, contribuir para o aumento na qualidade das informações corporativas.

Lembre-se também que regras e leis de *compliance* indicam modelos de continuidade do negócio, ou seja, a disponibilidade da infraestrutura não só no presente, mas também no futuro, é um fator crítico de sucesso.

A governança de TI apoia a definição de um processo contínuo de análise da infraestrutura, atuando de forma pragmática sobre pontos críticos, tais como:

- a identificação da capacidade atual da infraestrutura — verificando se ela está aderente ou deficiente em relação à carga de trabalho;
- a análise de sua adequação aos objetivos futuros da companhia;
- a identificação de novas tecnologias no mercado que possam resolver problemas estratégicos da empresa;
- a avaliação dos riscos associados à infraestrutura atual, especialmente no que diz respeito à disponibilidade e à continuidade das operações;
- a verificação de conformidade com requisitos regulatórios, sejam eles internos ou externos (Fernandes; Abreu, 2014).

Ainda na linha de “não vamos reinventar a roda”, existem modelos de processo de governança de TI prontos, já difundidos e utilizados no mercado, que nos auxiliam nas tarefas de criação das diretrizes. Com eles, não precisamos criar nada, apenas seguir o que já está definido. Entre esses modelos, destacam-se o COBIT e o ITIL.

O COBIT (*Control Objectives for Information and Related Technologies*) é um conjunto estruturado de práticas, princípios e modelos para governança e gestão de TI desenvolvido pela ISACA. Ele contempla desde a definição de metas e processos até o monitoramento e avaliação do desempenho da TI.

Seu objetivo é melhorar a governança de TI, ajudando empresas a gerenciar riscos, otimizar recursos e garantir a entrega de valor a partir da tecnologia da informação e é utilizado por organizações para estruturar processos de TI, fortalecer a segurança da informação e atender a requisitos regulatórios, como a Lei SOx, por exemplo (Sousa Neto, 2019).

O ITIL (*Information Technology Infrastructure Library*) é um conjunto de boas práticas para a gestão de serviços de TI. Ele apresenta diretrizes estruturadas para a gestão do ciclo de vida dos serviços, cobrindo

desde o planejamento e a estratégia até a operação e a melhoria contínua e é utilizado por empresas para padronizar processos, reduzir custos, aumentar a eficiência e melhorar a experiência dos usuários.

Seu principal objetivo é garantir que os serviços de TI sejam entregues de forma eficiente, previsível e com qualidade, reduzindo falhas e melhorando a resposta a incidentes e mudanças. Ele se baseia em cinco estágios: estratégia, desenho, transição, operação e melhoria contínua dos serviços. Por isso, é utilizado em setores que dependem da tecnologia da informação para manter a continuidade dos negócios e trabalhar em conformidade com rigorosos critérios de regulamentações (Sousa Neto, 2019).

A principal diferença entre o COBIT e o ITIL está nos seus objetivos. Enquanto o COBIT dá ênfase à governança e gestão de TI, o ITIL olha para a tecnologia da informação e sua infraestrutura como uma prestadora de serviços que apoia estrategicamente os negócios, logo suas diretrizes são relacionadas à gestão de serviços de TI.



PARA SABER MAIS

Saiba mais sobre COBIT acessando o site da ISACA no link: <https://www.isaca.org/>. Enquanto isso, mais informações sobre o ITIL podem ser obtidas no site da Axelos, empresa detentora dos direitos do *framework*: <https://www.axelos.com/certifications/itil-service-management/>.

A governança de TI caminha para, independentemente do modelo adotado, se adaptar às diferentes naturezas da tecnologia da informação que a empresa possui. TI bimodal é um conceito criado pelo Gartner que se refere a uma abordagem de gestão da tecnologia dividida em dois modos distintos, cada um com um propósito específico:

- **Modo 1 (tradicional):** tem ênfase na estabilidade, previsibilidade e segurança. Esse modelo segue processos rígidos e bem estruturados, sendo ideal para sistemas críticos e operações que exigem alta confiabilidade, como infraestrutura de TI e sistemas financeiros.
- **Modo 2 (ágil e inovador):** voltado para a experimentação, flexibilidade e velocidade. Esse modelo adota metodologias ágeis para desenvolvimento iterativo e incremental, permitindo a inovação e adaptação às mudanças do mercado.

A TI bimodal permite que as empresas mesquem a necessidade de manter a robustez, disponibilidade, confiança e segurança de sistemas tradicionais com a agilidade e inovação exigidas para determinadas situações (Sousa Neto, 2019).

Aqui, não se trata de termos qualquer tipo de governança, mas sim um modelo que se adapte à realidade do papel da TI e de como ela contribui para os processos de negócios que apoia.

Implantar um modelo de governança de TI que nos permita colher todos seus benefícios, não se resume à adoção de um ou outro padrão ou *framework*. O processo deve ser cíclico e incremental, buscando sempre a melhoria contínua.

É como a criação de um hábito. Um hábito é algo que fazemos de uma determinada forma e que, ao ser repetido diversas vezes, se torna automático, orgânico.

Para que isso aconteça, é fundamental a implantação de um mecanismo que permita a extração de dados e de indicadores sobre como a TI está operando. É a partir das informações que temos insumos para entender o que está bom e o que pode ser melhorado, para que nós, enquanto tecnologia da informação, também possamos tomar ações de forma embasada. Segundo Fernandes e Abreu (2014, p. 163): “você não gerencia o que você não consegue medir”.

3 Metas e métricas

O modelo de metas e métricas da governança de TI consiste num processo bem estruturado de definição de objetivos de desempenho, criação de indicadores para acompanhamento do percentual de atingimento desses objetivos, bem como a tomada de ações e melhorias baseadas nestes indicadores (Fernandes; Abreu, 2014).

Ainda segundo os autores, com metas e métricas, é possível:

- criar metas para melhoria dos processos e serviços;
- medir o grau de atingimento das metas;
- identificar quem ou o que são os detratores das metas;
- gerenciar projetos de TI com base em fatos e dados;
- garantir o bom funcionamento da TI como um todo: riscos sob controle, conformidade com regulamentos internos e externos e valor sendo gerado para o negócio;
- ser mais proativo quanto aos problemas, ou seja, a partir da medição, é possível identificar comportamentos anômalos com antecedência e tomar ações antes que o risco se torne incidente;
- propor rotas de correção para a TI e verificar se essas mudanças geraram efeitos positivos ou negativos.

O primeiro passo desse processo é definir quais são os objetivos de desempenho, ou metas, a serem atingidas. Existem muitas formas e abordagens para definição de metas, segundo o COBIT (Isaca, 2012). Conforme mencionado por Fernandes e Abreu (2014), as metas podem ser de três tipos:

- **Metas corporativas genéricas:** estão associadas à estratégia de negócio da corporação;

- **Metas de TI:** são aquelas que definem o que o negócio espera da tecnologia da informação;
- **Metas específicas:** definem qual é o objetivo de cada processo de tecnologia dentro das metas de TI.

Para exemplificar, suponhamos que precisamos definir metas e métricas para um processo que tem como objetivo promover a disponibilidade e a continuidade das operações de negócio.

Uma possível meta corporativa para este caso seria “garantir a disponibilidade e a continuidade dos serviços de negócio”, e os indicadores a serem medidos poderiam ser “quantidade de horas perdidas pelos usuários por mês devido a interrupções não planejadas nos serviços”.

Ao desdobrarmos essa meta para uma meta relacionada à TI, poderíamos ter “fazer com que as informações sejam confiáveis e estejam disponíveis para tomada de decisões”, enquanto as métricas poderiam ser “quantidade de incidentes em processos críticos de negócio causados por indisponibilidade de informações”.

O segundo desdobramento, transforma a meta de TI em uma meta específica do processo. Aqui, teríamos como exemplo: “disponibilizar informações críticas para o negócio em conformidade com os níveis de serviços mínimos requeridos”, e para medir essa meta, um indicador seria “percentual de restaurações de cópias de segurança feitas com sucesso e realizadas em tempo hábil” (Fernandes; Abreu, 2014).



PARA SABER MAIS

Definir metas e indicadores nem sempre é uma tarefa fácil. Porém, existem abordagens e métodos que nos ajudam nessa missão.

As metas SMART são um modelo de definição de objetivos que garante que eles sejam claros, mensuráveis e alcançáveis. O acrônimo SMART representa cinco critérios fundamentais que uma meta deve atender: *Specific* (específica) – A meta deve ser clara, sem ambiguidades;

Measurable (mensurável) – Deve ser possível medir o progresso; *Achievable* (atingível) – O objetivo precisa ser factível de ser atingido; *Relevant* (relevante) – Deve estar alinhada aos objetivos estratégicos; *Time-bound* (temporal) – Deve ter um prazo bem definido para ser alcançada.

Os KPIs (*Key Performance Indicators*) e os OKRs (*Objectives and Key Results*) são, respectivamente, um *framework* de gestão e um conjunto de indicadores utilizados para medir e gerenciar o desempenho de uma organização. Os KPIs (indicadores-chave de desempenho) são métricas utilizadas para monitorar o desempenho de processos e atividades específicas; enquanto o OKR (objetivo e resultados-chave) é um *framework* de definição de metas que combina objetivos qualitativos com indicadores mensuráveis.

O processo de metas e métricas segue para o processo de coleta, armazenamento e análise dos indicadores. Aqui, pode ser necessária a utilização de ferramentas para obtenção dos dados, repositório para o armazenamento e sistemas matemáticos e estatísticos que auxiliem na análise.

Quanto à infraestrutura de TI, a dica é sempre pesquisar e utilizar ferramentas que automatizem o monitoramento dos componentes e que possam fornecer dados, também de forma automática, da saúde ou não dos elementos que compõem a infraestrutura, como servidores, componentes de rede, sistemas operacionais e aplicações.

A última etapa do processo é comunicar o nível de atingimento dos indicadores e a situação atual das metas em relação ao que foi estabelecido inicialmente. Ferramentas de visualização de dados que dispõem de gráficos são grandes facilitadores nessa etapa.

Segundo Fernandes e Abreu (2014), a comunicação é um fator crítico não só para a governança de TI, mas para a tecnologia da informação como um todo. A chave aqui está em saber que, ao comunicarmos, precisamos estar atentos ao público-alvo das informações que pretendemos mostrar e a partir daí construir uma boa estratégia de comunicação.

Apresentar gráficos e números que indicam o percentual de indisponibilidade de um determinado recurso computacional, como um servidor ou um componente de rede, pode ser muito útil para um gestor de TI, mas pouco produtivo para o presidente da companhia.

Considerações finais

Neste capítulo, vimos que a governança corporativa é um conjunto de políticas, processos e práticas que visam direcionar, administrar e controlar uma organização, garantindo transparência, equidade, prestação de contas e definição das responsabilidades.

A governança de TI está diretamente relacionada à governança corporativa, pois trata da gestão estratégica da tecnologia da informação dentro da companhia. A TI desempenha um papel estratégico na tomada de decisões e de apoio às operações, sendo importante garantir que ela esteja alinhada aos objetivos estratégicos da empresa, mitigando riscos e assegurando conformidade regulatória.

Frameworks como COBIT e ITIL podem ajudar na implantação da governança de TI, mas é importante uma mudança cultural na adoção de metas e métricas de tal forma a assegurar que a tecnologia da informação esteja correndo em paralelo aos objetivos do negócio que apoia.

Referências

FERNANDES, Aguinaldo Aragon; ABREU, Vladimir Ferraz de. **Implantando a governança de TI da estratégia à gestão dos processos e serviços**. 4. ed. Rio de Janeiro: Brasport, 2014. *E-book*.

INSTITUTO BRASILEIRO DE GOVERNANÇA CORPORATIVA. **Código de Melhores Práticas de Governança Corporativa**. 6. ed. São Paulo: IBGC, 2023.

INTERNATIONAL ORGANIZATION FOR STANDARDIZATION. **ISO/IEC 38500: Information technology – Governance of IT for the organization**. 3 ed. Genebra, 2024.

ISACA. **COBIT 5: Enabling Processes**. Rolling Meadows: ISACA, 2012.

SOUSA NETO, Manoel Veras de. **Gestão da tecnologia da informação: sustentação e inovação para a transformação digital**. Rio de Janeiro: Brasport, 2019.

THE OPEN GROUP. **TOGAF Version 9.1: The Open Group Architecture Framework**. Zaltbommel: Van Haren Publishing, 2011.

Infraestrutura de TI: presente e futuro

A infraestrutura de tecnologia da informação tem passado por uma transformação significativa nas últimas décadas, impulsionada pelo avanço de tecnologias emergentes. O modelo tradicional de gestão de infraestrutura, baseado na configuração manual e provisionamento físico, vem sendo substituído por abordagens mais dinâmicas e automatizadas, como a infraestrutura como código.

Além da automação da infraestrutura, o suporte às novas demandas tecnológicas exige arquiteturas robustas e altamente escaláveis. No *big data*, por exemplo, a infraestrutura precisa trabalhar com grandes volumes de dados em tempo real, garantindo alto desempenho e confiabilidade.

Da mesma forma, a Internet das Coisas (IoT) impõe desafios únicos, como a conectividade distribuída e a necessidade de processar informações na borda da rede (*edge computing*). Esses cenários demandam soluções flexíveis, que otimizem o uso de recursos e garantam baixa latência.

Por fim, a crescente adoção de inteligência artificial e aprendizado de máquina exige infraestruturas especializadas, com capacidade computacional avançada para processamento e armazenamento. Além disso, questões como disponibilidade, segurança e eficiência energética precisam ser consideradas quando projetamos a infraestrutura que dará conta dessas demandas.

Neste capítulo, abordaremos os requisitos técnicos e os pontos de atenção que nos ajudam a planejar e projetar a infraestrutura sob a perspectiva das tecnologias emergentes.

1 Infraestrutura como código

Imagine o seguinte cenário: você trabalha em uma *startup* cujo produto principal é uma plataforma de comércio eletrônico que tem como objetivo conectar pessoas que vendem determinados produtos com potenciais consumidores. Inicialmente, você dimensionou sua infraestrutura para um certo número de usuários, mas para sua surpresa (positiva) essa base cresceu inesperadamente.

Nesse cenário, estamos diante de um caso clássico de escalabilidade, ou seja, sua infraestrutura precisa crescer para comportar os requisitos computacionais do aumento da sua base de usuários.

Para atender essas demandas, seu time de engenheiros, de forma manual, cria recursos (como máquinas virtuais e contêineres) sempre que necessário e, periodicamente, faz uma varredura na infraestrutura, desalocando e removendo recursos que eventualmente estejam subutilizados.

A princípio, esse método parece eficiente, mas à medida que o número de usuários aumenta e, por conseguinte, aumenta a quantidade de tarefas para o time de TI, alguns problemas começam a surgir.

Por mais que o time se esforce, os ambientes novos naturalmente demoram a ser criados, testados e disponibilizados, o que faz parte do processo. Além da limitação da própria tecnologia, uma equipe sobrecarregada não consegue provisionar recursos na velocidade necessária.

Cada engenheiro, manualmente, executa a criação ou manutenção dos recursos de uma determinada maneira, o que pode levar a inconsistências nos ambientes, ou seja, as configurações podem variar de um recurso para outro. Ademais, falhas humanas nesse processo podem levar a falhas, instabilidades e até a indisponibilidade da infraestrutura.

Infraestrutura como código, ou *Infrastructure as Code* (IaC), é uma abordagem para gerenciar e provisionar recursos de infraestrutura de TI a partir de código, na contramão da realização das mesmas atividades via processos manuais. Servidores, recursos de rede, bancos de dados e outros componentes são definidos e configurados usando arquivos de código (Morris, 2020).

Ainda segundo Morris (2020), a adoção dessa abordagem possui alguns pontos positivos:

- **Consistência:** reduz a necessidade de configuração manual, fazendo com que todos os ambientes (desenvolvimento, testes, produção, etc.) sejam padronizados e replicáveis em qualquer momento do ciclo de vida do produto.
- **Escalabilidade:** permite aumentar ou reduzir a infraestrutura de maneira automatizada, logo, de forma mais eficiente.
- **Rastreamento e versionamento:** como a infraestrutura é tratada como código, é possível rastrear mudanças e reverter configurações indesejadas.
- **Segurança:** políticas de segurança podem ser aplicadas para garantir que a infraestrutura atenda a requisitos corporativos e regulatórios.

Segundo o mesmo autor, a prática de infraestrutura como código utiliza arquivos de configuração para definir a infraestrutura, permitindo que ferramentas especializadas provisionem e gerenciem os recursos automaticamente. Existem duas formas de descrição de infraestrutura:

- **Modelo imperativo:** nesse modelo, o engenheiro descreve o passo a passo de como a infraestrutura deve ser provisionada e configurada. Cada comando representa uma instrução exata de como atingir o estado desejado. Esse modelo oferece maior controle, mas exige mais detalhamento e manutenção do código.
- **Modelo declarativo:** aqui, o engenheiro descreve a configuração desejada da infraestrutura e uma ferramenta especializada se encarrega de executar as mudanças necessárias para provisionar recursos e alcançar a configuração desejada. Esse modelo é mais simples de manter, pois abstrai o *“como fazer”*, focando apenas em *“o que é necessário”*.

Os códigos de IaC podem ser integrados a outras ferramentas dentro do ciclo de vida do projeto, o que automatiza o provisionamento e

gestão de recursos, além de possibilitar testes e validações, de tal forma que a criação de uma infraestrutura seja feita da forma mais segura possível.



PARA SABER MAIS

CI/CD é uma abordagem de desenvolvimento de *software* que pode ser aplicada ao contexto de infraestrutura como código e que automatiza a integração e a entrega de código, contribuindo para ciclos de desenvolvimento mais rápidos e seguros.

Integração contínua, ou CI (*Continuous Integration*) tem como objetivo automatizar a junção de códigos de diferentes engenheiros em um repositório central e executar testes automaticamente para detecção de erros. Enquanto isso, implantação contínua, ou CD (*Continuous Delivery*) tem a missão de garantir que o produto final esteja pronto para ser implantado automaticamente com qualidade.

Uma esteira de CI/CD é um conjunto automatizado de processos que transformam código-fonte em um *software* funcional e pronto para uso. Os códigos gerados na IaC podem ser integrados a esse tipo de esteira, garantindo que mudanças de infraestrutura sejam testadas e aplicadas de maneira segura e automatizada.

Segundo Morris (2020), muito embora a infraestrutura como código traga muitos benefícios, ela também apresenta alguns desafios:

- Aprendizado e mudança de paradigma de desenvolvimento: engenheiros e desenvolvedores precisam aprender novos modelos de declaração de infraestrutura e conhecer novas ferramentas de automação.
- Erros na automação podem causar problemas em escala maior.
- Quanto mais complexa é a infraestrutura, mais complexo é o código que automatiza o provisionamento e o gerenciamento. Isso

naturalmente promove um aumento na complexidade do desenvolvimento e gestão do produto.



NA PRÁTICA

Provedores de nuvem como AWS, Microsoft Azure e Google Cloud são o que mais se beneficiam com a abordagem de infraestrutura como código, e a utilizam para provisionar e gerenciar sua infraestrutura com serviços como *CloudFormation* (AWS, 2011), *Azure Resource Manager* (Microsoft, 2025) e *Deployment Manager* (Google Cloud, 2025) respectivamente. Na prática, utilizamos muito esses recursos para criação e gestão de recursos em nuvem, em associação com ferramentas de IaC como *Terraform* (Hashicorp, 2022) e *Ansible* (Red Hat, 2016).

A infraestrutura como código caminha para utilização cada vez maior de modelos declarativos – a partir do uso de ferramentas como Terraform e Pulumi, para integração cada vez maior com componentes de inteligência artificial que possibilitam a otimização do processo de configuração, além da crescente adoção de ferramentas que permitem menos codificação (*low code*), ideal para equipes que não têm conhecimento nos modelos de declaração e nas ferramentas de automação.

Por fim, a preocupação com a segurança se faz cada vez mais presente, a partir da integração de políticas diretamente no código que provisiona a infraestrutura, em uma abordagem chamada segurança como código, ou *Security as Code* (SaC) (Morris, 2020). Nela, políticas de segurança são definidas e versionadas como código, possibilitando automação, rastreabilidade e validação contínua. Isso inclui práticas como *Policy as Code*, nas quais ferramentas especializadas, como o *Open Policy Agent* (OPA), são utilizadas para aplicar regras de conformidade durante o provisionamento da infraestrutura ou dentro de *pipelines* de CI/CD.

2 Infraestrutura em *big data*

Sistemas transacionais, muito utilizados no nosso dia a dia, como sistemas financeiros (*internet banking*, caixas eletrônicos e meios de pagamento), comércio eletrônico, sistemas de gestão empresarial, aplicativos de transporte e mobilidade urbana, sistemas de saúde, entre outros, produzem uma enorme quantidade de dados.

A evolução tecnológica e das plataformas adicionou a esse conjunto de grandes produtores de informações as aplicações embarcadas (e seus muitos tipos de sensores), os dispositivos da Internet das Coisas e, principalmente, as redes sociais.

Nesse cenário, com cada vez mais fontes produtoras de informações dos mais diversos tipos, temos dados sendo gerados em maior volume e velocidade. Para entender o que é a variedade dos dados, imaginemos um exemplo do cotidiano: uma empresa que produz um determinado produto possui uma área de serviço de atendimento ao consumidor responsável por atender reclamações, dúvidas, sugestões e eventualmente responder elogios.

Essa empresa possui diversos canais para que os consumidores entrem em contato: um *website*, em que o usuário seleciona previamente sobre o que deseja falar (reclamação, dúvida, sugestão, etc.) e escreve uma mensagem; um canal em um aplicativo de trocas de mensagens, no qual o cliente escreve uma mensagem livre; e suas redes sociais (Facebook, Instagram, Twitter/X, etc.) para que os consumidores possam interagir.

Perceba que no caso do *website*, as informações já estão “categorizadas”, sabemos de antemão, a partir da opção que selecionada pelo cliente, de que tipo é a mensagem recebida. Não se pode dizer o mesmo das mensagens de aplicativo, pois essas precisariam ser lidas, interpretadas e categorizadas como reclamação, dúvida, sugestão, etc.

Os dados vindos das redes sociais seguem o mesmo padrão. As mensagens precisariam ser analisadas previamente para serem rotuladas, mas com um complicador adicional: as informações podem estar em diversos formatos. Dados originados do Instagram, por exemplo, são imagens, enquanto de redes como o Facebook ou Twitter/X são textos livres. Podemos ainda ter informações importantes vindas de um vídeo.

Temos aqui o que chamamos de grande variedade de dados. Informações importantes e vitais para o negócio vindas de forma estruturada (*website*), textos livres, imagens e vídeos.

Big data é a abordagem para o armazenamento e tratamento de dados produzidos em grande volume, velocidade e variedade, que são os chamados “3 Vs do *big data*”. Somam-se a esses três: veracidade – que indica a qualidade e confiabilidade dos dados, garantindo que sejam precisos para análise, e valor – a capacidade de transformar dados em informações úteis para tomada de decisão, compondo o que algumas referências bibliográficas denominam de “5 Vs” (Sousa Neto, 2019).

A infraestrutura de TI para *big data* envolve diversas tecnologias que têm como objetivo tratar a coleta, armazenamento, processamento, análise e visualização de grandes volumes de dados, não deixando de lado a segurança da informação.

Para a tarefa de armazenamento de dados, destacam-se as tecnologias de *Data Lake*, que são repositórios de dados centralizados que permitem armazenar grandes volumes de dados exatamente como foram gerados, ou seja, vindos de diferentes fontes e nos mais variados formatos sem a necessidade de pré-processamento.

Diferentemente dos repositórios de dados tradicionais, como os bancos de dados relacionais, o *Data Lake* é projetado especificamente para o armazenamento de dados gerados em velocidade, volume e com variedade que permite obter uma escalabilidade massiva, podendo chegar aos *exabytes*.

Um *Data Lake* pode ser um recurso computacional configurado em uma estrutura local (*on-premises*) ou um serviço adquirido no modelo de serviços de um provedor de computação em nuvem (Tiessi; Freitas, 2023).

Uma vez que os dados estão armazenados, é necessário processá-los, que é a etapa que tem como objetivo transformar grandes volumes de dados brutos em informações estruturadas e úteis para análises e tomada de decisão. A maneira mais eficiente de fazer isso é utilizar ao máximo a capacidade computacional de um recurso, utilizando paralelismo.

Segundo Tiessi e Freitas (2023), o Apache Hadoop é um *framework* de código aberto, criado pela *Apache Software Foundation*, projetado para o processamento distribuído de grandes volumes de dados. Ele permite que dados sejam processados de maneira eficiente em *clusters* de computadores (que não precisam ser um *hardware* específico ou ter um processador dedicado), utilizando paralelismo, arquitetura escalável e tolerância a falhas.



PARA SABER MAIS

O HDFS (*Hadoop Distributed File System*) é o sistema de arquivos distribuídos do Apache Hadoop, portanto também de código aberto e projetado para armazenar e gerenciar grandes volumes de dados de forma escalável, eficiente e tolerante a falhas.

Ele permite que os dados sejam divididos e armazenados em vários servidores de um *cluster*, garantindo redundância e acessibilidade (IBM, 2024).

Uma vez que os dados foram armazenados e processados, é necessário analisá-los. Ainda segundo Tiessi e Freitas (2023, p. 31): “existem inúmeras ferramentas analíticas disponíveis no mercado, elas são classificadas como plataformas analíticas e de BI”. Algumas dessas

ferramentas incorporam algoritmos de inteligência artificial e aprendizado de máquina para auxiliar no processo humano de transformar informações em conhecimento e inteligência.

3 Infraestrutura em Internet das Coisas (IoT)

Internet das Coisas, ou *Internet of Things* (IoT), é o conceito que une dispositivos físicos do nosso dia a dia (como eletrodomésticos, veículos e roupas), sensores, sistemas de *software* e redes, que têm como objetivo a troca de dados com sistemas distribuídos (Duraes *et al.*, 2022).

Perceba que apenas na definição de IoT, tocamos em aspectos de infraestrutura de TI abordados no decorrer dessa obra, como redes, e podemos desdobrar o tema para protocolos de comunicação, redes locais, internet e segurança de redes e sistemas distribuídos – que contempla desde *data centers* até computação em nuvem.

Quando falamos de Internet das Coisas, não podemos nos limitar à ideia de que ela é aplicável somente a dispositivos de consumo, como eletrodomésticos, roupas e sensores residenciais.

Dispositivos ligados à área da saúde, transportes, indústria, agricultura e infraestrutura urbana (com a ideia de cidades inteligentes) também fazem parte do conjunto de dispositivos físicos de IoT, e para cada um desses casos de uso, é necessária uma configuração de infraestrutura que atenda de maneira mais eficiente (Sinclair, 2018).

O primeiro aspecto de infraestrutura importante para IoT são os sensores. Eles fazem com que um dispositivo IoT interaja com o ambiente. Sensores transformam valores de leitura analógicos em informações digitais que podem ser enviadas a um sistema central (Duraes *et al.*, 2022).

São exemplos de sensores:

- Sensor de temperatura e umidade: utilizado na agricultura, casas inteligentes e indústrias para monitoramento do meio ambiente. São exemplos desses sensores o DHT11 e o DHT22.
- Sensor de qualidade do ar: é utilizado em sistemas de climatização e segurança na saúde para monitorar a presença de gases tóxicos como benzeno, dióxido de carbono e amônia. Um exemplo para essa categoria de sensores é o MQ-135.
- Acelerômetro e giroscópio: utilizado em sistemas de navegação, drones e roupas. Estes sensores detectam movimento, inclinação e rotação. O MPU6050 é um exemplo de sensor para esta finalidade.



IMPORTANTE

Enquanto os sensores transformam valores de leitura do meio ambiente em informações digitais, os atuadores fazem o caminho oposto.

Eles convertem dados digitais em algo perceptível fisicamente no meio ambiente, como LEDs, dispositivos sonoros (como buzinas e *buzzers*), relés, válvulas e bombas.

O segundo aspecto importante ao tratarmos de infraestrutura para IoT é a conectividade. Muito embora o nome sugira, não são todos os dispositivos que estão conectados à internet, eventualmente podem estar conectados a uma LAN ou sequer estarem conectados a uma rede (Duraes *et al.*, 2022).

Ainda segundo os mesmos autores, os dispositivos da Internet das Coisas podem estar conectados direta ou indiretamente à internet. No modelo de acesso direto, os dispositivos devem estar aptos a operar no protocolo TCP/IP, enquanto no modelo indireto, um dispositivo

intermediário é responsável por fazer a conexão entre o dispositivo IoT e a internet.

A conexão indireta de um dispositivo à internet pode se dar a partir de um *gateway*, que é um componente de rede responsável por centralizar o recebimento das requisições. Nesse sentido, caso seja necessário converter o formato dessa mensagem para um formato padrão (como TCP) e propagá-la a outros sistemas distribuídos na internet, ou ainda a partir de uma rede de dispositivos em que um desses sistemas tenha acesso direto à rede e atue como *gateway*, esse mecanismo garante a comunicação eficiente entre dispositivos conectados. Uma variação interessante é a topologia *mesh*, na qual os dispositivos formam uma malha de comunicação distribuída. Nessa arquitetura, os nós se comunicam diretamente entre si, repassando dados de forma cooperativa. Um ou mais desses nós podem ter acesso direto à internet e funcionam como *gateways*, centralizando a conexão com sistemas externos.

Existem também variações de modelos quanto à implementação da camada de redes e física na topologia de redes IoT. Existem sistemas não baseados em IP, dos quais se destacam os padrões *Bluetooth*, *Bluetooth Low Energy*, *LoRaWan* (rede de rádio de longa distância), *Zigbee* (baseada no modelo de protocolo IEEE 802.15.4) e *Z-Wave*. Esses dois últimos muito utilizados em aplicações comerciais e residenciais.



IMPORTANTE

Dispositivos que estejam conectados a partir de um modelo não baseado em IP precisam de um dispositivo intermediário, como um *gateway*, para se conectar à internet.

O segundo modelo são os sistemas baseados em IP. Os padrões *Wi-fi* (baseado no protocolo IEEE 802.11), *Ethernet*, *Cellular IoT* e comunicação por satélite são os destaques desse padrão de conectividade.

Trafegar dados entre dispositivos da Internet das Coisas e sistemas distribuídos também requer atenção. O formato da mensagem e a forma como ela é empacotada e enviada a partir da rede determinam o quão eficiente será a comunicação.

Os modelos relacionados a camada de aplicação também possuem diferenças e servem a propósitos diferentes. Além do protocolo HTTP/HTTPS, são exemplos de padrões:

- MQTT (*Message Queuing Telemetry Transport*): é um protocolo mais simplificado, que trafega dados binários sobre o protocolo TCP/IP, e mantém sempre o dispositivo conectado à rede. Ele é ideal para dispositivos com pouca capacidade de processamento.
- AMQP (*Advanced Message Queuing Protocol*): se assemelha ao MQTT, porém sua maior robustez é ideal para tráfego de grandes volumes de dados. É utilizado, por exemplo, em aplicações industriais e agrícolas.
- CoAP (*Constrained Application Protocol*): protocolo leve baseado em UDP, projetado para comunicação eficiente entre dispositivos com recursos limitados. É ideal para comunicação ponto a ponto (*peer-to-peer*) e pode ser usado como alternativa em casos em que os protocolos baseados em TCP, como o MQTT ou o AMQP, não são viáveis.

Ainda falando sobre comunicação, alguns requisitos necessitam de atenção especial: latência e economia de banda de rede, resiliência no funcionamento dos dispositivos, mesmo sem conexão com a rede, e segurança.

Um dispositivo *Edge*, muito utilizado na arquitetura IoT, é um equipamento responsável pelo processamento de dados mais próximo da origem, ou seja, mais próximo possível dos dispositivos que capturam as informações sem que elas precisem ser enviadas diretamente para fora da rede.

Ele atua como um intermediário entre os dispositivos IoT e a rede, reduzindo a necessidade de enviar todos os dados a todo instante para os sistemas distribuídos, diminuindo o tráfego da rede, aumentando a disponibilidade dos dispositivos e mantendo informações sensíveis dentro da rede, aumentando assim a segurança.

Alguns tipos de dispositivo *Edge* são providos de inteligência com capacidade analítica em tempo real. Isso é particularmente interessante em sistemas que necessitam de tomadas de decisões em tempo real, como controle de máquinas e processos produtivos na indústria e o monitoramento de pacientes na saúde (Sinclair, 2018).

4 Infraestrutura para aprendizado de máquina e inteligência artificial

Inteligência artificial é a área do conhecimento que tem como objetivo desenvolver sistemas que realizem tarefas independentes de interações humanas. Esses sistemas executam tarefas ou funções que se aplicam a diferentes casos de uso, como aprender, tomar decisões e interpretar linguagens naturais, sempre da maneira mais autônoma possível (Suave, 2024).

Aprendizado de Máquina, ou *Machine Learning* é uma subárea da inteligência artificial que permite que sistemas aprendam ou melhorem por meio da experiência sem serem explicitamente programados para isso (Suave, 2024, p. 10).

Boa parte dos algoritmos que são a base da IA e do aprendizado de máquina foram desenvolvidos décadas atrás, mas tiveram uso efetivo a partir do momento em que o avanço da capacidade computacional suportou sua execução.

A capacidade computacional necessária para a execução de algoritmos de IA envolve principalmente o poder de processamento e o

armazenamento de grandes volumes de dados. Quando falamos de armazenamento de grandes volumes de dados, automaticamente pensamos em *big data*.

Big data e inteligência artificial são interdependentes: *big data* fornece a capacidade de armazenar e tratar grandes volumes de dados necessários para treinar modelos de IA, enquanto a IA permite processar e extrair inteligência e conhecimento desses dados de forma eficiente. Logo, ao pensarmos em infraestrutura de TI para execução de algoritmos de inteligência artificial, precisamos começar pela infraestrutura necessária para armazenamento de grandes volumes de dados.

Modelos de IA, em particular algoritmos de redes neurais profundas, possuem alta demanda de processamento e, para tal, é recomendável a utilização de processadores do tipo dedicado, como por exemplo:

- GPUs (*Graphics Processing Unit*) ou unidades de processamento gráfico: são importantes para o treinamento de modelos complexos.
- TPUs (*Tensor Processing Unit*) ou unidades de processamento tensorial: são processadores específicos para o treinamento de modelos de *deep learning*.
- CPUs de alto desempenho: são utilizadas para tarefas que exigem baixa latência e resposta imediata, como inferência em tempo real, que são algoritmos que fazem previsões de forma instantânea, assim que os dados são recebidos, como por exemplo, modelos de prevenção a fraude em pagamentos *on-line*.

O processamento eficiente de modelos de IA também se cruza com a arquitetura de dispositivos de Internet das Coisas (IoT). Os dispositivos *Edge* desempenham um papel fundamental na inteligência artificial descentralizada, processando informações localmente e respondendo de forma instantânea, sem a necessidade de enviar dados para um serviço centralizado e esperar que ele devolva qual decisão deve ser tomada.



IMPORTANTE

Dispositivos *Edge* são particularmente importantes em casos de uso como carros autônomos, *drones*, câmeras utilizadas no monitoramento de cidades inteligentes, bem como na saúde e na Indústria 4.0.

Ainda sobre capacidade computacional associada ao armazenamento e processamento de dados, faz-se necessário pensar no modelo de infraestrutura para acomodar essas capacidades: computação em nuvem ou *data centers* locais (*on-premises*).

No modelo em nuvem, temos a vantagem da escalabilidade dos recursos e da maioria dos provedores fornecerem infraestrutura específica para IA ofertadas no modelo PaaS, o que acelera muito a implantação da inteligência artificial. A desvantagem fica por conta do custo, que pode ser alto a depender do tipo de algoritmo e da frequência de execução.

Em contrapartida, o modelo de infraestrutura própria (*on-premises*) permite um maior controle, segurança e é mais indicado para empresas que precisam cumprir regulamentações relacionadas a informação, como a LGPD, por exemplo. Como dissemos anteriormente, os custos de aquisição e de manutenção da infraestrutura são detratores deste modelo.



PARA SABER MAIS

A Lei Geral de Proteção de Dados Pessoais (LGPD), ou Lei nº 13.709/2018, regula o tratamento de dados pessoais e tem como objetivo proteger os direitos fundamentais de liberdade, privacidade e personalidade. Ela estabelece que todos os dados tratados, tanto no meio físico quanto no digital, estão sujeitos à regulação (Brasil, 2018).

A crescente demanda na execução de algoritmos de inteligência artificial, somada à grande necessidade de recursos computacionais envolvidos nessa tarefa, elevou o consumo de recursos dos *data centers*.

O alto consumo de energia elétrica decorrente do processamento dos algoritmos e a necessidade de resfriamento das CPUs (que muitas vezes é feito utilizando água) aumentam a demanda por recursos naturais e exigem novas soluções.



IMPORTANTE

Um estudo da Universidade de Massachusetts apresentou dados que levam à conclusão de que o treinamento de apenas um modelo de inteligência artificial pode gerar mais dióxido de carbono (que resulta, entre outras coisas, no aumento do efeito estufa) do que um carro pode gerar em toda sua vida útil (Strubell; Ganesh; McCallum, 2019).

O conceito de *data centers* verdes (*Green Data Centers*) tem como objetivo a adoção de tecnologias ambientalmente sustentáveis voltadas para IA, como o uso de energia de matriz renovável, técnicas de resfriamento eficientes (incluindo a construção de *data centers* em localizações geográficas com temperaturas naturalmente baixas) e reutilização de calor gerado pelas CPUs para o aquecimento de recursos utilizados pelas pessoas, como água e calefação de ambientes.

O aumento na maturidade da utilização de IA descentralizada, a partir da utilização maior de dispositivos *Edge*, também é uma solução encontrada para reduzir os impactos ambientais decorrentes do aumento no consumo dos recursos de infraestrutura resultantes da inteligência artificial e do aprendizado de máquina.

Considerações finais

Neste capítulo, vimos que a evolução da infraestrutura de tecnologia da informação é promovida pelo crescimento das tecnologias emergentes. A abordagem de infraestrutura como código (IaC) trouxe eficiência e padronização, reduzindo o trabalho manual e contribuindo para a segurança na gestão de ambientes computacionais.

Discutimos também que a ascensão do *big data* demonstrou a necessidade de infraestruturas robustas e distribuídas. Com o aumento exponencial do volume e da variedade dos dados gerados, as arquiteturas de armazenamento e processamento precisaram se adaptar para oferecer novos recursos que dessem conta dessa demanda.

O avanço das telecomunicações e das capacidades computacionais fomentaram a introdução de dispositivos que se conectam à internet e geram valor não só no nosso dia a dia, mas também para a indústria, comércio e serviços.

Por fim, vimos que a inteligência artificial e o aprendizado de máquina aumentaram a demanda por capacidade computacional, pressionando os *data centers* e elevando o consumo de recursos naturais. Como solução a este cenário, o desenvolvimento dos *data centers* verdes busca equilibrar desempenho e sustentabilidade a partir do uso de energias renováveis, técnicas avançadas de resfriamento e otimização do consumo de recursos.

Concluimos que o futuro da infraestrutura de TI estará cada vez mais interligado com a automação, a descentralização e a sustentabilidade. O desafio é inovar e garantir que a tecnologia evolua de forma responsável.

Referências

AWS. AWS CloudFormation documentation. **AWS**, 2011. Disponível em: <https://docs.aws.amazon.com/cloudformation/>. Acesso em: 30 abr. 2025.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Dispõe sobre a proteção de dados pessoais e altera a Lei nº 12.965, de 23 de abril de 2014 (Marco Civil da Internet). **Diário Oficial da União**: seção 1, Brasília, DF, 15 ago. 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/L13709.htm. Acesso em: 30 abr. 2025.

DURAES, Wellington; FERREIRA, Fernando Borba; MANZAN, Renato. **Arquitetura de soluções IoT**: desenvolva com internet das coisas para o mundo real. São Paulo: Casa do Código, 2022. *E-book*.

GOOGLE CLOUD. Cloud Deployment Manager. **Google**, 2025. Disponível em: <https://cloud.google.com/deployment-manager>. Acesso em: 30 abr. 2025.

HASHICORP. Terraform. **Hashicorp**, 2022. Disponível em: <https://developer.hashicorp.com/terraform>. Acesso em: 30 abr. 2025.

IBM. O que é o Hadoop Distributed File System (HDFS)? **IBM**, 2024. Disponível em: <https://www.ibm.com/br-pt/topics/hdfs>. Acesso em: 30 abr. 2025.

MICROSOFT. Azure Resource Manager documentation. **Microsoft**, 2016. Disponível em: <https://learn.microsoft.com/en-us/azure/azure-resource-manager/>. Acesso em: 30 abr. 2025.

MORRIS, Kief. **Infrastructure as Code**: Dynamic Systems for the Cloud Age. 2. ed. Sebastopol: O'Reilly Media, 2020.

RED HAT. Red Hat Ansible Automation Platform. **Red Hat**, 2016. Disponível em: <https://www.redhat.com/technologies/management/ansible>. Acesso em: 30 abr. 2025.

SINCLAIR, Bruce. **IoT: como usar a Internet das Coisas para alavancar seus negócios**. São Paulo: Autêntica Business, 2018.

SOUSA NETO, Manoel Veras de. **Gestão da tecnologia da informação**: sustentação e inovação para a transformação digital. Rio de Janeiro: Brasport, 2019.

STRUBELL, Emma; GANESH, Ananya; MCCALLUM, Andrew. Energy and Policy Considerations for Deep Learning in NLP. 2019. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, pages 3645–3650, Florence, Italy, jul. 2019. Disponível em: <https://arxiv.org/abs/1906.02243>. Acesso em: 30 abr. 2025.

SUAVE, André Augusto. **Inteligência artificial**. Rio de Janeiro: Freitas Bastos, 2024.

TIESSI, Ana; FREITAS, Nicksson. **Técnicas para processamento de big data**. São Paulo: Editora Senac São Paulo, 2023. *E-book*.

Sobre o autor

Fabio Rossi Versolatto é graduado em ciências da computação pelo Centro Universitário da Faculdade de Engenharia Industrial (FEI) e pós-graduado em tecnologia de construção de software orientado a objetos pelo Centro Universitário do Serviço Nacional de Aprendizagem Comercial de São Paulo (SENAC) e em inteligência artificial pela Universidade Mackenzie. Possui especialização em arquitetura, componentização e SOA pela Universidade Estadual de Campinas (UNICAMP), além de ser mestre em engenharia de software pelo Instituto de Pesquisas Tecnológicas de São Paulo (IPT). Com mais de vinte anos de experiência na área de desenvolvimento de software, já passou por empresas e consultorias dos mais diversos tamanhos e tipos, de diferentes tecnologias, assumindo papéis de desenvolvedor, analista, engenheiro, líder técnico e arquiteto de soluções, sempre ligado ao universo da engenharia de software e suas ramificações. Desde 2013, atua como professor universitário em cursos de graduação e pós-graduação.

Currículo Lattes: <http://lattes.cnpq.br/1172545849314411>.