

Poliana N. Ferreira

Introdução à **ciência de dados**

INTRODUÇÃO À CIÊNCIA DE DADOS

Dados Internacionais de Catalogação na Publicação (CIP)
(Simone M. P. Vieira – CRB 8º/4771)

Ferreira, Poliana N.

Introdução à ciência de dados / Poliana N. Ferreira. – São Paulo :
Editora Senac São Paulo, 2024. (Série Universitária)

Bibliografia.

e-ISBN 978-85-396-4855-9 (ePub/2024)

e-ISBN 978-85-396-4853-5 (PDF/2024)

1. Ciência de dados 2. Processamento de dados 3. Análise
prescritiva 4. Classificação de dados I. Título. II. Série.

23-2035g

CDD – 004

BISAC COM018000

COM021030

Índice para catálogo sistemático:

1. Ciência de dados 004

INTRODUÇÃO À CIÊNCIA DE DADOS

Poliana N. Ferreira





Administração Regional do Senac no Estado de São Paulo

Presidente do Conselho Regional

Abram Szajman

Diretor do Departamento Regional

Luiz Francisco de A. Salgado

Superintendente Universitário e de Desenvolvimento

Luiz Carlos Dourado

Editora Senac São Paulo

Conselho Editorial

Luiz Francisco de A. Salgado

Luiz Carlos Dourado

Darcio Sayad Maia

Lucila Mara Sbrana Sciotti

Luís Américo Tousi Botelho

Gerente/Publisher

Luís Américo Tousi Botelho

Prospecção

Dolores Crisci Manzano

Administrativo

Verônica Pirani de Oliveira

Comercial

Aldair Novais Pereira

Coordenação de Arte

Antonio Carlos De Angelis

Coordenação de E-books

Rodolfo Santana

Coordenação de Revisão de Texto

Marcelo Nardeli

Acompanhamento Pedagógico

Otacília da Paz Pereira

Designer Educacional

Ágatha Veiga

Revisão Técnica

Débora Richter Brólio

Preparação e Revisão de Texto

Camila Y. K. Assunção

Projeto Gráfico

Alexandre Lemes da Silva

Emília Corrêa Abreu

Capa

Antonio Carlos De Angelis

Editoração Eletrônica e Ilustrações

Sandra Regina Santana

Imagens

Adobe Stock Photos

Proibida a reprodução sem autorização expressa.

Todos os direitos desta edição reservados à

Editora Senac São Paulo

Av. Engenheiro Eusébio Stevaux, 823 – Prédio Editora

Jurubatuba – CEP 04696-000 – São Paulo – SP

Tel. (11) 2187 4450

editora@sp.senac.br

<https://www.editorasenacsp.com.br>

© Editora Senac São Paulo, 2024

Sumário

Capítulo 1

Uma imensidão de dados, 7

- 1 O que é ciência de dados?, 8
 - 2 Carreira em ciência de dados, 12
 - 3 A ciência de dados nas empresas, 16
- Considerações finais, 18
- Referências, 19

Capítulo 2

Ciclo de vida de um projeto em ciência de dados, 23

- 1 Entendendo o problema, 24
 - 2 Coleta de dados, 25
 - 3 Pré-processamento de dados, 29
 - 4 Análise exploratória dos dados (EDA), 35
 - 5 Construção de modelos, 40
 - 6 Resultados: geração de insights e implementação de modelo, 41
- Considerações finais, 42
- Referências, 43

Capítulo 3

Problemas e soluções em ciência de dados, 45

- 1 Como os dados são gerados, armazenados e usados em ciência de dados: datasets abertos e fechados, 47
 - 2 O que torna uma base de dados promissora para análise?, 52
 - 3 Identificando problemas e gerando soluções baseadas em dados: insights, métricas e ferramentas (produtos, serviços, processos), 53
 - 4 Pensamento analítico (perguntas e respostas em ciências de dados), 55
- Considerações finais, 57
- Referências, 58

Capítulo 4

Análise descritiva, 59

- 1 O que é e qual a função da análise descritiva, 60
 - 2 Tipos de pergunta, 61
 - 3 Estatística descritiva, 62
 - 4 Modelos descritivos, 70
 - 5 Resultados da análise descritiva, 75
- Considerações finais, 76
- Referências, 76

Capítulo 5

Análise preditiva, 79

- 1 O que é e qual a função da análise preditiva, 80
 - 2 Tipo de pergunta, 80
 - 3 Aprendizado de máquina preditivo, 81
 - 4 Algoritmos para realizar previsões, 84
 - 5 Predições na prática, 88
 - 6 Resultados da análise preditiva, 92
- Considerações finais, 93
- Referências, 93

Capítulo 6

Análise prescritiva, 95

- 1 O que é e qual a função da análise prescritiva, 96
 - 2 Tipo de pergunta, 96
 - 3 Decisões inteligentes (DI), 97
 - 4 Modelagem e algoritmos para análise prescritiva, 99
 - 5 Resultados da análise prescritiva, 107
 - 6 Case: sistema de recomendação de filmes, 108
- Considerações finais, 111
- Referências, 112

Capítulo 7

Business intelligence e visualização de dados, 113

- 1** O que é business intelligence, 114
 - 2** Ferramentas de BI, 117
 - 3** Storytelling, 119
 - 4** Visualização de dados, 120
 - 5** Hands-on: BI e DataViz na prática, 126
- Considerações finais, 128
- Referências, 129

Capítulo 8

A ética na ciência de dados, 131

- 1** A ética e a privacidade em ciência de dados, 132
 - 2** O mau uso de informações derivadas de dados e metadados, 136
 - 3** LGPD, *compliance*, data protection officer, data governance, 138
 - 4** Cases, 141
- Considerações finais, 144
- Referências, 145

Sobre a autora, 149

Uma imensidão de dados

A quantidade imensa de dados que existem nos meios digitais desafia a percepção dos indivíduos. Enquanto um HD com milhares de fotos pode parecer significativo, ele representa apenas uma gota d'água no oceano digital em que estamos imersos. A cada atividade que realizamos on-line, seja navegar por um site de notícias, interagir em redes sociais ou realizar uma compra em um e-commerce, estamos gerando e alimentando um universo interconectado de dados e informações.

Colocando em perspectiva, o Google, gigante da internet, processava 5,9 milhões de buscas por minuto em 2022, sem considerar os petabytes¹ de dados gerados diariamente por plataformas como YouTube, na qual 500 horas de vídeo são carregadas a cada minuto. Até o final de 2022, redes sociais como o Instagram tinham 2,8 bilhões de fotos compartilhadas por mês, ou 1,4 milhão de TB (Data Never Sleeps 10.0, 2023). Em comparação, um HD de 1 TB parece minúsculo. E não para por aí,

¹ Petabyte (PB) é uma unidade de armazenamento de dados equivalente a 1 milhão de gigabytes (GB) ou mil terabytes (TB).

pois estamos vivendo em uma era na qual a produção e o consumo de dados crescem exponencialmente a cada ano.

Com tanto volume gerado, os dados se tornaram catalisadores de transformação em diversos setores, assumindo um papel central na sociedade digital contemporânea. Dessa forma, é imprescindível entender o que são e como são processados.

Considere os diferentes tipos de dados existentes. Temos os dados estruturados, que são organizados e formatados de maneira específica, como bancos de dados de clientes com nomes, endereços e datas de nascimento. Temos os dados não estruturados, que são menos definidos e podem incluir dados como postagens em redes sociais, textos, áudios, imagens ou vídeos. Mas os tipos de dados não param por aí. Ainda podemos classificá-los como categóricos (nominal e ordinal) ou numéricos (discreto e contínuo) e textual ou multimídia (imagem, áudio, vídeo), por exemplo.

Neste contexto, a capacidade de transformar esses vastos conjuntos de dados em informação e conhecimento tornou-se uma habilidade altamente valorizada no mercado. A ciência de dados surge como consequência desta demanda, uma disciplina que combina estatística, programação e conhecimento de negócios para extrair valor dos dados. Neste primeiro capítulo, vamos explorar o mundo da ciência de dados, destacando onde ela está presente na atualidade e entender porque a profissão de cientista de dados foi considerada a “mais sexy do século XXI” (Davenport; Patil, 2012).

1 O que é ciência de dados?

Os conjuntos de dados passaram a ser tão volumosos que os métodos tradicionais de armazenamento, processamento e análise de dados tornaram-se inadequados para lidar com eles. Assim, surgem o big data e a ciência de dados (Rautenberg; Carmo, 2019). Big data é o nome

atribuído a tais conjuntos de dados, os quais não são apenas volumosos, mas também são produzidos em uma taxa de alta velocidade e de variados tipos (Amaral, 2016; Basso, 2023). Essa área foca em técnicas de armazenamento e processamento.

Já a ciência de dados busca coletar, analisar e extrair valor e significado dos dados. Apesar de ter ganhado destaque pela possibilidade de lidar com dados em escala, ela também pode ser utilizada para small data, ou seja, uma quantidade pequena de dados. Em ambas as formas, a ciência de dados gera valor e insights para os negócios.



IMPORTANTE


A frase “dados são o novo petróleo”, traduzida do inglês “*data is the new oil*”, foi cunhada em 2006 por Clive Humby (Palmer, 2006; Leaders, 2017) e é amplamente utilizada para mostrar o potencial transformador dos dados. A mensagem completa, entretanto, atesta para mais um fator relevante no contexto deste livro: “Os dados são o novo petróleo. São valiosos, mas se não forem refinados, não podem realmente ser usados e aproveitados”. Dessa forma, as técnicas de ciência de dados são necessárias para que esse ativo valioso (dados) atinja o seu potencial.

1.1 A ciência de dados é interdisciplinar

O foco deste livro é mostrar como a ciência de dados é aplicada para transformar os dados em informação e conhecimento. Esta ciência é interdisciplinar, como apresentado no diagrama de Venn, na figura 1 (Conway, 2010). A estatística e a matemática fornecem a base para a análise e a interpretação de dados, permitindo que os cientistas entendam tendências, padrões e variações nos dados. A ciência da computação permite que os cientistas de dados manipulem grandes conjuntos de dados digitais, implementem algoritmos e construam modelos no computador. Já o conhecimento de negócios é crucial para dar

contexto aos dados, formulando as questões corretas e dando significado real aos resultados.

Figura 1 – O diagrama de Venn da ciência de dados



Fonte: adaptado de Conway (2010).



PARA SABER MAIS


A Gartner é uma empresa global de pesquisa e consultoria, líder em insights de TI, tecnologia e indústria. Em 2023, eles divulgaram uma pesquisa sobre as tecnologias e sua adoção no ecossistema de dados e analytics (2023 Technology adoption roadmap..., 2023).

Acesse o link para conhecer a pesquisa: <https://www.gartner.com/en/publications/2023-technology-adoption-roadmap-for-data-and-analytics> (acesso em: 20 nov. 2023).

1.2 O processo da ciência de dados

Uma vez estabelecida a natureza multifacetada da ciência de dados, é indispensável entender como essas diversas disciplinas se ligam em um fluxo de trabalho coeso. O processo da ciência de dados não é apenas uma sequência de etapas, mas um ciclo iterativo² que refina continuamente a análise até que os insights desejados sejam alcançados, tal como ilustra a figura 2.

Figura 2 – O processo da ciência de dados



Fonte: adaptado de O'Neil e Schutt (2013).

² O desenvolvimento iterativo envolve a repetição de etapas ou ciclos para aprimorar constantemente um produto ou solução.

2 Carreira em ciência de dados

O profissional de ciência de dados tem como principais características a tríade analisar, processar e perceber (Machado, 2018). A análise descritiva de dados é um estágio crucial para o entendimento dos dados (Milani, 2020). Além disso, eles constroem modelos para análise preditiva e prescritiva, desenvolvem algoritmos e, mais importante, fazem descobertas que têm implicações reais no mundo real.


A ciência de dados é uma área em crescimento, assim como a necessidade de profissionais qualificados para preencher estes postos. Estima-se que sejam necessários mais de 190 mil cientistas de dados para atender às necessidades do mercado atualmente (Machado, 2018). Ao ser realizada uma busca de vagas no LinkedIn com o termo “cientista de dados” no Brasil, como resultado foram identificadas 4.003 vagas abertas para essa profissão ou áreas correlatas, ratificando sua importância no mercado (LinkedIn, 2023). Neste tópico, veremos as carreiras possíveis em ciência de dados e quais as principais competências necessárias para atuar nesta área.

2.1 Competências em ciência de dados

O’Neil e Schutt (2013) reuniram características para determinar um perfil do profissional de dados. As competências relacionadas foram a de visualização de dados, de aprendizado de máquina, de matemática, de estatística, de computação, de comunicação e de conhecimento de negócios. Apesar do que muitos podem pensar, um cientista de dados não precisa ser especialista em todas essas competências. Não existe um cientista de dados perfeito, por isso precisamos de equipes. Cada profissional terá um nível de proficiência em cada competência, e os níveis juntos configuram a capacidade da equipe para um projeto específico. Assim, é importante analisar as necessidades do projeto a ser desenvolvido, agregando os profissionais que possibilitam a sua realização.

É possível explorar também os requisitos de conhecimentos específicos para as vagas existentes na área. Foram analisadas dez vagas em ciência de dados, no LinkedIn (2023), das seguintes empresas: Cielo, Embraer, Globo, BTG, PicPay, Samsung, XP, CI&T, idwall, Deloitte, e as competências mais relevantes estão apresentadas na figura 3:

Figura 3 – Competências em ciência de dados



Outra característica importante para alguém que está buscando uma vaga em ciência de dados é possuir um bom portfólio demonstrando as competências listadas na figura 3. Assim, as empresas têm conhecimento da forma de trabalho do profissional e sua real proficiência além do que está no currículo. Uma forma de fazer isso é por meio de cases práticos, com a análise de bases de dados disponíveis publicamente. Nesse sentido, existem diversas plataformas que fornecem esses dados, tal como o Kaggle, que te possibilita desenvolver suas próprias aplicações, ver as soluções das outras pessoas e participar de comunidades e de desafios que, inclusive, oferecem prêmios para os participantes.



NA PRÁTICA


O Kaggle (2023) é uma renomada plataforma de ciência de dados que hospeda competições, conjuntos de dados e notebooks colaborativos. É um portal essencial para aprendizado e colaboração em análise de dados e machine learning. Acesse e explore em: <https://www.kaggle.com/>.

2.2 Funções em dados

Há um espectro variado de profissões em dados. Dependendo da organização e da especificidade do problema em questão, pode haver inclusive uma sobreposição de funções ou uma necessidade de uma especialização ainda mais acentuada. Vamos explorar algumas das funções mais comuns e suas atribuições.

Cientista de dados é o papel mais abrangente e está basicamente em todas as etapas do ciclo dos dados. Ele coleta, limpa, analisa e interpreta, transformando dados brutos em valor para a empresa. O *engenheiro de dados*, por outro lado, visa projetar, construir e manter a arquitetura de dados (como bancos de dados, processos de ETL e sistemas de big data), os pipelines e as estruturas de dados. Eles garantem que os dados estejam disponíveis, confiáveis e acessíveis para os outros profissionais. Além desses, mais orientado para a análise do que para o desenvolvimento de modelos avançados, um *analista de dados* examina conjuntos de dados para tirar conclusões práticas. Estas profissões podem ser visualizadas na figura 4, considerando a sua atuação nas etapas do ciclo de vida da ciência de dados.


Figura 4 – Funções em relação ao ciclo de vida da ciência de dados



Fonte: adaptado de Nantasenamat (2020).

Nesse sentido, ainda há muitas outras carreiras em dados, tais como engenheiro de aprendizado de máquina (ML), especialista em inteligência de negócios, especialista em big data, entre outros, como apresentadas na figura 5.

Figura 5 – O espectro emergente de funções em D&A (dados e analytics)



Fonte: adaptado de Kahn (2022).

3 A ciência de dados nas empresas

A pesquisa da Gartner de previsões em dados e analytics estima que 80% das organizações terão múltiplos locais de armazenamento e processamento de dados até o ano de 2026, gerando análises para diversos setores e informações críticas para a empresa (2023 Technology..., 2023).

Para isso, as empresas devem passar por diversas etapas de maturação em seu trabalho com dados. Buytendijk *et al.* (2020) sugerem um plano de trinta meses para essa adaptação. No primeiro mês, indica-se a construção formal do conhecimento do negócio, além da coleta, organização e validação dos dados existentes. Depois, inicia-se a geração de relatórios com boas visualizações de dados e análises descritivas. No 18º mês, inicia-se a base da ciência de dados, com modelos de aprendizado genéricos e projetos pilotos envolvendo análise preditiva. Com a consolidação, no 30º mês teremos modelos em fase de produção, tarefas e profissionais especializados a partir das reais necessidades do negócio.

As tarefas que podem ser propostas no sentido de utilizar dados para gerar valor para o negócio podem ser divididas em três tipos de análises: descritiva, prescritiva e preditiva (Mercante, 2022). O quadro 1 apresenta cada uma dessas análises, demonstrando quais tipos de perguntas devem ser feitas para alcançar bons resultados.

Quadro 1 – Tipos de análise de negócios

	ANÁLISE DE NEGÓCIO		
	DESCRITIVA	PREDITIVA	PRESCRITIVA
Perguntas	O que aconteceu? O que está acontecendo?	O que acontecerá? Por que acontecerá?	O que devo fazer? Por que devo fazer?
Facilitadores	Relatórios empresariais Dashboards Scorecards Data warehouse	Mineração de dados Mineração de web e redes sociais Previsões	Otimização Simulação Modelagem de decisões Sistemas especialistas

(cont.)

	ANÁLISE DE NEGÓCIO		
	DESCRITIVA	PREDITIVA	PRESCRITIVA
Resultados	Problemas e oportunidades empresariais bem definidos	Projeções precisas de eventos futuros e resultados finais	Melhores decisões e ações empresariais possíveis

Fonte: adaptado de Sharda, Delen e Turban (2019).

3.1 Cases reais

Mesmo recente, a ciência de dados já revolucionou as empresas. Alguns exemplos mais famosos são: sistema de recomendação na Netflix, otimização de logística na UPS, detecção de fraudes na American Express e em outros bancos, desenvolvimento de novos produtos com base no interesse dos usuários no Spotify, aplicação de preços dinâmicos no Airbnb, análise dos padrões de compra na Amazon, entre muitos outros exemplos. Isso sem falar das grandes empresas de redes sociais, que lidam diretamente com sistemas de curtidas e anúncios, moldando a forma que as pessoas consomem e interagem com conteúdo. Toda essa inovação é feita com a ciência de dados, a partir dos dados.

3.2 Data for Good

Um futuro cientista de dados, todavia, não deve embotar-se pelo dinheiro ou pelo prestígio de criar a melhor forma de fazer um usuário clicar em um anúncio. Eles devem buscar, também, oportunidades para resolver problemas de valor social e considerar os impactos de seus modelos (O'Neil; Schutt, 2013).

O Data for Good representa um movimento crescente que combina a ciência de dados com o enfrentamento de desafios sociais e humanitários. Os especialistas buscam abordar problemas como propagação de

doenças, desigualdades sociais e assistência em desastres. Além disso, organizações não governamentais sem fins lucrativos (ONGs) estão intensificando seus esforços para que projetos sociais incorporem a análise de dados, enquanto empresas demonstram cidadania corporativa ao disponibilizar recursos para causas sociais. Simultaneamente, hackathons³ sociais surgem como espaços criativos de solução, juntando profissionais com problemas relevantes.

Nesse sentido, há também uma forte ênfase em educação, sensibilização e inclusão, garantindo que a área de ciência de dados seja representativa e acessível. Ética, transparência e responsabilidade são os pilares deste movimento, assegurando que a revolução dos dados não se limite aos interesses comerciais, mas contribua significativamente para o bem-estar e progresso da sociedade como um todo.

Considerações finais

Este capítulo desvenda o intrincado mundo da ciência de dados, sendo uma referência inicial sobre sua relevância, trajetórias profissionais e implementação em ambientes empresariais. No subcapítulo “O que é ciência de dados?”, exploramos a essência dessa disciplina. A ciência de dados não se trata apenas da manipulação de dados, mas da extração de conhecimentos a partir deles. Esta é uma disciplina interdisciplinar que envolve estatística, computação e análise de negócios.

Em “Carreira em ciência de dados”, observamos algumas das diversas trajetórias possíveis dentro deste campo, assim como as competências mais valorizadas em um profissional da área. Finalmente, “A ciência de dados nas empresas” apresenta a indispensabilidade da ciência de dados no mundo empresarial atual. As empresas estão, cada vez mais,

³ Hackathons são eventos intensivos de programação em que indivíduos ou equipes trabalham rapidamente para resolver desafios específicos. Eles geralmente duram entre um dia a uma semana e incentivam a inovação e a colaboração.

percebendo o valor dos dados na otimização de processos, na tomada de decisões estratégicas e na oferta de produtos e serviços mais alinhados às necessidades dos consumidores.

Ao final deste capítulo, é essencial que o leitor reflita sobre a falsa onisciência dos dados em nossa sociedade atual. Quais são as implicações éticas de coletar, analisar e agir com base em tais dados? Os dados e modelos sempre apresentarão informações corretas? Como podemos, como sociedade, garantir que a ciência de dados seja usada para o bem comum? E, para aqueles considerando uma carreira neste campo, quais habilidades e características são fundamentais para prosperar na interseção entre dados, tecnologia e humanidade?

Referências

2023 TECHNOLOGY adoption roadmap for data and analytics. **Gartner**. Stamford, CT, USA, 2023. Disponível em: <https://www.gartner.com/en/publications/2023-technology-adoption-roadmap-for-data-and-analytics>. Acesso em: 12 ago. 2023.

AMARAL, Fernando. **Introdução à ciência de dados**: mineração de dados e big data. Rio de Janeiro: Alta Books, 2016.

BASSO, Douglas Eduardo. **Big data**. Curitiba: Contentus, 2020. *E-book*.

BUYTENDIJK, Frank *et al.* Advanced data and analytics: what do leading organizations do? **Gartner Research**, Stamford, CT, USA, 12 June 2020. Disponível em: <https://www.gartner.com/en/documents/3986252>. Acesso em: 12 ago. 2023.

CONWAY, Drew. The Data Science Venn Diagram. **Drew Conway Data Consulting**. New York, 2010. Disponível em: <http://drewconway.com/the-lab>. Acesso em: 12 ago. 2023.

DATA Never Sleeps 10.0. **Domo**. American Fork, UT, USA, 2023. Disponível em: <https://www.domo.com/data-never-sleeps>. Acesso em: 12 ago. 2023.

DAVENPORT, Thomas H.; PATIL, D. Data scientist: the sexiest job of the 21st century. **Harvard Business Review**, Brighton, MA, USA, Oct. 2012. Disponível em:

<https://hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century>. Acesso em: 12 ago. 2023.

KAGGLE. [Página inicial]. San Francisco, CA, USA, 2023. Disponível em: <https://www.kaggle.com/>. Acesso em: 12 ago. 2023.

KAHN, Zain. Roles and skills to support advanced analytics and AI initiatives. **Gartner Research**, Stamford, CT, USA, 2 Aug. 2022. Disponível em: <https://www.gartner.com/en/doc/00770015-roles-and-skills-to-support-advanced-analytics-and-ai-initiatives>. Acesso em: 12 ago. 2023.

LEADERS. The world's most valuable resource is no longer oil, but data. **The Economist**, London, UK, 6 May 2017. Disponível em: <https://www.economist.com/leaders/2017/05/06/the-worlds-most-valuable-resource-is-no-longer-oil-but-data>. Acesso em: 12 ago. 2023.

LINKEDIN. [Página inicial]. Sunnyvale, CA, EUA, 2023. Disponível em: <https://www.linkedin.com/>. Acesso em: 22 ago. 2023.

MACHADO, Felipe Nery Rodrigues. **Big data**. São Paulo: Saraiva, 2018. *E-book*.

MERCANTE, Tiago Henrique Medeiros. **Análise preditiva**: aplicada para solução de problemas reais. São Paulo: Editora Senac São Paulo, 2022.

MILANI, Alessandra Maciel Paz *et al.* (org.). **Visualização de dados**. Porto Alegre: Sagra, 2020.

NANTASENAMAT, Chanin. The data science process. **Towards Data Science**, Toronto, Canada, 27 July 2020. Disponível em: <https://towardsdatascience.com/the-data-science-process-a19eb7ebc41b>. Acesso em: 22 ago. 2023.

O'NEIL, Cathy; SCHUTT, Rachel. **Doing data science**: straight talk from the frontline. Sebastopol, CA, USA: O'Reilly Media, 2013.

PALMER, Michael. Data is the new oil. **ANA Marketing Maestros**, [s. l.], 3 Nov. 2006. Disponível em: https://ana.blogs.com/maestros/2006/11/data_is_the_new.html. Acesso em: 12 ago. 2023.

RAUTENBERG, Sandro; CARMO, Paulo Ricardo Viviurka do. Big data e ciência de dados: complementariedade conceitual no processo de tomada de decisão. **Brazilian Journal of Information Science**: research trends, v. 13, n. 1, p. 56-67,

mar. 2019. Disponível em: <https://revistas.marilia.unesp.br/index.php/bjis/article/view/8315>. Acesso em: 22 ago. 2023.

SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business intelligence e análise de dados para gestão do negócio**. Tradução: Ronald Saraiva de Menezes. 4. ed. Porto Alegre: Bookman, 2019.

Ciclo de vida de um projeto em ciência de dados

O ciclo de vida de um projeto em ciência de dados é uma sequência de etapas que servem como espinha dorsal para o desenvolvimento e implementação de soluções baseadas em dados (O'Neil; Schutt, 2013). A primeira etapa abrange *entender o problema* e identificar os objetivos do projeto de ciência de dados. Após todos os integrantes da equipe terem clareza de aonde querem chegar, passamos para a *coleta de dados*. Uma vez que os dados relevantes para o problema são coletados, entramos na fase de *pré-processamento*. Esta é uma das etapas mais trabalhosas e envolve limpeza, transformação e integração dos dados coletados. Então, os dados estão finalmente prontos para a *análise exploratória*. Combinando técnicas estatísticas e ferramentas de visualização, podemos descrever os dados. A próxima etapa é a *construção de modelos*, com a aplicação de machine learning para criar um modelo matemático para análises descritiva, preditiva e prescritiva.

Como resultados do ciclo de vida de um projeto em ciência de dados, há duas contribuições significativas que podemos destacar. A primeira é a geração e a comunicação de insights que são meticulosamente direcionados para o aprimoramento dos processos dentro da empresa. A segunda contribuição relevante é a *implementação dos modelos* de dados. Esses modelos vão além do simples diagnóstico da situação atual, oferecendo alternativas que podem ser aplicadas para executar tarefas ou otimizar determinadas funções beneficiando a empresa e o cliente final. Após a implementação do projeto, a etapa final é o feedback e a *medição da eficácia* dos modelos e dos resultados alcançados.

Ao longo deste capítulo, será apresentado um caso prático para ilustrar esse processo. Dominar as etapas e as ferramentas que serão apresentadas é crucial para o sucesso de qualquer projeto em ciência de dados, e este capítulo servirá como seu guia abrangente para navegar por esse ciclo complexo, mas essencial.

1 Entendendo o problema

A eficácia de um projeto em ciência de dados está atrelada à identificação clara e precisa do problema em questão (Amaral, 2016; Sharda; Delen; Turban, 2019). Esse marco inicial abrange não só o entendimento do cenário corporativo, mas também as necessidades dos clientes. Após essa investigação, é possível definir um objetivo central para o projeto, para o qual as estratégias e os recursos podem ser alocados de forma assertiva. Erros nesta fase inicial podem levar a investimentos ineficazes e respostas inadequadas, ratificando a importância deste passo para o sucesso das etapas futuras.

1.1 Introdução ao case

Imagine que você é um cientista de dados contratado por uma editora em busca de maior eficácia no mercado editorial. A empresa tem

como objetivo elevar suas vendas e solidificar sua reputação como uma editora que publica obras de qualidade e relevância. A pergunta estratégica que enfrentam é: “como identificar e publicar títulos ou gêneros que a audiência tenha maior interesse?”. Sua equipe acredita que os dados históricos de avaliação de clientes sobre livros em plataformas na internet podem fornecer as pistas necessárias para entender as preferências dos leitores. Sua tarefa neste capítulo será buscar os dados relevantes para atacar este problema e aplicar análises para encontrar possíveis soluções para responder à questão descrita.

2 Coleta de dados

Os resultados de um projeto de ciência de dados são, essencialmente, um reflexo direto da qualidade e da relevância dos dados iniciais coletados. Se os dados forem incompletos, imprecisos ou tendenciosos, será manifestado nos resultados finais, podendo levar a conclusões errôneas ou a decisões mal orientadas (Basso, 2020; Davenport, 2014). Os dados devem capturar a variabilidade e a complexidade do fenômeno que está sendo estudado (Machado, 2018), permitindo que sejam gerados insights precisos e acionáveis que possam trazer valor real para uma empresa ou um projeto de pesquisa.

Dessa forma, deve ser realizada uma coleta de dados rigorosa e direcionada para o objetivo proposto para garantir o sucesso do projeto. Deve-se pensar em quais tipos de dados podem ser relevantes para o problema, assim como em sua fonte. Inúmeros aspectos devem ser considerados e cada caso é específico.

Por exemplo, se o foco é a manutenção preditiva em um ambiente industrial, sensores colocados em máquinas podem fornecer dados em tempo real sobre temperatura, pressão e eficiência. Em projetos que visam otimizar estratégias de anúncios em redes sociais, os dados podem incluir curtidas, compartilhamentos, comentários, taxas de conversão, além de informações sobre o público-alvo.

No campo da saúde, podem ser coletados para análise registros médicos eletrônicos, resultados de exames laboratoriais e dados de *wearables*¹, como relógios inteligentes. Para projetos relacionados ao transporte público, por exemplo, dados de GPS de ônibus e trens, horários de chegada e partida e dados de fluxo de passageiros podem ajudar a otimizar rotas e horários. Na área financeira, históricos de transações, taxas de juros e dados do mercado de ações podem ser cruciais para prever tendências econômicas ou riscos de crédito.

Na educação, dados sobre desempenho de estudantes em provas, taxas de frequência e envolvimento dos alunos em atividades extracurriculares podem oferecer insights para melhorar a qualidade do ensino e reduzir taxas de evasão. No setor agrícola, informações como condições climáticas, qualidade do solo e dados de colheita podem ser valiosos para aprimorar as práticas agrícolas e aumentar a produção.

2.1 Kaggle e a base de dados do Goodreads

O Kaggle é uma das principais plataformas para cientistas de dados, principalmente por seu vasto repositório de datasets² (Kaggle, 2023). Essas bases de dados, que abrangem diversas áreas e setores, facilitam a inicialização de projetos, permitindo que pesquisadores e profissionais encontrem facilmente conjuntos de dados relevantes para suas necessidades específicas. Muitos datasets no Kaggle vêm com uma descrição detalhada, insights preliminares e até discussões da comunidade, ajudando os usuários a entenderem melhor o contexto e as características dos dados. Em suma, para quem está em busca de dados para análise, modelagem ou pesquisa, o Kaggle se torna uma ferramenta inestimável.

1 Dispositivos vestíveis.

2 Base de dados.

Para contextualizar a fase de coleta de dados, vamos nos aprofundar no caso da editora que deseja otimizar sua seleção de títulos com base nas preferências dos leitores. Para isso, utilizaremos uma base de dados que contém avaliações e feedbacks de leitores, oriundos do Goodreads, um site de recomendação de livros. A base de dados³ está disponível no Kaggle, é de domínio público e foi coletada via API do Goodreads pelo autor da base.

Essa base de dados é um arquivo csv, em que cada linha corresponde a informações de um livro diferente. As colunas são: ID do livro (bookID), título da obra, autores, média das avaliações, ISBN, ISBN-13⁴, idioma, número de páginas, quantidade de avaliações, quantidade de comentários em comentário, data de publicação e editora. Essas colunas são o que chamamos de atributos da base de dados, no qual cada livro tem seus próprios valores específicos para cada coluna.

Para iniciar o projeto, é necessário baixar o arquivo books.csv no Kaggle e importar o documento na ferramenta escolhida. Neste livro, vamos usar Python, Jupyter Notebook e suas diversas bibliotecas como ferramentas centrais.



PARA SABER MAIS

Python é uma das linguagens de programação mais aplicadas em ciência de dados e será utilizada para construir as soluções deste livro. Para saber mais, recomendamos explorar o site oficial e sua documentação antes de prosseguir: <https://www.python.org/> (acesso em: 26 set. 2023).

3 Site: <https://www.kaggle.com/datasets/jealousleopard/goodreadsbooks>.

4 O id do livro representa um código interno da plataforma, já o ISBN e o ISBN-13 são padrões internacionais de identificação de livros.

Para lidar com as bases de dados, utilizaremos a biblioteca *pandas*⁵, que é uma ferramenta de manipulação e análise de dados em Python amplamente utilizada em ciência de dados. Ela oferece estruturas de dados, como *dataframes*, para lidar facilmente com tabelas de dados e realizar operações complexas.

Primeiro, importamos o *pandas*, depois lemos o arquivo *csv* e transformamos a tabela com os dados em um *dataframe* (*df*). É possível exibir as primeiras linhas de um *df* por meio da função *head()*. Também podemos exibir linhas escolhidas aleatoriamente com a função *sample()*. É utilizada a função *info()* para verificar o tipo de dado de cada coluna. O exemplo do código pode ser visto a seguir:

```
import pandas as pd

df = pd.read_csv('books.csv', sep=",", on_bad_lines = "skip")
df.head()
df.sample(5)
df.info()
```

O resultado do *df.info()* pode ser observado na figura 1. Ele mostra que há 11.123 linhas de dados na base e que não há valores nulos em nenhuma linha nem coluna. Além disso, apresenta o tipo de dado de cada uma das colunas: valores inteiros (*int64*), valores decimais (*float64*) e texto (*object*). Observe que a data de publicação está como texto, o que deverá ser tratado depois.

⁵ Disponível no link: <https://pandas.pydata.org/>.

Figura 1 – Informações da base de dados

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 11123 entries, 0 to 11122
Data columns (total 12 columns):
#   Column              Non-Null Count  Dtype
---  -
0   bookID              11123 non-null  int64
1   title               11123 non-null  object
2   authors             11123 non-null  object
3   average_rating      11123 non-null  float64
4   isbn               11123 non-null  object
5   isbn13             11123 non-null  int64
6   language_code       11123 non-null  object
7   num_pages           11123 non-null  int64
8   ratings_count       11123 non-null  int64
9   text_reviews_count  11123 non-null  int64
10  publication_date     11123 non-null  object
11  publisher            11123 non-null  object
dtypes: float64(1), int64(5), object(6)
memory usage: 1.0+ MB
```

Com a base de dados e o entendimento da quantidade de exemplos de livros que temos, assim como de seus atributos, podemos passar para as próximas etapas do ciclo da ciência de dados.

3 Pré-processamento de dados

O pré-processamento de dados é uma etapa crucial em qualquer projeto de ciência de dados, servindo como ponte entre a coleta de dados brutos e a fase de análise (Faceli *et al.*, 2021). Muitas vezes, por ter a característica de ajudar a deixar os dados mais limpos e compreensíveis para a construção de modelos, essa etapa pode ser desenvolvida de forma iterativa com a etapa de análise exploratória. Dessa forma, a exploração indica o que deve ser consertado, enquanto as técnicas de pré-processamento mitigam os problemas identificados, proporcionando uma análise mais correta.

Vamos abordar alguns aspectos-chave dessa fase, começando pela integração de dados. *Integração* envolve a combinação de dados de várias fontes para criar um conjunto de dados unificado e coerente, sendo especialmente relevante quando os dados provêm de bancos de dados distintos ou até mesmo de tipos de dados diferentes.

Depois de integrados, os dados frequentemente contêm atributos que podem não ser relevantes para a análise. Por exemplo, no processo de diagnóstico de uma doença, o nome do paciente e código de identificação não são relevantes para a tarefa. Outra situação é quando um atributo possui um mesmo valor para todos ou quase todos os dados, não sendo uma informação que irá ajudar a distinguir os elementos. Assim, a *eliminação manual desses atributos* ajuda a reduzir a dimensionalidade, tornando as futuras etapas de análise mais eficientes e focadas.

A *amostragem* também é uma técnica usada para simplificar os dados, selecionando subconjuntos representativos para análise em vez de usar o conjunto de dados completo. Utilizamos a amostragem quando a base de dados tem muitos exemplos e gostaríamos de selecionar apenas alguns para as análises. Algumas técnicas de amostragem são: aleatória simples, estratificada e progressiva. No processo de amostragem, também é possível a utilização de um especialista para selecionar os exemplos, a depender do caso proposto.

O *desbalanceamento dos dados* é outro ponto importante. Por exemplo, imagine que estamos construindo um modelo de seleção de currículos. Caso os currículos de exemplo na base de dados sejam predominantemente masculinos, o modelo terá um viés para a seleção de candidatos homens, mesmo que esses não sejam necessariamente os mais qualificados. Ou seja, se uma classe é muito mais prevalente do que outra, pode levar a modelos tendenciosos e incorretos. Métodos como *undersampling* e *oversampling* são comuns para lidar com esse problema.

Por sua vez, a *limpeza dos dados* envolve várias subetapas (Faceli *et al.*, 2021; Grus, 2016). Dados incompletos precisam ser tratados, seja por meio da inserção de valores nos campos faltantes, seja por meio da exclusão de exemplos incompletos. Para a inserção, é possível utilizar medidas de tendência central nos valores conhecidos, preenchendo-as com tal valor, ou também utilizar um indutor para prever o valor do atributo para cada linha que está incompleta. Inconsistências e redundâncias

também devem ser identificadas e corrigidas. A redundância ocorre, por exemplo, quando os atributos são muito semelhantes entre si, fornecendo o mesmo tipo de informação, ou quando há amostras duplicadas. Por fim, também podemos limpar os ruídos, que são valores que não representam a realidade, devendo ser suavizados ou eliminados.

Por último, a *transformação de dados* é realizada para preparar o conjunto de dados para exploração e construção de modelos. Essa transformação pode incluir a *normalização*, que ajusta os valores numéricos em uma escala comum, e a *codificação*, que converte variáveis categóricas em um formato que pode ser colocado à disposição de algoritmos estatístico, gráficos para visualização e algoritmos de aprendizado de máquina (Faceli et al., 2021).

3.1 Na prática: limpeza de dados dos livros

No nosso case da editora, podemos observar a base de dados do Goodreads e realizar o pré-processamento. Observe que cada cientista de dados tem diferentes abordagens sobre essa etapa, sendo importante que você pense nos possíveis problemas que podem ocorrer, e como avaliá-los e corrigi-los.

Você constatou neste exemplo, por meio da exploração básica dos dados com o Python, que não há linhas duplicadas, nem valores duplicados de ISBN. Além disso, não há valores nulos e todos os valores de avaliação média estão entre 0 e 5. Alguns problemas também foram percebidos, os quais devem ser discutidos com a equipe para pensar e implementar a solução:

1. Os atributos ISBN, ISBN-13 e ID do livro não são relevantes para o projeto;
2. O atributo *num_pages* possui espaços;

3. Inconsistência nas linhas de dados que possuem uma avaliação, mas a contagem de avaliações é 0;
4. Inconsistência nas linhas que possuem número de comentários maior que número de avaliações;
5. Linhas que não possuem nenhuma avaliação (não são úteis para o problema);
6. Livros que possuem 0 páginas;
7. As datas não estavam em um formato acessível e algumas datas podiam não existir;
8. Títulos iguais em mais de uma linha de dados;
9. Desbalanceamento de dados considerando a média de avaliação (muito mais valores entre 3 e 5).

O código a seguir mostra como as análises para extrair as informações descritas foram feitas em Python. A função *describe()* descreve os atributos numéricos com medidas estatísticas. A função *duplicated()* apresenta as linhas duplicadas na base; caso o nome de um atributo seja inserido dentro dos parênteses, são verificadas apenas as linhas com valores repetidos daquele atributo. Além disso, é possível criar outras condições para verificar linhas de dados correspondentes, tal como se o valor de um atributo é maior ou igual a um determinado valor.

```
df.isnull().sum() # valores nulos
df.describe() # descrição da base
df[df.duplicated()] # checa linhas duplicadas

df[df.duplicated('isbn')] # checa isbn duplicado
df[df.duplicated('isbn13')] # checa isbn13 duplicado
df[df.duplicated('bookID')] # checa bookID duplicado

df[df.ratings_count < df.text_reviews_count] # dados que
possuem mais comentários do que número de reviews
```

```
df[df.ratings_count == 0].shape # qt. dados que não possuem
reviews

df[df['num_pages'] < 30].shape # qt. dados com número de
páginas menor que 30

df[df.duplicated(["title", "language_code"], keep=False)].
sort_values('title') # dados que têm título e língua
duplicados
```

A partir disso, endereçamos os problemas descritos. Para o problema 1, removemos as colunas de ISBN, ISBN-13 e bookID. Para o 2, renomeamos esse atributo. Para os problemas 3, 4 e 5, optamos por remover as linhas específicas que não possuem nenhuma avaliação ($n = 80$). Para os livros sem nenhuma página, no problema 6, percebemos que a grande maioria se tratava de *audiobooks*. Estendemos essa interpretação para livros com menos de 30, que considerava *audiobooks* e livros infantis, os quais não são foco da editora ($n = 305$). Assim, esses livros também foram removidos. As datas, no problema 7, foram convertidas para o tipo *timestamp* e as linhas de dados com datas que não podiam existir (por exemplo, 31 de novembro) foram removidas ($n = 2$).

O problema 8 foi um pouco mais complicado, pois havia mais de mil livros com títulos repetidos no mesmo idioma. Não poderíamos apenas eliminar os valores repetidos, nem manter apenas uma entrada, em razão do número e do valor das avaliações. Dessa forma, foi pensada uma estratégia de agrupamento. O título e o idioma foram mantidos; a coluna do autor foi concatenada com uma barra ("/"); para a avaliação, foi calculada a média; o valor máximo foi mantido para o número de páginas; e as somas foram calculadas para o número de avaliações e comentários. A data de publicação mais antiga foi mantida na coluna, e a coluna da editora foi concatenada também com uma barra ("/").

Por fim, após discussão entre a equipe, foi decidido que vocês não fariam nada em relação ao desbalanceamento, já que poderiam assumir

valores apenas entre 3 e 5, caso necessário, nas análises futuras, uma vez que isso reflete a realidade das avaliações dos usuários.

O código a seguir apresenta essa etapa de limpeza e tratamento de dados em Python utilizando o pandas. Ao final, teremos 10.211 livros para analisar nas etapas futuras. Você pode realizar outras explorações e aplicar mais métodos de pré-processamento caso seja necessário no decorrer do projeto (por exemplo, ajustar todos os valores do idioma inglês para “eng” ou remover valores que têm “*NOT A BOOK*” como autor).

```
df.drop(['isbn', 'isbn13', 'bookID'], axis=1, inplace=True)

df.rename(columns = {' num_pages': 'num_pages'},
inplace=True)

df.drop(df[(df.ratings_count == 0) | (df['num_pages'] < 30)].
index, inplace=True)
df.reset_index(drop= True, inplace=True)

invalid_dates = []
for idx, date_str in enumerate(df['publication_date']):
    try:
        pd.to_datetime(date_str, format='%m/%d/%Y')
    except ValueError:
        invalid_dates.append((idx, date_str))
df.drop(index=[idx for idx, _ in invalid_dates],
inplace=True)
df['publication_date'] = pd.to_datetime(df['publication_
date'], format='%m/%d/%Y')

aggregated_df = df.groupby(['title', 'language_code']).agg({
    'authors': lambda x: '/'.join(set(x)),
    'average_rating': 'mean',
    'num_pages': 'max',
    'ratings_count': 'sum',
    'text_reviews_count': 'sum',
    'publication_date': 'min',
    'publisher': lambda x: '/'.join(set(x))
}).reset_index()
df = aggregated_df
```

4 Análise exploratória dos dados (EDA)

A análise exploratória dos dados (exploratory data analysis, ou EDA) envolve uma variedade de técnicas para examinar, resumir e visualizar a estrutura dos dados (Grus, 2016). Essa etapa pode ser realizada mediante técnicas de *estatística* e *análise descritiva* para fornecer medidas resumidas e insights sobre o conjunto de dados, as quais incluem o uso de médias, medianas, modas, desvio padrão, variância, percentis e outros indicadores que ajudam a entender distribuição, tendência central e dispersão dos dados (Morettin, 2021).

Também muito utilizadas nesta etapa são as *visualizações de dados* com gráficos e tabelas ilustrativas (Milani, 2020). Gráficos como histogramas, de dispersão e de caixa (*boxplots*) são instrumentos poderosos para entender tanto a distribuição individual das variáveis como as relações entre elas. Mapas de calor oferecem uma visão compacta das correlações entre múltiplas variáveis, enquanto gráficos de barras e gráficos de torta são excelentes para comparar categorias e proporções. Essas visualizações, juntamente com estatísticas descritivas, compõem um conjunto robusto de ferramentas que tornam a EDA uma etapa indispensável no ciclo de análise de dados.

O presente capítulo oferece apenas uma visão geral sobre esses métodos, tendo como ponto de partida o case da editora.

4.1 EDA para o nosso case da editora

A realização de uma análise exploratória pode ser guiada pelo método científico, por meio de perguntas específicas que fazem parte do problema em questão. No case, você e sua equipe de ciência de dados estabeleceram algumas perguntas: “quais os dez livros com mais avaliações e qual a sua média de avaliação?”, “qual a média de avaliação dos autores com mais livros?”, “qual a média de avaliação de livros por autor e por ano?” e “qual a distribuição das avaliações?”.



PARA SABER MAIS

Além dessas perguntas, muitas outras podem ser respondidas. No Kaggle, é possível explorar os códigos feitos por outras pessoas para essa mesma base de dados, de modo que muitos deles tratam da análise exploratória: <https://www.kaggle.com/datasets/jealousleopard/goodreadsbooks/code?datasetId=231310> (acesso em: 26 set. 2023).


Na primeira pergunta, você pode realizar uma ordenação das linhas de dados considerando o número de avaliações e exibir a lista. Para ilustrar melhor, é possível criar um gráfico de barras com a quantidade de avaliações no eixo x e o título no eixo y.

```
import matplotlib.pyplot as plt
import seaborn as sns

most Rated = df.sort_values('ratings_count', ascending =
False).head(10).set_index('title')
sns.barplot(x=most Rated['ratings_count'], y=most Rated.
index)

most Rated.describe()
```

Gráfico 1 – Número de avaliações por livro



Observa-se que *Crepúsculo* tem o maior número de avaliações, com mais de 4,5 milhões, seguido por *Hobbit* e vários livros da série Harry Potter. Tal resultado mostra que esses livros foram muito lidos e são populares, mas não significa, necessariamente, que as pessoas gostaram. Para isso, é necessário olhar a média da avaliação, da qual *Crepúsculo* é de apenas 3,59. Entre os dez livros com mais avaliações, a média foi de 4,19. Ainda nesse sentido, os cientistas de dados buscaram saber quantas avaliações tinham os livros com *rating* maior que 4,9 e observaram que, no máximo, foram onze avaliações que mantiveram esse valor alto. Já acima de 4,8, um dos livros teve 32 mil avaliações, enquanto os demais estavam também abaixo de onze.

```
df[df.average_rating > 4.8].sort_values('ratings_count',
ascending = False).head(10)
```

Para a pergunta “qual a média de avaliação dos autores com mais livros?”, em primeiro lugar é necessário agrupar os livros por autor e realizar a contagem dos livros, ordenando os autores. Depois, deve-se fazer o cálculo da média para os livros de cada um e exibi-los em uma tabela. Como resultado, foi possível observar que a média das avaliações dos autores com mais livros varia entre 3,7 e 4,2, sendo o Stephen King o autor com mais livros.

```
# df com autores como uma lista
df2 = df.copy()
df2['authors'] = df2['authors'].apply(lambda x: set(x.
split('/')))
df2 = df2.explode('authors')

# Agrupe por 'authors' para contar o número de livros e
calcular a média de avaliação
author_book_count = df2.groupby('authors').size().
reset_index(name='num_books')
author_rating_mean = df2.groupby('authors')['average_
rating'].mean().reset_index()


# Junte as duas informações em um único DataFrame
pd.merge(author_book_count, author_rating_mean,
on='authors').sort_values('num_books', ascending=False)
```

Tabela 1 – Média da avaliação dos autores com mais livros

AUTHORS	NUM_BOOKS	AVERAGE_RATING
Stephen King	79	4,006025
William Shakespeare	53	3,960000
Sandra Brown	47	3,723191
J. R. R. Tolkien	44	4,200455
Mercedes Lackey	43	3,985116

A pergunta “qual a média de avaliação de livros por autor e por ano?” pode ser respondida por meio de um gráfico para cada autor. Vamos ilustrar o gráfico para o autor com mais livros, Stephen King. Inicialmente, separamos os livros nos quais ele é um dos autores. Depois, criamos um *barplot*, que já extrai a média e coloca no gráfico de barras, como demonstrado no gráfico 2.

Gráfico 2 – Média das avaliações por ano: Stephen King




```
plt.figure(figsize=(15,5))
plt.grid()

author_df = df[df.authors.str.contains('Stephen King',
case=False, na=False)]
sns.barplot(x=author_df.publication_date.dt.year,
y=author_df.average_rating)
```

A distribuição das avaliações também pode ser observada por intermédio de um gráfico, tal como o *violinplot*. Neste gráfico, a largura do “violino” indica a densidade dos dados em diferentes valores de média de avaliação. No gráfico 3, observa-se que a maioria dos livros estão avaliados na faixa de 4, de modo que os valores abaixo de 3 são considerados *menos comuns*.

Gráfico 3 – Gráfico de violino da distribuição das avaliações



```
sns.violinplot(df.average_rating)
```



PARA SABER MAIS

No GitHub da autora (Ferreira, 2023), é possível ter acesso ao Jupyter Notebook em Python com maior aprofundamento do projeto da editora: <https://github.com/pnferreira/> (acesso em: 26 set. 2023).

5 Construção de modelos

O aprendizado de máquina (machine learning, ou ML) é uma subárea da inteligência artificial que se concentra no desenvolvimento de algoritmos e modelos estatísticos que permitem que os computadores executem tarefas sem serem explicitamente programados (Faceli *et al.*, 2021; Grus, 2016). Estes algoritmos aprendem de dados ou experiências anteriores e fazem previsões ou decisões baseadas neles.

O ML pode ser categorizado como aprendizado supervisionado, aprendizado não supervisionado ou aprendizado por reforço, cada um com seus próprios algoritmos e aplicações. No aprendizado supervisionado, os algoritmos são treinados em um conjunto de dados rotulados para realizar tarefas como classificação e regressão. Modelos como máquinas de vetores de suporte (SVM), árvores de decisão e redes neurais são comumente usados para classificar dados em diferentes categorias. Para tarefas de regressão, que envolvem a previsão de valores contínuos, métodos como regressão linear e árvores de regressão são frequentemente empregados. Por outro lado, o aprendizado não supervisionado não requer um conjunto de dados rotulados e é mais focado na detecção de padrões nos dados. Ele geralmente é usado em tarefas de agrupamento e associação, com modelos como k-means e análise de componentes principais (PCA).

As análises empregadas na ciência de dados utilizam o ML para a extração de insights e a construção de modelos. A análise descritiva se beneficia do aprendizado não supervisionado, pois procura entender a estrutura e os padrões subjacentes nos dados. A análise preditiva, por sua vez, tende a empregar modelos supervisionados para fazer previsões futuras baseadas em dados passados (Mercante, 2022). A análise prescritiva combina elementos de ambos, usando modelos preditivos para simular diferentes cenários para então sugerir ações específicas.

No case da editora, uma possibilidade seria a criação de um modelo para prever a avaliação por meio dos demais atributos dados. Outra possibilidade seria a criação de um sistema de identificação e recomendação de livros similares mediante técnicas de agrupamento, por exemplo. Os capítulos 4, 5 e 6 irão adentrar mais nesses temas.

6 Resultados: geração de insights e implementação de modelo

Na etapa “resultados: geração de insights e implementação de modelo” do ciclo de vida em ciência de dados, o principal objetivo é utilizar as análises e modelos desenvolvidos para extrair informações significativas e responder à pergunta estratégica. Para isso, o cientista de dados deve construir relatórios compreensíveis que serão analisados e utilizados, por exemplo, pelos executivos da empresa para tomarem decisões. O feedback dessas pessoas guiará a continuidade do projeto. Ainda, a implementação do modelo é outro aspecto crucial. Depois de desenvolvido e validado, o modelo finalizado é colocado em produção para fazer previsões ou categorizações de forma contínua, conforme o caso.

No case da editora, podemos usar as análises para responder à pergunta “como identificar e publicar títulos ou gêneros que a audiência tenha maior interesse?”. Por meio da análise exploratória, percebemos que os títulos com mais avaliações são aqueles do gênero infantojuvenil de fantasia. Já para os autores com mais livros avaliados na plataforma, não foi possível identificar uma tendência, com livros de suspense, drama, ficção e fantasia. Também foi percebido que os autores tendem a manter uma média de avaliação similar de seus livros com o passar dos anos, o que pode contribuir para a escolha da editora de publicar ou não algum autor. Por fim, foi visto na análise exploratória que a maior parte das avaliações está concentrada em torno de 4, não necessariamente representando uma falta de engajamento da audiência.

Em relação a um modelo para auxiliar no processo de publicação de títulos mais atraentes para a audiência, é possível utilizar a previsão da avaliação para prospectar quais livros têm tendência a fazer mais sucesso. Também é possível usar o modelo de similaridade e recomendação para observar os livros parecidos com aquele que estão pensando em publicar e ver como eles se saíram com a audiência.

Esses resultados devem ser enviados em forma de relatório compreensível para os executivos analisarem e tomarem as decisões apropriadas em cada situação. Em caso de haver também um modelo de análise prescritiva, devem ser geradas recomendações de quais decisões tomar e estas também podem ser enviadas no relatório.

Considerações finais

Ao longo deste capítulo, exploramos o ciclo de vida de um projeto em ciência de dados, desde a compreensão inicial do problema até a implementação do modelo e geração de insights. Cada etapa deste ciclo é fundamental para o sucesso de qualquer projeto de análise de dados, e a ausência ou falha em qualquer uma dessas fases pode comprometer a integridade e a utilidade dos resultados finais. A etapa inicial de entender o problema fornece a direção e o foco para todas as fases subsequentes, desde a coleta e o pré-processamento dos dados até a construção e avaliação do modelo.

Nas fases de análise exploratória dos dados (EDA) e construção do modelo, a qualidade e a preparação dos dados são rigorosamente avaliadas para garantir que os modelos gerados sejam tanto precisos quanto aplicáveis ao problema em questão. Finalmente, a fase de resultados não é apenas o culminar desses esforços, mas também um ponto crítico para avaliar a eficácia do modelo em um contexto prático e entender como os insights podem ser aplicados para atingir os objetivos inicialmente propostos. Assim, o ciclo de vida de um projeto em ciência de

dados é um processo iterativo e interconectado, em que cada etapa constrói sobre a anterior para gerar insights acionáveis e soluções eficazes.

Vimos também o exemplo prático do case da editora de livros que intenciona publicar livros que tenham maior engajamento com a audiência no geral. Há diversas outras análises que podem ser feitas apoiadas nesta base de dados, assim como um aprofundamento da resposta para a pergunta proposta. Além disso, é importante reconhecer que a ciência de dados é uma disciplina em constante evolução, e as melhores práticas e técnicas estão sendo continuamente atualizadas. Portanto, é essencial manter um compromisso frequente com o aprendizado e a atualização para garantir que as abordagens e métodos usados sejam os mais eficazes e relevantes possíveis.

Referências

AMARAL, Fernando. **Introdução à ciência de dados**: mineração de dados e big data. Rio de Janeiro: Alta Books, 2016.

BASSO, Douglas Eduardo. **Big data**. Curitiba: Contentus, 2020. *E-book*.

DAVENPORT, Thomas H. **Big data no trabalho**: derrubando mitos e descobrindo oportunidades. Tradução: Cristina Yamagami. Rio de Janeiro: Elsevier, 2014.

FACELI, Katti *et al.* **Inteligência artificial**: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2021.

FERREIRA, Poliana N. [Página inicial do perfil]. **GitHub**. San Francisco, CA, USA, 2023. GitHub: @pnferreira. Disponível em: <https://github.com/pnferreira/>. Acesso em: 12 ago. 2023.

GRUS, Joel. **Data science do zero**. Tradução: Welington Nascimento. Rio de Janeiro: Alta Books, 2016. *E-book*.

KAGGLE. [Página inicial]. San Francisco, CA, USA, 2023. Disponível em: <https://www.kaggle.com/>. Acesso em: 12 ago. 2023.

MACHADO, Felipe Nery Rodrigues. **Big data**. São Paulo: Saraiva, 2018. *E-book*.

MERCANTE, Tiago Henrique Medeiros. **Análise preditiva**: aplicada para solução de problemas reais. São Paulo: Editora Senac São Paulo, 2022.

MILANI, Alessandra Maciel Paz *et al.* (org.). **Visualização de dados**. Porto Alegre: Sagah, 2020.

MORETTIN, Pedro A.; SINGER, Julio M. **Estatística e ciência de dados**. Versão preliminar. São Paulo: Instituto de Matemática e Estatística da USP, 2021.

O'NEIL, Cathy; SCHUTT, Rachel. **Doing data science**: straight talk from the frontline. Sebastopol, CA, USA: O'Reilly Media, 2013.

PANDAS. [Página inicial]. San Francisco, CA, USA, 2023. Disponível em: <https://pandas.pydata.org/>. Acesso em: 12 ago. 2023.

SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business intelligence e análise de dados para gestão do negócio**. Tradução: Ronald Saraiva de Menezes. 4. ed. Porto Alegre: Bookman, 2019.

SOUMIK. Goodreads-books: comprehensive list of books listed in Goodreads. **Kaggle**. San Francisco, CA, USA, 2019. Disponível em: <https://www.kaggle.com/datasets/jealousleopard/goodreadsbooks>. Acesso em: 12 ago. 2023.

Problemas e soluções em ciência de dados

A questão central deste capítulo é entender de que forma a ciência de dados se aplica na resolução de problemas concretos no mundo real. Para abordar essa questão de maneira abrangente, faremos uma viagem desde a fase inicial de geração e armazenamento de dados até os momentos finais de análise e implementação de soluções eficazes nos negócios. Este percurso nos permite visualizar como os dados brutos são transformados em insights valiosos e, por fim, em ações estratégicas que impactam positivamente diversas áreas de atuação (O'Neil; Schutt, 2013).

Contrariando a percepção de que a ciência de dados é uma área confinada a laboratórios de pesquisa ou a profissionais altamente especializados, queremos destacar seu caráter eminentemente prático. A ciência de dados, armada com uma variedade de métodos analíticos e algoritmos, é uma ferramenta poderosa que pode ser aplicada em contextos tão diversos quanto logística, saúde pública ou marketing (Amaral, 2016; Mercante, 2022). Por exemplo, técnicas avançadas de otimização podem ser utilizadas para aprimorar rotas de entrega, minimizando custos e tempo de transporte. Da mesma forma, a análise de grandes volumes de dados médicos pode revelar padrões e tendências em saúde pública que seriam impossíveis de detectar apenas por meio de métodos tradicionais. E ainda, a análise de sentimentos, alimentada por dados de redes sociais e feedback de clientes, pode oferecer informações cruciais para o desenvolvimento e melhoria de produtos e serviços.

Este capítulo ampliará significativamente sua perspectiva sobre as potencialidades da ciência de dados. Exploraremos exemplos práticos e casos de sucesso, e discutiremos critérios importantes para avaliar a relevância e a utilidade de diferentes conjuntos de dados. A ideia é que você possa compreender como identificar os tipos de dados mais adequados para responder perguntas específicas e resolver problemas complexos.

Além disso, queremos mostrar como os insights derivados dessas análises não são meros pontos de interesse acadêmico; eles são, frequentemente, o primeiro passo para a tomada de ações efetivas e impactantes. Como você verá, a tradução desses insights em medidas concretas é uma arte em si, exigindo habilidade técnica e compreensão profunda do contexto em que os dados serão aplicados.


Prepare-se, então, para uma jornada enriquecedora através das diversas aplicações práticas da ciência de dados. Este capítulo é um convite para explorar como essa disciplina cada vez mais está moldando nossa compreensão e interação com o mundo dinâmico e multifacetado em que vivemos. Seja na otimização de sistemas complexos, na detecção de

problemas de saúde em estágios iniciais ou na compreensão do comportamento do consumidor, a ciência de dados se estabelece como uma ferramenta indispensável para navegar com sucesso na era da informação.

1 Como os dados são gerados, armazenados e usados em ciência de dados: datasets abertos e fechados

Os dados usados em um projeto podem ter diferentes proveniências, estruturas e disponibilidade (Grus, 2016). Eles podem ser datasets abertos, que são conjuntos de dados disponíveis publicamente, geralmente divulgados por organizações governamentais, instituições de pesquisa ou empresas. Mas também podem ser datasets fechados, ou seja, dados proprietários, frequentemente detidos por empresas e que contêm informações sensíveis ou comerciais. Muitas vezes, utilizamos os dois tipos de dados em um projeto, mediante técnicas de integração.

Figura 1 – Base de dados abertas e fechadas



Fonte: adaptado de Nelson (2015).

Neste tópico, examinaremos os aspectos técnicos que envolvem a geração, o armazenamento e a utilização de dados no geral. Utilizaremos três casos práticos para ilustrar essas diferenças e mostrar como elas influenciam na resolução de problemas reais.

1.1 Geração dos dados

A geração de dados é uma etapa crucial em qualquer projeto de ciência de dados, e compreender as diversas formas como os dados podem ser gerados pode ter um impacto significativo nos resultados da análise. Por exemplo, a coleta direta de dados é uma abordagem proativa que envolve reunir informações diretamente dos participantes por meio de questionários, pesquisas e entrevistas. Esta técnica é frequentemente utilizada em campos como psicologia, marketing e ciências sociais.


Além disso, os sensores em dispositivos conectados, como smartphones e outros aparelhos de Internet das Coisas (IoT), são fontes inesgotáveis de dados em tempo real. Esses dados são úteis para monitorar condições que podem mudar dinamicamente, como condições ambientais ou métricas de saúde. Bancos e outras instituições financeiras também geram uma enorme quantidade de dados baseados nos registros de transações, que são fundamentais para análises financeiras e detecção de fraudes. O rastreamento da atividade on-line oferece outro conjunto rico de dados. Websites e aplicativos coletam informações sobre o comportamento do usuário, como páginas visitadas, tempo gasto em cada página e cliques, para entender melhor as preferências e tendências do público. Plataformas de *streaming* e redes sociais complementam esse quadro, fornecendo insights sobre o consumo de mídia e as interações sociais.

Além da fonte de dados, é importante considerar a forma como os dados são coletados, seja em lotes ou em tempo real. A coleta em lotes é feita em intervalos programados e é adequada para dados que não

requerem análise imediata. Em contraste, os dados em tempo real são continuamente coletados e analisados, o que é essencial para aplicações que necessitam de respostas rápidas, como monitoramento de tráfego e sistemas de recomendação em tempo real.

Por último, a estrutura dos dados também é um fator crítico. Os dados podem ser estruturados ou não estruturados. Dados estruturados encaixam-se bem em tabelas e são facilmente armazenados em bancos de dados SQL, enquanto dados não estruturados, como textos e imagens, exigem métodos de tratamento e modelagem mais complexos.

Figura 2 – Geração de dados



1.2 Armazenamento dos dados

O armazenamento dos dados é importante para a eficiência dos sistemas e para a segurança. Como exemplo, bancos de dados relacionais como MySQL e PostgreSQL são frequentemente escolhidos para dados estruturados em razão de sua eficiência e facilidade de manipulação. No entanto, para dados mais complexos ou não estruturados, bancos de dados NoSQL como MongoDB oferecem a flexibilidade necessária. Data lakes e opções de armazenamento em nuvem como AWS e Google Cloud proporcionam escalabilidade e são especialmente úteis para empresas que lidam com grandes volumes de dados em formatos variados, ou seja, em aplicações de big data (Basso, 2020).

Outra consideração importante é a velocidade de acesso aos dados. Enquanto sistemas de armazenamento em cache como Redis são usados para dados que requerem recuperação rápida e frequente, soluções de data warehousing como Snowflake e BigQuery são otimizadas para consultas de dados complexas e oferecem um desempenho excepcionalmente rápido para operações de leitura. A escolha entre esses métodos muitas vezes depende das necessidades específicas do projeto, como a frequência de consultas e o tipo de análises a serem realizadas.

Por último, mas não menos importante, a segurança e a conformidade regulatória são aspectos críticos para o armazenamento de dados. É imperativo que os dados sejam armazenados de forma segura, com criptografia robusta e controles de acesso rigorosos, para proteger contra violações de dados. Além disso, o armazenamento de dados deve estar em conformidade com regulamentações locais e internacionais, como o Regulamento Geral de Proteção de Dados (GDPR) na Europa ou a Lei Geral de Proteção de Dados Pessoais (LGPD) no Brasil, especialmente quando se trata de dados pessoais.



PARA SABER MAIS

Para saber mais sobre a Lei Geral de Proteção de Dados (LGPD) e como ela afeta o tratamento de dados pessoais no Brasil, visite o site do Serviço Federal de Processamento de Dados (Serpro), disponível em: <https://www.serpro.gov.br/lgpd/> (acesso em: 20 nov. 2023). O site oferece informações detalhadas e recursos úteis sobre conformidade e melhores práticas. Acesse, também, a lei na íntegra em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm (acesso em: 20 nov. 2023).

1.3 Utilização dos dados

O monitoramento da qualidade do ar nas cidades é frequentemente realizado por meio de sensores urbanos, e os dados coletados geralmente são disponibilizados ao público. Esse é um exemplo clássico do uso de dados abertos para beneficiar a sociedade. Com essa informação, é possível identificar áreas com altos níveis de poluição e reconhecer os períodos do dia em que a qualidade do ar se deteriora. Esse tipo de dado é valioso tanto para o planejamento urbano quanto para fornecer alertas aos residentes, que podem tomar medidas para reduzir a exposição a poluentes.

Por outro lado, no mundo do comércio eletrônico, grandes varejistas on-line coletam uma variedade de dados, como cliques, histórico de compras e padrões de navegação. Esses dados são altamente sensíveis e se enquadram na categoria de dados fechados, usados internamente para refinar algoritmos de recomendação e otimizar as vendas. O acesso a essas informações geralmente é restrito em virtude de sua natureza sensível e de seu potencial de vantagem competitiva.

Um caso interessante que combina ambos os tipos de dados, abertos e fechados, é a previsão de doenças epidêmicas. Dados de saúde pública, que são frequentemente abertos e acessíveis, podem ser

combinados com informações mais sensíveis de hospitais e clínicas, que são dados fechados. A combinação dessas fontes de dados pode resultar em modelos preditivos mais precisos, que são cruciais para o planejamento e resposta durante surtos de doenças. Este caso ilustra como a integração de diferentes tipos de dados pode melhorar significativamente a precisão e a eficácia das soluções baseadas em dados.

2 O que torna uma base de dados promissora para análise?

Para avaliar o potencial de um conjunto de dados para análise em um projeto de ciência de dados, é crucial considerar diversos fatores técnicos e métricas específicas. Em relação à qualidade dos dados, a precisão é um aspecto primordial que pode ser avaliada por meio de auditorias de amostra de dados para identificar a proporção de registros livres de erros. A integridade dos dados, outro aspecto crítico, pode ser verificada ao observar a completude dos registros e ao identificar campos faltantes ou nulos. Também é de grande importância considerar a atualidade dos dados, observando a data da última atualização e a frequência com que essas atualizações ocorrem. A consistência nos formatos e escalas usados em diferentes variáveis também deve ser avaliada para assegurar a qualidade do conjunto de dados.

Quanto às dimensões do big data, o volume deve ser suficiente para garantir a viabilidade estatística da análise, algo que pode ser confirmado com o auxílio de métodos estatísticos rigorosos. A variedade de tipos de dados, que pode incluir dados numéricos, categóricos e textuais, deve ser inventariada e avaliada para garantir que ela seja adequada para resolver o problema em questão. A velocidade de ingestão de novos dados e a latência para análises em tempo real também são critérios que não podem ser ignorados.

Além desses aspectos, a relevância dos dados em relação ao problema específico deve ser avaliada por meio de testes estatísticos, como os coeficientes de correlação de Pearson ou de Spearman e outros testes de hipótese. A disponibilidade de metadados suficientes e documentação contextual também é crucial para a avaliação da utilidade dos dados.

Finalmente, temos o aspecto da acessibilidade dos dados, que pode ser medida pela existência de APIs e *endpoints* programáticos, além da conformidade com as regulamentações de governo e da empresa. Em suma, uma avaliação técnica robusta que considere todas essas métricas e critérios será instrumental para determinar a utilidade e a viabilidade de um conjunto de dados para análise em projetos de ciência de dados.

Figura 3 – Aspectos que tornam uma base de dados promissora para análise




3 Identificando problemas e gerando soluções baseadas em dados: insights, métricas e ferramentas (produtos, serviços, processos)

Neste subcapítulo, vamos focar na aplicação direta da ciência de dados na identificação de problemas e na geração de soluções baseadas em dados. Esta é uma etapa crítica em que o valor real da ciência de dados se manifesta, transformando dados brutos em ações práticas

que solucionam problemas reais (Sharda, Delen; Turban, 2019). Esse processo é feito com base em insights, métricas e ferramentas, como no exemplo da figura 4.

Figura 4 – Case com insight, métrica e ferramenta para solução



O primeiro passo nesse processo é o desenvolvimento de insights, ou seja, entendimentos significativos extraídos dos dados e que fornecem uma visão clara dos problemas subjacentes. Por exemplo, uma análise exploratória de dados pode revelar que as taxas de abandono de um site de e-commerce aumentam drasticamente após às 18h. Este é um insight que pode ser avaliado e investigado mais a fundo para gerar uma solução, como ajustes na infraestrutura do servidor para lidar com picos de tráfego ou ofertas especiais que incentivam compras após esse horário.

A parte crítica após a geração de insights é a seleção de métricas adequadas para avaliar as soluções implementadas. As métricas devem ser quantificáveis e diretamente relacionadas ao problema que está sendo abordado. No mundo dos negócios e finanças, por exemplo, o retorno sobre investimento (ROI) ajuda a medir o ganho em relação ao dinheiro investido, enquanto o custo de aquisição de cliente (CAC) e o lifetime value (LTV) fornecem insights sobre eficácia e valor a longo prazo das estratégias de aquisição e retenção de clientes.

Na área da saúde, métricas como taxa de mortalidade e taxa de readmissão hospitalar são imprescindíveis para avaliar a qualidade dos cuidados médicos. A taxa de eficiência do tratamento, que pode levar em consideração variáveis como a duração da estadia hospitalar e a taxa de recuperação do paciente, também é uma métrica importante. Em

engenharia de software, o tempo de resposta do sistema, o número de *bugs* por linha de código e a utilização de recursos fornecem medidas valiosas para a otimização e o aprimoramento contínuo do software. No marketing digital, por sua vez, a taxa de cliques (CTR) e a taxa de conversão são métricas fundamentais que ajudam a entender o engajamento e a eficácia das campanhas, enquanto a taxa de abertura de e-mail pode indicar o sucesso de estratégias de e-mail marketing. No varejo, a taxa de abandono de carrinho é um indicador crucial da eficácia da experiência de compra on-line, e métricas como venda por visita oferecem percepções importantes sobre o desempenho.

Finalmente, a etapa de implementação envolve o uso de várias ferramentas e tecnologias para transformar insights e métricas em ações concretas, podendo envolver desde o ajuste de algoritmos em produtos de software até a reconfiguração de processos empresariais ou a introdução de novos serviços. No contexto da ciência de dados, ferramentas como algoritmos de aprendizado de máquina, painéis de BI (business intelligence) e sistemas de automação são comumente utilizados.

A eficácia desta abordagem é continuamente avaliada por meio das métricas escolhidas, fechando o ciclo de identificação de problemas e geração de soluções. O resultado é uma abordagem dinâmica e centrada em dados para resolver problemas, melhorar o desempenho e criar valor em diversos setores e aplicações.

4 Pensamento analítico (perguntas e respostas em ciências de dados)

O pensamento analítico em ciência de dados envolve a habilidade de questionar, interpretar e comunicar informações de maneira eficaz. Por intermédio dele, as métricas encontram a tomada de decisão e a teoria se traduz em ação. A seguir, serão detalhados alguns casos práticos para ilustrar como o pensamento analítico é aplicado no mundo real.

Observe que em cada um desses casos o pensamento analítico não foi apenas um exercício acadêmico, mas uma ferramenta crucial para resolver problemas complexos e gerar valor real para as organizações. As perguntas estruturadas deram forma à análise, e as métricas escolhidas ajudaram a converter os insights em ações efetivas. É esse o núcleo do pensamento analítico em ciência de dados: questionar de forma incisiva, analisar rigorosamente e agir decisivamente.

4.1 **Case 1: otimização de *supply chain***

Uma grande empresa de manufatura procurou usar a análise de dados para otimizar sua cadeia de suprimentos. As perguntas iniciais incluíam: “como podemos reduzir os custos sem comprometer a qualidade?” e “como podemos prever melhor as demandas de mercado?”. Utilizando técnicas de aprendizado de máquina para analisar dados históricos de fornecedores, padrões de consumo e fluxo de materiais, a empresa foi capaz de identificar gargalos e implementar um sistema de recomendação para aquisições futuras. Métricas-chave como tempo de ciclo, custo por unidade e taxa de defeitos foram rigorosamente acompanhadas.

4.2 **Case 2: análise de sentimento em *reviews***

Uma start-up focada em um aplicativo móvel de estilo de vida utilizou técnicas de processamento de linguagem natural (NLP) para analisar os comentários dos usuários na App Store e no Google Play. Perguntas como “o que os usuários mais e menos gostam em nosso aplicativo?” e “quais funcionalidades deveríamos priorizar?” direcionaram a análise. Utilizando algoritmos de aprendizado de máquina, a empresa categorizou os comentários em termos de sentimentos e tópicos, permitindo que ajustes fossem feitos no *roadmap* do produto com base em métricas como satisfação do cliente e taxas de engajamento.

4.3 Case 3: prevenção de fraudes em transações financeiras

Um grande banco estava enfrentando problemas crescentes de fraude em transações on-line. Questões do tipo “como podemos detectar atividades suspeitas de maneira eficiente?” e “como podemos minimizar falsos positivos?” foram formuladas. Utilizando técnicas de aprendizado de máquina e de detecção de anomalias, o banco conseguiu criar um sistema de pontuação de risco em tempo real. Métricas como taxa de detecção, taxa de falsos positivos e tempo de resposta foram definidas e monitoradas para avaliar o desempenho do sistema.

Considerações finais

Neste capítulo mergulhamos na jornada dos dados, desde a geração e armazenamento de dados até a tradução em insights acionáveis e soluções inovadoras para problemas do mundo real. Ficou evidente que, embora a ciência de dados possa parecer um território dominado apenas por algoritmos complexos e grandes volumes de dados, seu verdadeiro poder reside na capacidade de fornecer soluções tangíveis que impactam diretamente a sociedade, os negócios e a vida cotidiana. Além disso, conhecemos as nuances entre datasets abertos e fechados, a importância de avaliar a utilidade e a qualidade dos dados, e as diversas métricas que podem ser empregadas para medir o sucesso e a eficácia das iniciativas de análise de dados.

Na medida em que encerramos este capítulo, é imperativo reconhecer que o sucesso de projeto em ciência de dados depende de uma compreensão clara dos problemas, da escolha adequada de ferramentas e técnicas, e da capacidade de interpretar resultados de forma crítica e contextual. Assim sendo, com as abordagens certas, ela tem o potencial de revolucionar setores de forma inovadora e criar soluções impactantes para perguntas e desafios persistentes.

Referências

AMARAL, Fernando. **Introdução à ciência de dados**: mineração de dados e big data. Rio de Janeiro: Alta Books, 2016.

BASSO, Douglas Eduardo. **Big data**. Curitiba: Contentus, 2020. *E-book*.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). **Diário Oficial da União**, Brasília, DF, 15 ago. 2018, Seção 1, nº 157, p. 59. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm.htm. Acesso em: 12 set. 2023.

GRUS, Joel. **Data science do zero**. Tradução: Wellington Nascimento. Rio de Janeiro: Alta Books, 2016. *E-book*.

MERCANTE, Tiago Henrique Medeiros. **Análise preditiva**: aplicada para solução de problemas reais. São Paulo: Editora Senac São Paulo, 2022.

NELSON, Gregory S. Practical implications of sharing data: a primer on data privacy, anonymization, and de-identification. In: **Conference SAS Global Users Group**. Cary, NC: SAS Institute, 2015.

O'NEIL, Cathy; SCHUTT, Rachel. **Doing data science**: straight talk from the frontline. Sebastopol, CA, USA: O'Reilly Media, 2013.

SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business intelligence e análise de dados para gestão do negócio**. Tradução: Ronald Saraiva de Menezes. 4. ed. Porto Alegre: Bookman, 2019.

Análise descritiva

No universo da ciência de dados, a análise descritiva é essencial para aqueles que buscam transformar números brutos em insights significativos. Ela oferece respostas a questões como “o que aconteceu?” e “o que está acontecendo?”. Este campo se difere de métodos inferenciais ou preditivos pelo seu foco em resumir e organizar um conjunto de dados. Com essa clareza, empresas e indivíduos estão mais aptos a tomar decisões informadas e estratégicas, navegando pelo complexo mundo dos dados com confiança e precisão.

A análise descritiva é uma abordagem multifacetada, podendo ser considerada tanto numa perspectiva da estatística clássica quanto em técnicas de aprendizado de máquina. Na estatística, o foco principal é quantificar características básicas dos dados por meio de métricas matemáticas. Em contraste, no campo do aprendizado de máquina, a análise descritiva é frequentemente incorporada em uma variedade de algoritmos para revelar estruturas ou padrões subjacentes nos dados que não são aparentes à primeira vista, tal como técnicas de agrupamento.

Ambos os domínios, embora distintos em suas abordagens e objetivos, compartilham o propósito de buscar compreender a estrutura intrínseca dos dados. Este capítulo explora essa dualidade, apresentando como a análise descritiva é aplicada tanto na estatística quanto no aprendizado de máquina. A discussão irá evidenciar a utilidade desta análise na orientação de decisões informadas e na extração de informações valiosas de conjuntos de dados complexos.

1 O que é e qual a função da análise descritiva

De forma teórica, e como visto na introdução, a análise descritiva refere-se ao conjunto de técnicas empregadas para caracterizar e sumarizar os principais aspectos de um conjunto de dados (Sharda; Delen; Turban, 2019). Ela funciona como uma lente, permitindo aos cientistas de dados examinarem melhor os dados e identificar padrões subjacentes. Perceba que é complicado descrever e ter um entendimento geral quando se trata de uma quantidade volumosa de dados (Basso, 2020), ainda mais quando nos referimos a atributos numéricos. Dessa forma, a análise descritiva ajuda nesse sentido.

A análise descritiva é o primeiro passo no universo da análise de dados, servindo como um radar, capturando o panorama dos dados, suas nuances e padrões. Em vez de prever tendências futuras ou de determinar as

causas subjacentes a certos fenômenos, esta análise foca em descrever os dados em seu estado atual, utilizando métricas, agrupamentos e representações gráficas.

2 Tipos de pergunta

Em sua essência, a análise descritiva busca responder às perguntas “o que aconteceu?” ou “o que está acontecendo?”, sem adentrar no território das inferências ou previsões. Tais perguntas auxiliam a ilustrar o panorama dos dados e a descrevê-los (Sharda; Delen; Turban, 2019). Ilustraremos esse item com exemplos concretos, por meio de perguntas que podem ser respondidas utilizando a análise descritiva.

Imagine um hospital que coletou dados sobre a duração da estadia dos pacientes. A primeira indagação poderia ser: “qual a duração média da estadia dos pacientes em nosso hospital?”. Essa é uma pergunta que busca identificar um ponto central para representar o conjunto de dados; ainda assim, uma média por si só pode não oferecer uma visão completa do que está sendo investigado. O hospital pode querer saber, por exemplo, a variação nas durações das estadias, ou se houve pacientes que permaneceram por um tempo excepcionalmente longo ou curto, ou ainda se existe alguma época do ano em que as estadias são mais longas. Esses questionamentos investigam a dispersão, os outliers e as tendências sazonais nos dados.

Agora, considere uma empresa de comércio eletrônico tentando entender o comportamento de compra de seus clientes. A empresa pode perguntar: “quais produtos são comprados com mais frequência juntos?”. Isso ajuda a identificar grupos e padrões de compra e a criar estratégias, como promoções em conjunto.

Outro cenário possível pode ser uma empresa automobilística que questiona: “existe uma correlação entre a idade do carro e a frequência de visitas à oficina?”. Essa pergunta visa identificar se os modelos mais

antigos de carros tendem a precisar de mais manutenção do que os mais novos, permitindo à empresa ajustar suas estratégias de garantia ou até mesmo de pesquisa e desenvolvimento.

3 Estatística descritiva

A estatística descritiva é, em muitos aspectos, a espinha dorsal do campo estatístico, fornecendo o contexto e a estrutura necessários para compreender e interpretar dados brutos (Morettin; Singer, 2021; Grus, 2016). Ela concentra-se em resumir, organizar e simplificar dados de uma maneira que permita uma fácil interpretação e compreensão. Embora outros ramos da estatística possam se concentrar em fazer inferências ou previsões baseadas em dados, a estatística descritiva é a primeira etapa crucial que nos ajuda a entender a *forma* e a *estrutura* dos dados que estamos analisando.

3.1 Medidas de tendência central

As medidas de tendência central são estatísticas que buscam resumir um conjunto de dados com um único valor que representa o “centro” desse conjunto. Essas medidas são essenciais para fornecer uma rápida compreensão dos dados disponíveis e são frequentemente o primeiro passo em qualquer análise estatística. As mais comuns são a média, a mediana e a moda.

Cada uma delas tem suas próprias vantagens e limitações, e a escolha de qual medida usar pode depender de vários fatores, incluindo a presença de outliers nos dados. Mas antes de nos aprofundarmos nas medidas de tendência central, é importante entender o que são outliers.



IMPORTANTE

Outliers são valores que são significativamente diferentes dos outros valores em um conjunto de dados. Eles podem ser excepcionalmente altos ou baixos e têm o potencial de distorcer a representação geral dos dados. Por exemplo, se você está calculando a média salarial de uma empresa em que quase todos ganham entre 50 e 60 mil dólares por ano, mas o CEO ganha 2 milhões, o salário do CEO é um outlier.

A média é talvez a medida de tendência central mais conhecida e utilizada. Ela é calculada somando todos os valores de um conjunto de dados e dividindo a soma pelo número total de valores. A média é sensível a outliers, o que significa que valores extremamente altos ou baixos podem distorcer a média.

$$\text{Média} = \frac{\text{Soma de todos os valores}}{\text{Número total de valores}}$$

Por outro lado, a mediana é menos afetada por outliers, tornando-a uma escolha mais robusta quando esses valores extremos estão presentes. Para encontrar a mediana, você ordena os valores do conjunto de dados e identifica o valor do meio. Se houver um número ímpar de observações, a mediana é o valor do meio. Se houver um número par de observações, a mediana é a média dos dois valores do meio.

Já a moda é simplesmente o valor que aparece com mais frequência em um conjunto de dados. Diferentemente da média e da mediana, a moda pode ser usada com dados que são categóricos em vez de numéricos. Além disso, a moda não é afetada por outliers.

Como exemplo da diferença entre as três, consideremos o seguinte conjunto de idades dos alunos de uma turma:

Idades = 20, 22, 22, 24, 24, 25, 27, 27, 27, 30, 55.

A fórmula da média pode ser aplicada somando todas as idades:

$$\text{Soma} = 20 + 22 + 22 + 24 + 24 + 25 + 27 + 27 + 27 + 30 + 55 = 303$$

E dividindo o resultado pelo total de elementos, que no caso do exemplo é 11:

$$\text{Média} = \frac{303}{11} = 27,5$$

A mediana, por sua vez, é o valor do meio, ou seja, o sexto elemento da lista quando ela está ordenada, sendo:

$$\text{Mediana} = 25$$

Por fim, a moda é o valor que mais se repete, ou seja, no nosso exemplo, o 27, que aparece três vezes:

$$\text{Moda} = 27$$

Se seus dados são distribuídos de maneira aproximadamente simétrica e você não tem valores extremamente altos ou baixos, conhecidos como outliers, a média pode ser a melhor opção, pois leva em consideração todos os valores no conjunto de dados. No entanto, se há outliers que você suspeita que possam distorcer a representação geral do conjunto de dados, a mediana é geralmente uma escolha mais consistente, pois ela é menos suscetível a esses valores extremos. A mediana é particularmente útil em situações em que os dados são assimétricos ou quando estamos interessados em uma medida que resista às influências de valores extremos. Por sua vez, a moda pode ser mais apropriada para dados que são categóricos em vez de numéricos, ou quando você deseja identificar o valor mais comum em um conjunto de dados.

3.2 Medidas de dispersão

Depois de entender a média ou a mediana de um conjunto de números, que são formas de identificar o “centro” dos dados, o próximo passo é entender quão espalhados esses números estão em relação a esse centro. Isso é o que chamamos de dispersão. Compreender a dispersão é como olhar para uma caixa de chocolates e querer saber se todos os sabores são parecidos ou se temos uma grande mistura.

Para isso, temos algumas ferramentas úteis como a variância e o desvio padrão. A variância é uma forma de calcular quão distantes os números estão da média. Quanto maior a variância, mais espalhados estão os números. O desvio padrão é a raiz quadrada da variância e é útil porque está na mesma “linguagem” que os números originais. Então, se estamos medindo altura em centímetros, o desvio padrão também estará em centímetros, tornando mais fácil entender sua representação.

A amplitude é outra forma simples de entender a dispersão. É basicamente a diferença entre o maior e o menor número do conjunto de dados. Por exemplo, se a menor temperatura registrada foi de 10 graus e a maior foi de 30 graus, a amplitude é de 20 graus. Mas cuidado, a amplitude pode ser enganosa se você tiver outliers.

Também temos o intervalo interquartil (IQR), que é uma medida que nos diz sobre a dispersão dos números que se localizam mais ao meio do conjunto, ignorando os 25% menores e os 25% maiores. O IQR é útil porque não é tão afetado por esses outliers ou números extremos.

Entender a dispersão é crucial porque, sem ela, a média ou a mediana podem dar uma visão distorcida da realidade. Imagine que duas escolas tenham a mesma média de notas. Na primeira, todos os alunos têm desempenhos próximos à média, enquanto na segunda há muitas notas baixas e altas, variando muito. Se você olhar apenas para a média, pensaria que as duas escolas são iguais, mas ao considerar a dispersão, fica

claro que elas são bem diferentes. Portanto, sempre que estiver analisando um conjunto de números, lembre-se de que entender a dispersão é tão importante quanto conhecer a média ou a mediana.

3.3 Correlação

Além de conhecer o centro e a dispersão dos seus dados, é frequentemente útil entender como duas ou mais variáveis interagem ou se relacionam entre si. Esse é o domínio do conceito de correlação. Em termos simples, a correlação nos ajuda a identificar se uma variável muda em conjunto com outra e quão forte é essa relação. O coeficiente de correlação é uma métrica que varia entre -1 e 1 e serve como um termômetro dessa relação. Um valor próximo de 1 sugere uma relação positiva forte, ou seja, quando uma variável aumenta, a outra também tende a aumentar. Um valor próximo de -1 indica uma relação negativa forte, significando que quando uma variável aumenta, a outra tende a diminuir. Um valor próximo de zero indica uma falta de relação linear entre as variáveis.

Embora o tipo mais conhecido de correlação seja a correlação de Pearson, que mede relações lineares, existem outras, como a correlação de Spearman e a de Kendall, que são usadas quando a relação entre as variáveis não é linear. Mas o coeficiente por si só não nos diz tudo. É crucial visualizar também os dados, muitas vezes recorrendo a um gráfico de dispersão, para realmente entender o contexto dessa correlação.

Vale lembrar que correlação não significa causalidade. Mesmo se duas variáveis estão fortemente correlacionadas, isso não significa que uma causa a mudança na outra. Esse entendimento é especialmente importante em campos como medicina e ciências sociais, nas quais a relação entre variáveis pode ser influenciada por fatores não medidos.

A aplicação prática da correlação é vasta. Nos negócios, por exemplo, pode ser usada para avaliar se níveis mais altos de satisfação do cliente estão de fato ligados a um aumento nas vendas. Em medicina,

poderia ser usada para investigar se certos sintomas se correlacionam com a presença de uma doença específica.

3.4 Case: Relatório Mundial da Felicidade

O conjunto de dados que vamos explorar neste subcapítulo fornece uma avaliação abrangente da felicidade em vários países e regiões, com base em dados coletados em 2019. Esses dados foram compilados de uma pesquisa feita em 155 países pela Rede de Soluções para o Desenvolvimento Sustentável das Nações Unidas (SDSN), com base na Gallup World Poll (Sustainable Development Solutions Network, 2019), gerando o Relatório Mundial da Felicidade. A nossa fonte para os dados é o Kaggle (Kaggle, 2023).

O relatório classifica os países usando um *score* de felicidade, que é calculado com base em várias métricas. No conjunto de dados (Sustainable Development Solutions Network, 2019), esse *score* é representado na coluna “Score”; um *score* mais alto indica maior felicidade. O ranking geral desses *scores* é mostrado na coluna “Overall rank”; um ranking mais baixo, como 1, indica um país mais feliz. O conjunto de dados também considera várias outras métricas que contribuem para esse *score*. Por exemplo, o PIB *per capita*, representado na coluna “GDP per capita”, é usado como um indicador de prosperidade econômica. A coluna “Social support” tenta medir o nível de apoio social disponível para os indivíduos, enquanto a “Healthy life expectancy” dá uma ideia da expectativa de vida saudável no país. Além dessas métricas de saúde e economia, o conjunto de dados também inclui indicadores mais subjetivos. A coluna “Freedom to make life choices” avalia o grau de liberdade que as pessoas têm para fazer suas escolhas de vida. A “Generosity” tenta quantificar o nível de generosidade entre os cidadãos.

O objetivo geral deste conjunto de dados é fornecer uma visão holística do bem-estar humano em todo o mundo. Ele é valioso tanto para

pesquisadores acadêmicos quanto para formuladores de políticas e organizações que buscam entender melhor os fatores que contribuem para a felicidade e o bem-estar.

Ao combinar indicadores econômicos, sociais e de saúde, o conjunto oferece dados para comparar a qualidade de vida em diferentes países e identificar áreas para melhoria, as quais devem ser descritas para gerar interpretações e informações. Essa descrição pode ser feita com medidas de estatística e Python.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv('2019.csv', sep=",", on_bad_lines = "skip")

mean_score = df['Score'].mean()
median_gdp = df['GDP per capita'].median()
mode_social_support = df['Social support'].mode()[0]

std_dev_score = df['Score'].std()
variance_healthy_life = df['Healthy life expectancy'].var()

amplitude_freedom = df['Freedom to make life choices'].max() - df['Freedom to make life choices'].min()

iqr_generosity = df['Generosity'].quantile(0.75) - df['Generosity'].quantile(0.25)

corrmap = df.corr(method="spearman", numeric_only=True)
sns.heatmap(corrmap, annot=True)
```

A média da pontuação de felicidade é de aproximadamente 5,41. Este valor é crucial porque serve como um nível de referência para entender a felicidade global. Países com pontuações significativamente maiores que 5,41 podem ser considerados relativamente felizes, enquanto aqueles com pontuações menores podem estar enfrentando desafios em aspectos que contribuem para a felicidade. A média também é útil para

comparações longitudinais; se a média global aumentar ou diminuir com o passar dos anos, isso pode indicar mudanças globais no bem-estar.


A mediana do PIB *per capita* é de 0,96, o que significa que metade dos países têm um PIB *per capita* abaixo deste valor e a outra metade acima. Em um contexto global, ela serve como um ponto de divisão para categorizar países em termos de riqueza econômica. Se um país tem um PIB *per capita* significativamente menor que 0,96, pode ser um indicativo de problemas econômicos que podem afetar negativamente a qualidade de vida.

O desvio padrão de 1,11 na pontuação de felicidade nos diz sobre a dispersão dos dados em torno da média. Esse valor alto sugere uma variação mais significativa nas pontuações entre os países, o que pode indicar desigualdades na qualidade de vida ou bem-estar entre diferentes nações. A variância de 0,059 na expectativa de vida saudável, por outro lado, sugere que os valores estão relativamente próximos da média, indicando menor dispersão dessa métrica entre os países.

A correlação, por sua vez, está representada no gráfico 1 por meio de um gráfico do tipo mapa de calor (Milani, 2020). Vamos analisar com mais detalhes as correlações entre o *score* de felicidade e as demais variáveis.

Entre o *score* de felicidade e o PIB *per capita* a correlação é de 0,794, destacando que nações mais prósperas tendem a ter cidadãos mais felizes. A forte correlação de 0,777 com o apoio social sublinha a importância das redes de suporte na felicidade geral. Saúde, medida pela expectativa de vida saudável, também está intimamente ligada à felicidade, com uma correlação de 0,780. A liberdade para fazer escolhas de vida tem uma associação positiva moderada (0,567), enquanto a generosidade mostra uma relação mais fraca (0,076). Notavelmente, a percepção reduzida de corrupção, com uma correlação de 0,386, indica que a transparência e a integridade podem contribuir para o bem-estar dos cidadãos.

Gráfico 1 – Mapa de calor da correlação entre as variáveis da base de dados de felicidade mundial



4 Modelos descritivos

Modelos descritivos têm como objetivo capturar, representar e explicar a estrutura dos dados em vez de prever ou classificar novas observações. Em muitos campos, desde a psicologia à economia e à biologia, esses modelos ajudam a entender as relações entre as variáveis e a natureza do conjunto de dados em análise, funcionando como uma espécie de mapa que descreve o terreno, mas que não necessariamente nos diz para aonde ir em seguida.

No campo do aprendizado de máquina, algoritmos de agrupamento são frequentemente usados para modelagem descritiva. Eles dividem o conjunto de dados em grupos ou *clusters* que compartilham características semelhantes. Por exemplo, um algoritmo de agrupamento poderia analisar um conjunto de artigos de notícias e dividi-los em tópicos com base na similaridade do conteúdo. O modelo descreve, mas não faz previsões ou inferências.

Além disso, outro exemplo de modelo descritivo são as regras de associação, que são frequentemente usadas no varejo para entender padrões de compra. Esses modelos podem revelar, por exemplo, que clientes que compram churrasqueiras também tendem a comprar carvão e utensílios para churrasco, fornecendo insights de vendas cruzadas.


4.1 Algoritmo k-means

O algoritmo k-means é uma forma popular de agrupar itens similares em diferentes grupos ou *clusters* (Faceli *et al.*, 2021). Imagine que você tenha vários pontos espalhados em um gráfico e quer organizá-los de modo que os pontos de cada grupo fiquem próximos uns dos outros. O k-means faz exatamente isso, de forma automatizada e eficiente.

Vamos usar uma analogia para tornar essa explicação mais fácil de entender. Imagine que você tenha uma cesta de frutas contendo maçãs, bananas e uvas, e você quer separá-las em grupos distintos. Você poderia fazer isso com os olhos fechados, sentindo a forma e o tamanho das frutas. O k-means faz algo similar, só que com dados em vez de frutas e utilizando distâncias entre os pontos de dados para agrupá-los.

Observe o gráfico 2 para entender esse exemplo. O gráfico é composto de frutas diversas, das quais não sabemos a classificação, representadas pela sua largura e altura. O algoritmo k-means vai perceber que existem grupos mais similares e colocar uma cor específica para cada uma no gráfico. Como sabemos que temos três tipos, bananas, maçãs e uvas, é possível caracterizar que o grupo amarelo são as bananas (finas e alongadas), que o vermelho são as maçãs (com altura e largura similares e grandes) e que o grupo verde são as uvas (pequenas e com altura e largura similares).

Gráfico 2 – K-means e o agrupamento de frutas pela altura × largura



O k em k-means representa o número de grupos que você quer criar. No nosso exemplo da cesta de frutas, k seria 3, correspondendo aos grupos de maçãs, bananas e uvas. O k-means é uma ferramenta poderosa para organizar dados, mas é importante notar que você precisa escolher o número de grupos (k) com cuidado, e que nem sempre é óbvio o número correto de grupos a serem usados. No entanto, uma vez que os grupos são formados, eles podem fornecer insights valiosos em muitas áreas diferentes.

Seu funcionamento básico pode ser descrito em três passos. Para começar, ele seleciona aleatoriamente centros para cada um dos k grupos. Podemos interpretar esses centros como os representantes ideais para cada grupo. Em segundo lugar, o algoritmo analisa cada item (ou ponto de dados) e os coloca no grupo cujo centro está mais próximo. Em terceiro lugar, ele recalcula o centro de cada grupo com base nos itens que agora estão dentro do grupo. O algoritmo repete os passos dois e três várias vezes até que os centros não mudem muito, indicando que os grupos foram estabelecidos.

4.2 Case: agrupamento de perfis de clientes

A base de dados de clientes de um shopping, disponível no Kaggle (Choudhary, 2018), contém informações sobre diferentes aspectos desses clientes. Ela inclui cinco colunas, sendo: um identificador único para cada cliente, servindo como chave primária na base de dados; o gênero do cliente, que pode ser masculino ou feminino; a idade do cliente, que pode ser útil para segmentação etária e para entender quais grupos etários frequentam o shopping; a renda anual do cliente, em milhares de dólares, que pode ser crucial para entender o poder de compra deles; e um *score* numérico entre 1 e 100 que representa o comportamento de gastos do cliente.

Assim, podemos criar grupos a partir desses dados, direcionando diferentes estratégias de marketing, por exemplo. Aplicamos o k-means usando o Python e a biblioteca scikit-learn e geramos um gráfico do tipo *pairplot* para analisar os *clusters*, relacionando-os com as variáveis.

```
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd

df = pd.read_csv('Mall_Customers.csv')


# Selecionar as variáveis para a clusterização
df = df.drop(['CustomerID', 'Gender'], axis=1)

# Executar o algoritmo K-means
kmeans = KMeans(n_clusters=5, random_state=42)
kmeans.fit(df)

# Adicionar os rótulos dos clusters ao DataFrame original
df['Cluster'] = kmeans.labels_

sns.pairplot(df, hue="Cluster", palette="Dark2")
plt.show()
```

Ao aplicar um algoritmo de agrupamento como o k-means, os centros dos *clusters* são calculados e os pontos de dados são atribuídos ao *cluster* mais próximo baseados em alguma métrica de distância (geralmente a distância euclidiana). Os gráficos *pairplots* podem ajudar a visualizar como esses *clusters* são formados nas várias combinações de dimensões de recursos. Como resultado, observamos pelo gráfico 3 que o grupo 0 representa as pessoas com menor salário anual e menor *score* de compra. O grupo 1 é o mais bem definido, composto de pessoas com *score* médio (em torno de 50) e salário anual variando entre 40 e 70 mil dólares. O grupo 2, por sua vez, representa as pessoas mais novas, entre 20 e 40 anos, e com *score* alto. O grupo 3 corresponde às pessoas de alto salário e baixo *score*. E o grupo 4, às pessoas de alto *score* e baixo salário.



5 Resultados da análise descritiva

Os resultados de uma análise descritiva consistem principalmente em um melhor entendimento dos dados, extraindo informações como tendências centrais, dispersão, outliers, correlações e padrões de grupos nos dados. De forma prática, a capacidade da análise descritiva de revelar insights poderosos a partir de dados brutos é amplamente evidenciada por diversos casos reais em diversos setores.

Considere, por exemplo, o setor de varejo. Uma grande rede de supermercados percebeu, ao analisar suas transações mediante análise descritiva, que a venda de fraldas e cervejas tinha um padrão interessante nas noites de sexta-feira. O padrão mostrou que homens entre 30 e 40 anos, quando compravam fraldas, também tendiam a comprar cerveja. Fundamentada nesta descoberta, a loja rearranjou seus produtos para otimizar as compras cruzadas, colocando promoções de cervejas próximas à seção de fraldas.

Outro exemplo notável vem do setor de saúde. Hospitais identificaram, ao analisar a entrada e a saída de pacientes mediante análises descritivas, que certas épocas do ano apresentavam maior ocorrência de doenças respiratórias. Esta descoberta levou a uma melhor gestão de recursos durante esses períodos, com a alocação adequada de leitos, medicamentos e equipe.

Em um terceiro caso, uma cidade analisou os dados de tráfego e descobriu que certos cruzamentos tinham uma incidência significativamente mais alta de acidentes durante as horas de chuva. Por intermédio da análise descritiva foi possível identificar os pontos problemáticos, levando a cidade a implementar medidas preventivas, como sinalização mais adequada e drenagem melhorada.

Estes exemplos demonstram que a análise descritiva, em sua essência, desempenha um papel crucial na identificação de padrões e tendências

que, quando devidamente interpretados e aplicados, podem levar a intervenções estratégicas e melhorias significativas em diversos campos de atuação.

Considerações finais

Neste capítulo, exploramos o vasto domínio da análise descritiva, abordando sua importância e as aplicações em diferentes campos. Embora as técnicas e os métodos variem, a meta permanece constante: fornecer compreensão clara e interpretação inicial dos dados coletados. Seja no uso de medidas estatísticas simples ou algoritmos mais sofisticados, o valor intrínseco está na geração de insights que auxiliam na tomada de decisões informadas.

Ao abordar diferentes técnicas, como medidas de tendência central e algoritmo k-means, vemos que há várias ferramentas disponíveis para fazer essa análise inicial. Além disso, cada técnica tem seus próprios méritos e limitações, tornando crucial a escolha da abordagem mais adequada para cada cenário.

A análise descritiva não é um fim em si mesma, mas um ponto de partida basilar para abordagens mais complexas em ciência de dados. Em sua essência, ela fornece um quadro que ajuda a posicionar ou reorientar questões de pesquisa ou problemas de negócios, sendo especialmente valiosa em um mundo em que os dados estão em abundância, mas o tempo e os recursos para interpretá-los são limitados.

Referências

BASSO, Douglas Eduardo. **Big data**. Curitiba: Contentus, 2020. *E-book*.

CHOUDHARY, Vijay. Mall customer segmentation data. **Kaggle**. San Francisco, CA, USA, 2018. Disponível em: <https://www.kaggle.com/datasets/vjchoudhary7/customer-segmentation-tutorial-in-python>. Acesso em: 28 ago. 2023.

FACELI, Katti *et al.* **Inteligência artificial**: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2021.

GRUS, Joel. **Data science do zero**. Tradução: Welington Nascimento. Rio de Janeiro: Alta Books, 2016. *E-book*.

KAGGLE. [Página inicial]. San Francisco, CA, USA, 2023. Disponível em: <https://www.kaggle.com/>. Acesso em: 12 ago. 2023.

MILANI, Alessandra Maciel Paz *et al.* (org.). **Visualização de dados**. Porto Alegre: Sagah, 2020.

MORETTIN, Pedro A.; SINGER, Julio M. **Estatística e ciência de dados**. Versão preliminar. São Paulo: Instituto de Matemática e Estatística da USP, 2021.

SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business intelligence e análise de dados para gestão do negócio**. Tradução: Ronald Saraiva de Menezes. 4. ed. Porto Alegre: Bookman, 2019.

SUSTAINABLE Development Solutions Network (SDSN). World Happiness Report. **Kaggle**. San Francisco, CA, USA, 2019. Disponível em: <https://www.kaggle.com/datasets/unsdsn/world-happiness>. Acesso em: 28 ago. 2023.

Análise preditiva

A análise preditiva surge como uma ferramenta poderosa em uma era em que as decisões baseadas em dados se tornam cruciais para o sucesso empresarial. Mais do que um simples olhar retrospectivo, essa forma avançada de análise de dados tenta responder a duas questões fundamentais: “o que acontecerá?” e “por que acontecerá?”. Ao fazer isso, a análise preditiva não apenas prediz o futuro, mas também fornece uma compreensão dos fatores que influenciam essas previsões. Essa dupla capacidade de antecipar eventos e entender suas causas subjacentes torna a análise preditiva uma ferramenta estratégica indispensável para as organizações.

Além disso, técnicas como mineração de dados e mineração de web e redes sociais estão enriquecendo o arsenal de ferramentas utilizadas em análise preditiva. Dessa forma, olhando para estes dados é possível utilizar técnicas de análise preditiva no contexto do negócio, como detecção de fraudes, avaliação de preços de mercado e previsão de necessidade de manutenção de equipamentos. Quando pensando diretamente no cliente, também é possível a construção de soluções para uma melhor experiência, tais como reconhecimento facial em fotos no celular ou classificador de spam em um e-mail.

Desta forma, a análise preditiva está entre os tipos de técnicas mais conhecidas e utilizadas da ciência de dados, por isso a importância em conhecer melhor seus algoritmos e ferramentas para aplicá-la. Assim sendo, trabalharemos este conteúdo no decorrer deste capítulo.

1 O que é e qual a função da análise preditiva

O conceito da análise preditiva refere-se ao uso de dados, técnicas estatísticas e algoritmos de aprendizado de máquina para prever a probabilidade de resultados futuros com base em dados históricos (Mercante, 2022). Ao contrário de abordagens de análise que se concentram no que já aconteceu, a análise preditiva busca antecipar eventos e tendências futuras, permitindo que empresas e organizações tomem decisões estratégicas informadas, antecipando cenários e ajustando suas ações de acordo com as demandas.

2 Tipo de pergunta

As perguntas moldadas por essa abordagem frequentemente visam antecipar o que pode acontecer, permitindo que organizações e indivíduos se preparem e tomem decisões informadas, envolvendo questões

do tipo “o que acontecerá?” e “por que acontecerá?”, considerando cada contexto de negócio específico (Sharda; Delen; Turban, 2019).

No setor de energia, por exemplo, os especialistas precisam avaliar as tendências futuras de consumo de eletricidade e fazem perguntas do tipo: “dado o consumo atual e as tendências que observamos nos últimos anos, quanto de eletricidade precisaremos gerar para a cidade no próximo verão?”, tratando-se de um problema de regressão. A resposta a essa pergunta pode influenciar decisões sobre onde alocar recursos, como otimizar a produção de energia ou se há necessidade de construir alguma infraestrutura.

Já para empresas de tecnologia, especialmente aquelas que lançam produtos inovadores, a análise preditiva é crucial. Elas podem querer saber, por exemplo, qual produto seria mais bem recebido por diferentes perfis de clientes baseado em lançamentos anteriores, em feedback inicial do mercado e em tendências de adoção. Responder a essa pergunta pode orientar estratégias de produção, marketing e distribuição.

3 Aprendizado de máquina preditivo

O aprendizado de máquina preditivo é um ramo da ciência de dados focado em construir estimadores que possam fazer previsões ou decisões futuras sem serem explicitamente programados para isso (Faceli *et al.*, 2021). Um estimador é um algoritmo matemático que toma dados como entrada e produz uma previsão ou decisão como saída. Esses estimadores são treinados para aprender padrões a partir de dados existentes, permitindo que façam previsões precisas sobre dados não vistos ou futuros eventos. Este subcapítulo explora o conceito de treino supervisionado como a espinha dorsal do aprendizado de máquina preditivo e diferencia as tarefas de classificação e regressão, fornecendo exemplos práticos para cada uma.

3.1 Treinamento supervisionado

O treino supervisionado é uma etapa do aprendizado de máquina preditivo em que um modelo é alimentado com um conjunto de dados composto por entradas, também conhecidas como atributos ou características, e saídas correspondentes, conhecidas como rótulos (Faceli *et al.*, 2021; Grus, 2016). O termo *supervisionado* refere-se ao fato de que o modelo é treinado sob a supervisão de um conjunto de dados já rotulado, permitindo que o algoritmo aprenda a mapear as entradas para as saídas desejadas e tornando-se eficaz em fazer previsões com base em dados nunca vistos, usando apenas os padrões descobertos na fase de treinamento.


Para ilustrar, considere um modelo de predição de falhas em equipamentos industriais. As entradas podem incluir leituras de sensores de temperatura, pressão e vibração, por exemplo, enquanto os rótulos podem indicar se o equipamento apresentou alguma falha em condições similares no passado. O treino supervisionado ajudaria o modelo a entender como as variáveis dos sensores estão relacionadas às falhas de equipamento, habilitando-o a prever futuras falhas com maior precisão.

3.2 Classificação e regressão

Duas tarefas no contexto da realização de predições se destacam: classificação e regressão (Faceli *et al.*, 2021). Ambas têm aplicações práticas vastas e são fundamentais para entender o poder e o alcance da análise preditiva e do aprendizado de máquina supervisionado.

Figura 1 – Diferença entre classificação e regressão

TAREFAS DE APRENDIZADO DE MÁQUINA



A tarefa de classificação envolve atribuir uma categoria ou classe específica a uma nova entrada com base em seu conjunto de características. O objetivo é criar um modelo que possa efetivamente categorizar novos dados em um dos rótulos predefinidos. Um exemplo clássico é o filtro de spam de um serviço de e-mail. Neste caso, o modelo é treinado com um conjunto de e-mails que já foram categorizados como “spam” ou “não spam”. O algoritmo aprende a identificar características distintas desses e-mails, como palavras-chave específicas, formatação e outros atributos. Uma vez treinado, o modelo pode então categorizar novos e-mails recebidos em uma dessas duas classes, ajudando a manter a caixa de entrada do usuário livre de mensagens indesejadas.

Outro exemplo é o emprego de dados na área da saúde, em que algoritmos de classificação podem ser usados para diagnosticar doenças. O modelo pode ser treinado com dados de histórico médico, de resultados de exames ou de sintomas do paciente para aprender a classificar novos casos em categorias como “alto risco” ou “baixo risco” para certas condições médicas.

A regressão, por outro lado, é focada em prever um valor numérico contínuo com base em variáveis de entrada. Diferentemente da classificação, que categoriza dados em rótulos distintos, a regressão lida com a previsão de uma quantidade. Um exemplo comum é a previsão do preço

de uma casa com base em características como área, localização e número de quartos. O modelo é treinado com um conjunto de dados em que os preços anteriores de casas são conhecidos, e o algoritmo aprende a relação entre as características da casa e o seu preço de venda.

Outra aplicação prática de regressão pode ser encontrada na área de finanças, em que modelos podem ser usados para prever o preço futuro de uma ação com base em indicadores de mercado e desempenho passado. Aqui, o objetivo é estimar um valor contínuo que represente o preço futuro da ação para então ser usado para tomar decisões de investimento informadas.

4 Algoritmos para realizar previsões

O poder da análise preditiva está intimamente ligado à eficácia dos algoritmos utilizados para fazer previsões. O sucesso de um modelo preditivo não depende apenas da qualidade dos dados ou do entendimento do problema, mas também da escolha do algoritmo apropriado (Faceli *et al.*, 2021). Neste capítulo, exploraremos alguns dos algoritmos básicos usados para realizar previsões: k-nearest neighbors (k-NN), regressão linear e regressão logística.



PARA SABER MAIS

Há ainda diversos outros algoritmos para geração de modelos preditivos. Um deles é o aprendizado profundo e as redes neurais, muito difundidos e utilizados na prática em empresas e soluções. Para conhecer mais sobre eles, recomendamos a publicação on-line *Deep learning book* (2022), uma iniciativa da Data Science Academy.


4.1 K-nearest neighbors (k-NN)

O algoritmo k-nearest neighbors (k-NN) é um método de aprendizado de máquina que utiliza a ideia de proximidade para fazer previsões. É um algoritmo baseado em instância, o que significa que ele faz previsões com base no conjunto de dados de treinamento inteiro em vez de criar um modelo generalizado. A premissa básica é que entradas similares tendem a ter saídas similares.

O funcionamento do k-NN é relativamente simples. Quando uma nova entrada precisa ser classificada ou um valor precisa ser previsto, o algoritmo busca no conjunto de treinamento as k observações mais próximas da nova entrada. A proximidade geralmente é medida usando métricas de distância, como a distância euclidiana para dados numéricos ou medidas de similaridade de texto para dados categóricos.

Para uma tarefa de classificação, o algoritmo identifica as classes dos k vizinhos mais próximos e atribui à nova entrada a classe que aparece com mais frequência entre esses vizinhos. Para uma tarefa de regressão, o algoritmo calcula a média (ou alguma outra medida central) dos valores dos k vizinhos mais próximos para fazer uma previsão numérica. Para demonstrar o algoritmo, é possível usar o gráfico *scatterplot* (Milani, 2020) mostrando a inserção de um novo ponto no gráfico e classificando-o como azul ou vermelho, dependendo do número de k .

Figura 2 – Demonstração do algoritmo k-NN



4.2 Regressão linear

A regressão linear é um dos métodos mais elementares e frequentemente empregados em aprendizado de máquina para previsões numéricas. Este algoritmo tenta estabelecer uma relação linear entre a variável que se deseja prever, conhecida como variável dependente, e uma ou mais variáveis que são usadas para fazer a previsão, chamadas de variáveis independentes. O objetivo é encontrar a melhor linha de ajuste que pode prever a variável dependente de forma precisa.

Os principais componentes de um modelo de regressão linear são os coeficientes e o intercepto. Os coeficientes representam os pesos ou a importância dada às variáveis independentes. O intercepto é basicamente o ponto onde a linha de melhor ajuste cruza o eixo da variável dependente quando todas as variáveis independentes são iguais a zero.

4.3 Regressão logística

A regressão logística é comumente utilizada para categorização ou classificação em situações binárias, embora o termo *regressão* possa sugerir algo diferente. Sua força reside em sua capacidade de fornecer estimativas de probabilidade para esses cenários. Utilizando diversas variáveis independentes, o algoritmo quantifica as chances de um evento específico acontecer. Essa estimativa de probabilidade é então transformada em uma escala que varia de zero a um, facilitando a interpretação e a tomada de decisões.

4.4 Métricas de avaliação

Para avaliar a qualidade dos modelos preditivos criados, utilizamos diversas métricas. Na classificação, a acurácia é uma das métricas mais diretas e frequentemente usadas para avaliar o desempenho de um modelo, visto que mede a proporção de previsões corretas feitas em relação ao número total de observações. Embora seja fácil de entender e calcular, a acurácia pode ser enganosa em cenários em que as classes estão desequilibradas. Calcula-se a acurácia dividindo o número de previsões corretas pelo número total de previsões.

$$\text{Acurácia} = \frac{\text{número de classificações corretas}}{\text{total de exemplos}}$$

Em tarefas de regressão, são comumente usadas as métricas de erro médio absoluto (*MAE*) e erro quadrático médio (*MSE*). O *MAE* é a média dos erros absolutos entre as previsões e os valores reais, fornecendo uma noção clara da magnitude dos erros. Para calcular, deve-se pegar o valor real e o valor previsto de cada exemplo e extrair o módulo da diferença, resultando no erro. Então, soma-se todos esses erros e divide-se pelo número total de exemplos (*n*). O *MSE*, por sua vez, eleva ao quadrado as diferenças entre as previsões. Isso faz com que o *MSE* penalize erros maiores mais severamente do que o *MAE*, tornando-o mais sensível a outliers.

$$MAE = \frac{1}{n} \sum_{i=1}^n |\text{valor}_{\text{real}_i} - \text{valor}_{\text{previsto}_i}|$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (\text{valor}_{\text{real}_i} - \text{valor}_{\text{previsto}_i})^2$$

5 Predições na prática

Na prática, as técnicas de análise preditiva são indispensáveis para resolver uma variedade de problemas do mundo real, desde a identificação de padrões de comportamento do consumidor até a otimização de operações industriais. Utilizando ferramentas como Python e scikit-learn, é possível implementar algoritmos de aprendizado de máquina para tarefas específicas, como classificar se uma pessoa tem tendência a diabetes (classificação), ou prever o preço de uma casa com base em suas características (regressão).

5.1 Case: previsão de diabetes

Para empregar a classificação de forma prática, usaremos uma base de dados sobre diabetes, proveniente do Instituto Nacional de Diabetes e Doenças Digestivas e Renais dos Estados Unidos, extraída do Kaggle (Khare, 2016; Smith *et al.*, 1988). Este conjunto de dados tem um objetivo diagnóstico: visa prever a probabilidade de um paciente ter diabetes com base em várias medidas médicas. O conjunto de dados inclui atributos como níveis de glicose, índice de massa corporal (BMI), idade e função de genealogia do diabetes, considerados particularmente úteis na avaliação do risco da doença, além do *outcome*, ou seja, se aquela pessoa teve diabetes.

Espera-se que quando um paciente novo chegue ao hospital, seja possível extrair essas informações sobre sua saúde e prever se ele corre risco de ter diabetes.

Podemos aplicar dois algoritmos de aprendizado de máquina, k-nearest neighbors e regressão logística, para prever a ocorrência de diabetes e criar um modelo e, depois, avaliar a acurácia de cada modelo. Para isso, uma possibilidade é utilizar Python, pandas e scikit-learn, tal como mostrado no exemplo a seguir.

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score

df = pd.read_csv('diabetes.csv')

selected_features = ['Glucose', 'BMI', 'Age',
'DiabetesPedigreeFunction']

# Extraindo os atributos e o rótulo
X = df[selected_features]
y = df['Outcome']

# Dividindo a base de dados entre treino e teste
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)

# KNN
knn = KNeighborsClassifier(n_neighbors=5)
knn.fit(X_train, y_train)
knn_predictions = knn.predict(X_test)
knn_accuracy = accuracy_score(y_test, knn_predictions)

# Logistic Regression Model
log_reg = LogisticRegression()
log_reg.fit(X_train, y_train)
log_reg_predictions = log_reg.predict(X_test)
log_reg_accuracy = accuracy_score(y_test,
log_reg_predictions)

knn_accuracy, log_reg_accuracy
```

Após aplicar os algoritmos de k-NN e regressão logística no conjunto de dados, obtivemos acurácias de aproximadamente 74,03% e 77,27%,

respectivamente. Ambos os modelos apresentaram acurácias razoavelmente altas, mas o modelo de regressão logística superou o k-NN neste conjunto de dados usando os atributos selecionados, que são “*Glucose*”, “*BMI*”, “*Age*” e “*DiabetesPedigreeFunction*”. Esses números sugerem que o modelo de regressão logística pode ser mais adequado para este problema de classificação específico.

5.2 Case: previsão de preços de casas

O conjunto de dados de preços de casas na Califórnia é um dataset amplamente utilizado em problemas de aprendizado de máquina relacionados à regressão, sendo possível acessar diretamente pela biblioteca scikit-learn. O conjunto abrange informações sobre várias características dos imóveis e é frequentemente usado para prever o valor das casas nessas áreas.

O conjunto de dados contém atributos como longitude e latitude para a localização geográfica, idade média das casas, total de cômodos e quartos, população da área e número de domicílios. Também inclui informações sobre a renda média dos residentes e o valor médio das casas, que é a variável alvo a ser prevista. Um último atributo indica a proximidade do oceano, o que pode ser um fator significativo no valor de uma propriedade.

Podemos criar modelos de regressão linear e k-NN para realizar a previsão de valores de casas novas que foram construídas na região ou que ainda não têm avaliação. Neste livro, faremos isso com Python e scikit-learn.

```

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import fetch_california_housing
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.neighbors import KNeighborsRegressor
from sklearn.metrics import mean_squared_error

housing = fetch_california_housing()

X = housing.data
y = housing.target

X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                    test_size=0.2, random_state=42)

# Regressão Linear
lin_reg = LinearRegression()
lin_reg.fit(X_train, y_train)
lin_reg_predictions = lin_reg.predict(X_test)
lin_reg_mse = mean_squared_error(y_test, lin_reg_predictions)

# KNN
knn_reg = KNeighborsRegressor(n_neighbors=5)
knn_reg.fit(X_train, y_train)
knn_reg_predictions = knn_reg.predict(X_test)
knn_reg_mse = mean_squared_error(y_test, knn_reg_predictions)

lin_reg_mse, knn_reg_mse

```

Ao aplicar modelos de regressão linear e k-NN de regressão ao conjunto de dados de moradias da Califórnia, obtivemos diferentes erros quadráticos médios (*MSE*) para os dois métodos. O modelo de regressão linear resultou em um *MSE* de aproximadamente 0,556, enquanto o modelo k-NN teve um *MSE* de aproximadamente 1,119. Isso sugere que o modelo de regressão linear teve um desempenho significativamente melhor que o k-NN em termos de precisão na previsão do valor médio das casas. Um *MSE* menor indica que as previsões do modelo estão mais

próximas dos valores reais, tornando o modelo de regressão linear mais adequado para este conjunto de dados específico.

6 Resultados da análise preditiva

Os resultados de uma análise preditiva focam principalmente na previsão de futuros eventos ou tendências com base em dados históricos, utilizando algoritmos avançados e técnicas de modelagem estatística. Estas previsões, quando corretamente implementadas, podem oferecer vantagens competitivas notáveis e informar decisões estratégicas em várias indústrias (O’Neil; Schutt, 2013).

Tomemos, por exemplo, o setor financeiro. Um banco, ao empregar técnicas de análise preditiva, percebeu que era capaz de prever com precisão os clientes que estavam mais propensos a solicitar um empréstimo nos próximos seis meses. Armado com essa informação, o banco desenvolveu campanhas de marketing direcionadas a este segmento específico, maximizando a eficácia de seus esforços promocionais e melhorando a conversão.

No setor de tecnologia, uma empresa de softwares percebeu, por meio da análise preditiva, que haveria mais probabilidade de certas características e funcionalidades serem demandadas pelos usuários nos próximos anos. Com base nessa previsão, a empresa pôde direcionar sua pesquisa e desenvolvimento de forma mais eficaz, antecipando-se às necessidades do mercado e mantendo sua posição de liderança. Por fim, consideremos o setor de agricultura. Agricultores, ao analisarem dados climáticos passados e utilizando modelos preditivos, conseguiram prever períodos de seca ou chuva com maior precisão. Isso permitiu que planejassem melhor suas plantações e colheitas, otimizando a produção e minimizando perdas.

Estes exemplos ilustram a capacidade inerente da análise preditiva. Enquanto a análise descritiva observa o passado e a análise prescritiva gera

recomendações de ações e decisões, a análise preditiva tem como resultado antecipar tendências e eventos futuros. Quando as empresas reconhecem e aproveitam essas previsões, elas podem adaptar-se proativamente, garantindo vantagens competitivas e otimizando seus resultados.

Considerações finais

Neste capítulo, mergulhamos na jornada dos dados, desde a sua geração e armazenamento até a tradução em insights acionáveis e soluções inovadoras para problemas do mundo real. Ficou evidente que embora a ciência de dados possa parecer um território dominado apenas por algoritmos complexos e grandes volumes de dados, seu verdadeiro poder reside na capacidade de fornecer soluções tangíveis que impactam diretamente a sociedade, os negócios e a vida cotidiana. Além disso, conhecemos as nuances entre datasets abertos e fechados, a importância de avaliar a utilidade e a qualidade dos dados, e as diversas métricas que podem ser empregadas para medir o sucesso e a eficácia das iniciativas de análise de dados.

Na medida em que encerramos este capítulo, é imperativo reconhecer que o sucesso de um projeto em ciência de dados depende de uma compreensão clara dos problemas, da escolha adequada de ferramentas e técnicas, e da capacidade de interpretar resultados de forma crítica e contextual. Dessa forma, com as abordagens certas, ela tem o potencial de revolucionar setores de forma inovadora e de criar soluções impactantes para perguntas e desafios persistentes.

Referências

BASSO, Douglas Eduardo. **Big data**. Curitiba: Contentus, 2020. *E-book*.

DATA SCIENCE ACADEMY. Capítulo 9 – a arquitetura das redes neurais. *In*: DATA SCIENCE ACADEMY. **Deep learning book**. Brasília, DF: Data Science Academy,

2022. Disponível em: <https://www.deeplearningbook.com.br/a-arquitetura-das-redes-neurais/>. Acesso em: 2 out. 2023.

FACELI, Katti *et al.* **Inteligência artificial**: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2021.

GRUS, Joel. **Data science do zero**. Tradução: Welington Nascimento. Rio de Janeiro: Alta Books, 2016. *E-book*.

KHARE, Akshay Dattatray. Diabetes dataset. **Kaggle**. San Francisco, CA, USA, 2016. Disponível em: <https://www.kaggle.com/datasets/akshaydattatraykhare/diabetes-dataset>. Acesso em: 2 out. 2023.

MERCANTE, Tiago Henrique Medeiros. **Análise preditiva**: aplicada para solução de problemas reais. São Paulo: Editora Senac São Paulo, 2022.

MILANI, Alessandra Maciel Paz *et al.* (org.). **Visualização de dados**. Porto Alegre: Sagah, 2020.

O'NEIL, Cathy; SCHUTT, Rachel. **Doing data science**: straight talk from the frontline. Sebastopol, CA, USA: O'Reilly Media, 2013.

SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business intelligence e análise de dados para gestão do negócio**. Tradução: Ronald Saraiva de Menezes. 4. ed. Porto Alegre: Bookman, 2019.

SMITH, J. W. *et al.* Utilização do algoritmo ADAP para prever o início do diabetes mellitus. In: SIMPÓSIO DE APLICAÇÕES COMPUTACIONAIS EM SAÚDE, 1988, [s. l.]. **Anais [...]**. Washington, DC, USA: IEEE Computer Society Press. p. 261-265.

WHAT IS predictive analytics? **Google Cloud**. [S. l.], [202-]. Disponível em: <https://cloud.google.com/learn/what-is-predictive-analytics?hl=pt-br>. Acesso em: 18 set. 2023.

Análise prescritiva

A análise prescritiva ocupa um lugar estratégico na ciência de dados. Seu foco principal é responder à pergunta: “dado o cenário atual, qual é a melhor decisão a ser tomada?” (Sharda; Delen; Turban, 2019). Enquanto outras formas de análise desvendam o passado ou projetam o futuro, a análise prescritiva oferece soluções práticas e acionáveis para o presente.

Neste contexto, podemos utilizar a análise prescritiva para orientar e sugerir cursos de ação aos gestores, o que chamamos de “tomada de decisão homem-máquina”. Um dos possíveis usos seria para o planejamento da alocação de funcionários em projetos, ou para a sugestão de rotas para transporte de mercadoria. Já outra possibilidade é a “tomada de decisão exclusivamente por máquinas”, utilizada, por exemplo, em sistemas de recomendação, jogos e carros autônomos (Kulkarni; Shivananda; Manure, 2023).

Em um ambiente empresarial em constante mudança, a capacidade de tomar decisões inteligentes e informadas é crucial. A análise prescritiva emerge, portanto, como uma solução robusta, guiando estratégias e ações de maneira otimizada. Neste capítulo, então, veremos mais sobre as principais abordagens para o desenvolvimento desse tipo de análise, assim como formas de aplicar essas abordagens de maneira prática.

1 O que é e qual a função da análise prescritiva

A análise prescritiva integra-se à ciência de dados como um método focado na determinação de soluções otimizadas para problemas complexos. Por meio da combinação de técnicas como programação linear, otimização, sistemas especialistas e simulação, a análise prescritiva modela situações para identificar a melhor ação ou sequência de ações. Sua principal função é produzir recomendações específicas baseadas em dados e modelos matemáticos, levando em consideração variáveis de entrada, restrições operacionais e objetivos predeterminados. Ao contrário de outras formas de análise que se concentram na interpretação ou previsão, a análise prescritiva prioriza a aplicação prática, oferecendo soluções claras para a implementação em cenários reais.

2 Tipo de pergunta

As perguntas apontadas pela análise prescritiva são estruturadas para indicar ações ideais. Elas procuram esclarecer a melhor estratégia ou curso de ação para situações específicas, levando em consideração variáveis, restrições e objetivos. Essencialmente, as questões se centram em “o que devo fazer?” ou “como devo proceder?” em um contexto específico.

No setor financeiro, por exemplo, uma indagação poderia ser: “dadas as tendências atuais do mercado e o perfil de risco do portfólio, como

deveríamos realocar investimentos para otimizar os retornos?”. Esta abordagem tem impacto direto nas decisões de investimento, gestão de riscos e composição de ativos. Já na área da saúde, os profissionais poderiam se perguntar: “com base nos sintomas do paciente, no histórico médico e nos padrões identificados em casos semelhantes, qual seria o tratamento mais indicado?”. Esta questão orienta procedimentos médicos, prescrição de medicamentos e planos de cuidados.

No segmento do varejo, uma questão pertinente poderia ser: “com base nas tendências de compra e no inventário atual, quais produtos deveríamos priorizar ou descontinuar?”. Essa análise influencia as campanhas de marketing, as estratégias de vendas e a gestão de estoque. No universo dos sistemas de recomendação, empresas como Amazon e Netflix enfrentam questões prescritivas: “dado o histórico de navegação e compra de um usuário, quais produtos ou conteúdos deveríamos recomendar para maximizar sua satisfação e engajamento?”.

Estes exemplos mostram a adaptabilidade e a relevância prática da análise prescritiva em múltiplos setores, demonstrando seu papel fundamental na tomada de decisões inteligentes.

3 Decisões inteligentes (DI)

A tomada de decisão sempre foi uma junção de intuição, experiência e dados disponíveis (Rautenberg; Carmo, 2019). No ambiente corporativo, por exemplo, um gestor poderia confiar em suas vivências passadas e em sua capacidade de julgamento para tomar uma decisão estratégica. Além disso, mesmo com a disponibilidade de dados, muitas vezes esses eram analisados de forma manual ou por intermédio de ferramentas básicas, levando a interpretações que poderiam ser afetadas por vieses humanos. Essas decisões, embora tenham resultados positivos em muitas ocasiões, também carregam consigo os problemas inerentes à natureza humana, como as tendências cognitivas e emocionais.

Com a revolução digital e a expansão da capacidade computacional, a forma como as decisões são tomadas está mudando. A inteligência de decisão (DI) surge como uma junção entre o julgamento humano e as capacidades analíticas das máquinas, criando duas categorias distintas de tomada de decisão: a decisão homem-máquina e a decisão somente máquina (Kulkarni; Shivananda; Manure, 2023).

Na *decisão homem-máquina*, a máquina analisa dados e fornece insights, mas a decisão final ainda repousa no ser humano. Por exemplo, um médico pode usar um software de diagnóstico para analisar imagens de ressonância magnética e com base nos insights do software, o médico faz um diagnóstico. Em outro cenário, um gestor de finanças pode usar um programa de análise de tendências do mercado para informar suas estratégias, mas a decisão sobre onde investir ainda é dele.

Já na *decisão somente máquina*, a máquina é responsável por tomar a decisão final sem intervenção humana direta. Por exemplo, sistemas de *trading* algorítmico no mercado de ações compram e vendem ativos em milissegundos com base em algoritmos, sem necessidade de um operador humano. Da mesma forma, em carros autônomos, decisões sobre manobras, aceleração e frenagem são tomadas em tempo real por sistemas embarcados, sem intervenção do passageiro.

Nesse contexto, a capacidade de discernir quando confiar na máquina, no julgamento humano ou numa combinação dos dois torna-se uma habilidade valiosa. A verdadeira força da tomada de decisão no futuro está na habilidade de equilibrar com eficácia a análise prescritiva e a opinião humana intuitiva e subjetiva, assim como algumas empresas líderes de mercado já vêm fazendo, por exemplo.

A Capital One, no setor financeiro, utiliza a análise prescritiva e decisões inteligentes para aperfeiçoar suas decisões de crédito. Ao combinar modelos de aprendizado de máquina com expertise humana, a empresa conseguiu aumentar a precisão nas decisões de crédito e diminuir o risco de inadimplência. A Boeing, por sua vez, tem otimizado a

manutenção de aeronaves. Mediante análise de dados dos sensores em seus motores, a empresa agora consegue prever necessidades de manutenção, agendando reparos proativamente e aprimorando a segurança das operações. No setor de logística, a UPS utiliza DI para potencializar a entrega de pacotes. Com o auxílio de modelos de aprendizado de máquina para prever demanda e otimizar rotas de entrega, a empresa tem conseguido diminuir o consumo de combustível e acelerar os prazos de entrega (Kulkarni; Shivananda; Manure, 2023).

4 Modelagem e algoritmos para análise prescritiva

A análise prescritiva engloba uma vasta gama de ferramentas e metodologias que auxiliam na tomada de decisão otimizada. Estas ferramentas, moldadas pelo aumento considerável da quantidade de dados disponíveis (Basso, 2020; Davenport, 2014), assim como por avanços computacionais e teóricos, abrangem desde modelos matemáticos tradicionais até abordagens baseadas em inteligência artificial. Este subcapítulo visa fornecer uma visão geral dessas ferramentas e metodologias centrais.

4.1 Otimização


Uma das técnicas mais importantes da análise prescritiva é a otimização. Essa metodologia envolve a formulação matemática de um problema cujo objetivo é encontrar a solução mais adequada dentro de um conjunto de opções viáveis (Delen, 2019). Em termos práticos, essa “melhor solução” pode se traduzir em maximizar lucros, minimizar custos, otimizar a alocação de recursos, entre outras metas.

A modelagem começa com a representação do problema de forma computacional, o que pode ser alcançado mediante decomposição em seus componentes fundamentais e por meio da tradução desses componentes em estruturas de dados e algoritmos. Esse processo permite

que complexidades intrínsecas do mundo real sejam capturadas e manipuladas em ambientes digitais, facilitando as análises, as simulações e a busca por soluções ótimas ou aproximadas.

Uma das principais modelagens para otimização são os grafos, que são estruturas matemáticas que permitem representar relações entre objetos de um certo conjunto, sendo extremamente úteis para visualizar e resolver problemas que envolvem conectividade e relações. Em um grafo, os objetos são representados por vértices (ou nós) e as relações entre eles por arestas (ou arcos). Por exemplo, as pessoas podem ser representadas pelos nós e suas amizades em redes sociais pelas arestas, sendo possível também quantificar a força dessa relação por meio de pesos nas arestas. Outro uso muito comum de grafos é em problemas de transporte e logística, sendo as cidades ou casas representadas pelos nós, as arestas pelas estradas e a distância entre elas representada pelo peso. A figura 1 retrata essa modelagem.

Figura 1 – Grafo de cidades e suas distâncias



Após a representação do problema, devemos determinar uma função objetivo, que é a medida que se deseja otimizar. Por exemplo, a função objetivo em uma indústria pode ser a maximização da produção, enquanto em um banco pode ser a minimização de riscos. Acompanhando essa função estão as restrições, que delimitam as condições sob as quais a solução deve ser encontrada. Elas podem ser restrições de capacidade, orçamentárias, de tempo, entre outras. Por fim, deve-se aplicar uma técnica para otimizar a função e sugerir algum curso de ação.

4.1.1 Programação linear e não linear

A programação linear (PL) é uma técnica matemática de otimização cujo foco é encontrar o valor máximo ou mínimo de uma função objetivo, expressa de forma linear e sujeita a um conjunto de restrições também lineares. Como exemplo, em um contexto empresarial, uma fábrica pode querer maximizar seu lucro considerando a fabricação de dois produtos. A função objetivo linear pode representar o lucro total da produção, enquanto as restrições podem abordar a quantidade limitada de matérias-primas e horas de trabalho disponíveis. Por sua vez, a programação não linear (PNL) aborda situações em que a função objetivo ou as restrições não são linearmente expressas. A complexidade cresce em razão das curvas e dos contornos do problema, o que pode levar a múltiplas soluções locais. Por exemplo, ao tentar otimizar o design de uma antena para maximizar a recepção de sinal, a relação entre o formato da antena, os materiais e a eficiência de sinal pode ser mais bem representada por uma função não linear.

4.1.2 Heurísticas

Heurísticas são métodos de solução de problemas que fornecem soluções aproximadas, mas eficientes, especialmente quando é impraticável abordar o problema de forma exaustiva por causa de sua

complexidade. O termo heurística vem da palavra grega *heuriskein*, que significa “encontrar”. Em vez de buscar a solução ótima, uma heurística tenta rapidamente produzir uma solução de alta qualidade que atende aos critérios de aceitabilidade.

A principal característica das heurísticas é que elas oferecem soluções práticas quando a busca pela solução perfeita é muito dispendiosa ou demorada. No mundo real, a maioria dos problemas estarão dentro desse espectro, uma vez que a complexidade de possibilidades e representação é grande. Essa multiplicidade torna as abordagens tradicionais exatas, como algoritmos de busca exaustiva, computacionalmente proibitivas.

As heurísticas são muitas vezes baseadas em regras práticas que se provaram úteis para problemas similares no passado. Por exemplo, no problema do caixeiro-viajante, uma heurística comum é o método do “vizinho mais próximo”, em que se inicia em uma cidade e, em seguida, se move repetidamente para a cidade mais próxima até que todas as cidades tenham sido visitadas (também conhecidos como algoritmos gulosos). Embora este método possa não garantir a rota mais curta, ele geralmente produz uma rota razoavelmente eficiente em um tempo curto.

4.1.3 Algoritmos genéticos

Os algoritmos genéticos são inspirados nos processos de seleção natural e genética, usados principalmente em problemas de otimização complexos (Faceli *et al.*, 2021). Iniciando com uma população de soluções aleatórias, cada solução (ou indivíduo) é avaliada com base em sua aptidão. As soluções mais aptas são selecionadas e combinadas entre si, gerando novas soluções. Para garantir diversidade, ocorrem pequenas mutações aleatórias nos indivíduos gerados. Este ciclo de seleção, combinação e mutação se repete até que se alcance uma solução satisfatória ou um critério de parada. A eficácia dos algoritmos genéticos reside em sua habilidade de explorar uma vasta gama de soluções e de adaptar-se continuamente, buscando aproximações cada vez melhores para o problema.

4.2 Sistemas baseados em regras

A tomada de decisão é, inerentemente, um processo que envolve a avaliação de diferentes opções e cenários com base em um conjunto de critérios ou instruções. Em muitos contextos, particularmente naqueles caracterizados por sua complexidade ou pela necessidade de respostas rápidas, a capacidade humana de processar informações e de aplicar uma infinidade de regras de maneira eficiente é limitada. É aqui que a automação desse processo se torna extremamente valiosa. Ao codificar instruções e regras em sistemas automatizados, as organizações podem garantir que decisões sejam tomadas de forma rápida, consistente e livre de possíveis vieses humanos.

Os sistemas especialistas representam uma das abordagens mais notáveis nesta área. Eles são projetados para emular a capacidade de decisão de um *expert* em um campo específico. Esses sistemas contêm uma ampla base de conhecimento, que armazena uma miríade de regras e princípios do domínio em questão. Junto de um mecanismo de inferência, esses sistemas avaliam as informações apresentadas, aplicam as regras pertinentes e fornecem recomendações ou decisões.

Imagine que um médico em um hospital superlotado precise diagnosticar rapidamente um paciente com sintomas de uma doença rara. Aqui, um sistema especialista médico, que contém uma vasta base de conhecimento sobre várias doenças e sintomas, pode ser consultado para fornecer um diagnóstico preliminar, auxiliando o médico em sua decisão. Esse sistema avalia as informações do paciente, aplica as regras pertinentes de seu banco de dados e sugere um diagnóstico ou recomendações.

A implementação e o uso de sistemas especialistas oferecem vários benefícios. Além da rapidez na tomada de decisão, eles proporcionam uma consistência nas decisões, algo essencial em áreas como medicina, engenharia ou finanças, em que a padronização é fundamental. Adicionalmente,

em domínios nos quais o conhecimento está em constante evolução e é vasto, os sistemas especialistas servem como repositórios de informação, centralizando o conhecimento e tornando-o mais acessível. No entanto, é crucial manter tais sistemas atualizados e periodicamente revisados, garantindo que regras e informações armazenadas permaneçam relevantes e precisas.

4.3 Simulações

As simulações são ferramentas essenciais na análise prescritiva, pois fornecem uma maneira de testar diversas estratégias em um ambiente controlado, permitindo entender as possíveis consequências de cada cenário antes de serem implementados no mundo real.

No contexto de análise prescritiva, as simulações são geralmente empregadas para modelar sistemas complexos, que envolvem incertezas e variabilidades. Essa modelagem permite que os tomadores de decisão visualizem o funcionamento interno de um sistema, compreendam as relações entre as partes envolvidas e antecipem os resultados de diferentes decisões. Por exemplo, uma empresa pode usar a simulação para entender como diferentes estratégias de precificação afetariam as vendas e os lucros sob diferentes cenários econômicos.

Existem diferentes tipos de técnicas de simulação. A simulação de Monte Carlo, por exemplo, é baseada na repetição de amostragens aleatórias para obter resultados numéricos. Ela é útil para lidar com incertezas, fornecendo uma distribuição de possíveis resultados. Já a simulação de eventos discretos foca na modelagem de sistemas em que a mudança de estado é discreta e sequencial, comum em operações industriais ou logísticas.



PARA SABER MAIS

A simulação de Monte Carlo, cujo nome tem origem no famoso cassino de Mônaco, é uma técnica que usa aleatoriedade para prever variabilidade em modelos matemáticos. Em vez de fixar um único valor, ela testa milhares de cenários possíveis, fornecendo um espectro de resultados. A simulação é usada em campos como finanças e engenharia, e captura incertezas complexas, orientando decisões. Para conhecer mais sobre essa simulação, assista à explicação do professor John Guttag: https://www.youtube.com/watch?v=OgO1gpXSUzU&ab_channel=MITOpenCourseWare (acesso em: 20 nov. 2023).

A força da simulação é que ela não apenas sugere uma decisão específica, mas também oferece insights sobre o potencial impacto dessa decisão em diversos cenários. Dessa forma, ajuda os gestores a entender os riscos e as oportunidades de cada escolha, levando a decisões mais informadas e robustas.

4.4 Sistemas autônomos

Sistemas autônomos são sistemas capazes de realizar tarefas e tomar decisões sem intervenção humana direta, dependendo em grande parte de algoritmos avançados e capacidades de aprendizado de máquina. Entre as abordagens mais notáveis dentro dos sistemas autônomos estão o aprendizado por reforço e os sistemas de recomendação.

4.4.1 Aprendizado por reforço

O aprendizado por reforço é uma técnica de aprendizado de máquina em que um agente aprende a tomar decisões por meio de tentativa e erro, explorando e interagindo com seu ambiente e com o objetivo de maximizar algum tipo de recompensa acumulada. O agente decide quais ações tomar em determinado estado para maximizar a recompensa total.

Imagine que um robô esteja aprendendo a caminhar. No estado inicial, o robô está parado e tem à sua disposição um conjunto de possíveis movimentos, como mover uma perna para frente, inclinar-se para o lado ou dar um passo à esquerda. Cada ação é como uma experimentação que leva a um novo estado: o robô pode avançar um passo, manter-se no lugar ou até mesmo cair.

Ao escolher uma ação, como mover a perna direita para frente, o robô observa o resultado. Se ele avança sem cair, ele pode receber uma recompensa positiva. Se ele cai, recebe uma penalidade. Com o passar do tempo, ao repetir esse processo de ação—observação—recompensa, o robô “aprende” a sequência de movimentos que maximiza sua recompensa total, ou seja, ele descobre como caminhar de maneira estável e eficaz.

Este método de aprendizado permite a adaptação e a otimização de estratégias ao longo do tempo, sendo particularmente útil em ambientes dinâmicos e incertos. Por exemplo, um carro autônomo aprendendo a navegar em um ambiente urbano pode receber recompensas por escolhas que o levam ao destino de forma segura e eficiente e penalidades por colisões ou violações de trânsito. Uma outra aplicação inovadora do aprendizado por reforço é o AlphaGo da Google DeepMind, que empregou a técnica para derrotar campeões mundiais no jogo de Go, um feito considerado revolucionário em razão da complexidade do jogo.

4.4.2 Sistemas de recomendação

Sistemas de recomendação são algoritmos projetados para sugerir itens ou ações a usuários com base em informações coletadas anteriormente. Esses sistemas são amplamente utilizados em serviços on-line, em que a personalização é fundamental para melhorar a experiência do usuário.

Dois métodos predominantes nesses sistemas são a filtragem colaborativa e a filtragem baseada em conteúdo. A filtragem colaborativa

apoia-se nas interações passadas de usuários semelhantes. Por exemplo, se o usuário A gosta dos filmes X, Y e Z, e o usuário B gosta de X e Y, é provável que B também goste do filme Z. Já a filtragem baseada em conteúdo usa características dos itens para fazer recomendações. Por exemplo, se um usuário assiste a muitos filmes de ação, o sistema recomendará outros filmes desse gênero.

Um exemplo clássico é o da Netflix. Com base no histórico de visualizações e nas avaliações dos usuários, ela oferece recomendações personalizadas, usando uma combinação de filtragem colaborativa e técnicas baseadas em conteúdo, bem como aprendizado profundo. Outro exemplo é o da Amazon, que sugere produtos com base no histórico de compras e navegação.

5 Resultados da análise prescritiva

A análise prescritiva, quando adequadamente empregada, tem o poder de fornecer insights profundos e soluções acionáveis para uma ampla gama de desafios empresariais. Um dos principais resultados dessa abordagem é a otimização de recursos. Seja em termos de capital, mão de obra ou infraestrutura, a análise ajuda as empresas a alocá-los de forma eficiente. Como exemplo, pense em uma empresa de logística que, por meio da análise prescritiva, determina a rota mais eficaz para suas entregas, ponderando variáveis como tráfego, custo de combustível e capacidade de carga.

Além disso, a tomada de decisão torna-se mais precisa. Com recomendações fundamentadas em dados, as escolhas corporativas estão mais alinhadas aos objetivos estratégicos, garantindo uma ação mais informada. A personalização da experiência do cliente também é uma realidade tangível. Recorrendo à análise prescritiva, empresas como Amazon e Netflix personalizam ofertas, tornando a experiência do cliente mais

relevante e atraente. Esta personalização aumenta a satisfação do cliente e promove uma maior lealdade.

Por fim, ao identificar e explorar novas oportunidades, as empresas podem descobrir e adotar abordagens inovadoras que anteriormente não eram contempladas. Em resumo, a análise prescritiva proporciona uma variedade de benefícios, permitindo que as empresas naveguem com confiança na complexidade dos negócios modernos.

6 **Case: sistema de recomendação de filmes**

É possível implementar um sistema de recomendação de filtragem baseada em conteúdo com Python, pandas e scikit-learn. Suponha que você foi contratado por um novo serviço de *streaming* que tem em seu catálogo os mil filmes mais bem avaliados da história. Essa classificação é derivada da plataforma IMDb, uma renomada base de avaliações de filmes e refletida na base de dados disponível no Kaggle (Shankhdhar, 2020).

O objetivo é que o usuário possa digitar o nome de um filme de que gostou, e como resposta a plataforma deve sugerir novos filmes para assistir. O processo de construção e implementação da aplicação inicia-se pela aquisição e manipulação dos dados, dos quais um conjunto selecionado de atributos, incluindo gênero, diretor e atores principais, são extraídos e preparados. A preparação dos dados envolve técnicas de pré-processamento responsáveis por transformar e padronizar os dados, garantindo uma análise mais precisa e coerente.

Após a preparação dos dados, o algoritmo de similaridade é implementado para identificar filmes que compartilham características similares com o filme indicado pelo usuário. O algoritmo empregado explora o conceito de vizinhos mais próximos, utilizando os atributos previamente escolhidos para estabelecer relações de proximidade entre os filmes, resultando em sugestões mais precisas e afinadas às preferências do usuário.

```
# Importações
import pandas as pd
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder,
StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.neighbors import NearestNeighbors
```

```
# Coleta e pré-processamento
def prepare_data():
    imdb = pd.read_csv('imdb_top_1000.csv')

    # Filtrando os dados
    keep_cols = ['Genre', 'Director', 'Star1', 'Star2']
    imdb_filtered = imdb.loc[:, keep_cols]

    # Tratando variáveis numéricas
    numeric_pipe = Pipeline([('scaler', StandardScaler())])

    # Tratando variáveis categóricas
    categorical_pipe = Pipeline([('encoder',
OneHotEncoder(drop = 'first'))])

    col_transf = ColumnTransformer([
        ('numeric', numeric_pipe, imdb_filtered._get_numeric_
data()).columns.tolist()),
        ('categorical', categorical_pipe, imdb_filtered.select_
dtypes('object').columns.tolist()) ])

    col_transf_fit = col_transf.fit(imdb_filtered)
    imdb_filtered_transf = col_transf_fit.
transform(imdb_filtered)

    return imdb, imdb_filtered_transf
```

```
# Recomendação de filme
def get_movie_recommendations(movie_name, imdb,
                              imdb_filtered_transf):
    # Buscando o filme
    movie_idx = imdb[imdb["Series_Title"].str.lower().str.
contains(movie_name.lower())].index[0]

    n_neighbors = 5
    nneighbors = NearestNeighbors(n_neighbors=n_neighbors,
metric='cosine').fit(imdb_filtered_transf)

    movie_data = imdb_filtered_transf[movie_idx].toarray().
reshape(1, -1)
    _, ind = nneighbors.kneighbors(movie_data)

    # Recomendações
    recommended_movies = imdb.loc[ind[0][1:], :]
    return recommended_movies
```

```
# Executando a aplicação
imdb, imdb_filtered_transf = prepare_data()

movie_name = input("Escreva o filme de que você gostou: ")
recommendations = get_movie_recommendations(movie_name, imdb,
imdb_filtered_transf)

print("\nFilme: ", imdb[imdb["Series_Title"].str.lower().str.
contains(movie_name.lower())].Series_Title.iloc[0])
print("="*80)
print("Recomendações")
print("="*80)
recommendations[['Series_Title', 'Genre']]
```

Ainda que esta implementação de sistemas seja relativamente simples, ela nos traz bons resultados, tal como apresentado na figura 2, permitindo formar um base de conhecimento e estudos. É possível, ainda, expandir o que foi feito aqui para integrar outros fatores e formas de recomendação, tal como colocar o modelo para sugerir filmes em tempo real depois que a pessoa terminou de assistir algo, ou mesmo integrar com redes sociais para considerar opiniões de familiares ou amigos.

Figura 2 – Resultado da execução do algoritmo de recomendação

Escreva o filme de que você gostou: incredibles		
Filme: The Incredibles		
=====		
Recomendações		
=====		
	Series_Title	Genre
891	Incredibles 2	Animation, Action, Adventure
389	The Iron Giant	Animation, Action, Adventure
58	Spider-Man: Into the Spider-Verse	Animation, Action, Adventure
367	Ratatouille	Animation, Adventure, Comedy

Considerações finais

Neste capítulo, exploramos o universo da análise prescritiva, uma abordagem crítica da ciência de dados voltada para a orientação de ações e tomadas de decisão fundamentadas em insights derivados de dados. Destacamos a importância da modelagem de otimização, uma técnica que busca encontrar a solução mais adequada em um conjunto de possíveis soluções. Discutimos também os sistemas baseados em instruções e regras, evidenciando sua capacidade de oferecer decisões consistentes em cenários em que uma miríade de regras precisa ser rapidamente avaliada. Além disso, nos aprofundamos nas técnicas de aprendizado por reforço e sistemas de recomendação, componentes cruciais dos sistemas autônomos.

Em todas essas técnicas e metodologias, um tema comum prevaleceu: a necessidade de tomar decisões informadas em um mundo cada vez mais complexo e saturado de dados. As ferramentas e técnicas discutidas neste capítulo permitem que organizações e indivíduos naveguem neste ambiente utilizando dados para informar, orientar e otimizar suas decisões. Por fim, vimos na prática como construir um sistema de recomendação de filmes que pode ser usado em plataformas de

streaming ou mesmo na sua casa para escolher o que assistir no final de semana a partir dos seus gostos e da sua família.

Referências

BASSO, Douglas Eduardo. **Big data**. Curitiba: Contentus, 2020. E-book.

DAVENPORT, Thomas H. **Big data no trabalho**: derrubando mitos e descobrindo oportunidades. Tradução: Cristina Yamagami. Rio de Janeiro: Elsevier, 2014.

DELEN, Dursun. **Prescriptive analytics**: the final frontier for evidence-based management and optimal decision making. Upper Saddle River, NJ, USA: Pearson FT Press, 2019.

FACELI, Katti *et al.* **Inteligência artificial**: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2021.

KULKARNI, Akshay; SHIVANANDA, Adarsha; MANURE, Avinash. **Introduction to prescriptive AI**: a primer for decision intelligence solutioning with Python. Berkeley, CA, USA: Apress, 2023. Disponível em: <https://doi.org/10.1007/978-1-4842-9568-7>. Acesso em: 3 out. 2023.

MONTE CARLO SIMULATION. **MIT OpenCourseWare**. 19 maio 2017. 1 vídeo (50 min.). Disponível em: https://www.youtube.com/watch?v=OgO1gpXSuzU&ab_channel=MITOpenCourseWare. Acesso em: 13 out. 2023.

RAUTENBERG, Sandro. CARMO, Paulo Ricardo Viviurka do. Big data e ciência de dados: complementariedade conceitual no processo de tomada de decisão. **Brazilian Journal of Information Science**: research trends, Marília, São Paulo, v. 13, n. 1, p. 56-67, mar. 2019. Disponível em: <https://revistas.marilia.unesp.br/index.php/bjis/article/view/8315>. Acesso em: 12 out. 2023.

SHANKHDHAR, Harshit. IMDB movies dataset: top 1000 movies by IMDB rating. **Kaggle**. San Francisco, CA, USA, 2020. Disponível em: <https://www.kaggle.com/datasets/harshitshankhdhar/imdb-dataset-of-top-1000-movies-and-tv-shows/data>. Acesso em: 12 out. 2023.

SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business intelligence e análise de dados para gestão do negócio**. Tradução: Ronald Saraiva de Menezes. 4. ed. Porto Alegre: Bookman, 2019.

Business intelligence e visualização de dados

No intrincado cenário da era da informação, no qual a ciência de dados desempenha um papel protagonista ao desvendar complexidades e prever tendências futuras, há uma disciplina que se destaca como a ponte entre dados brutos e decisões informadas: o business intelligence (BI). Enquanto a ciência de dados busca respostas mais profundas explorando os “porquês” e imaginando “o que poderia ser” usando os métodos avançados e preditivos, o BI foca incisivamente no “o que” e no “como”, proporcionando clareza e insights sobre o estado atual de qualquer negócio.

As empresas de hoje estão imersas em oceanos de dados, vindos de todas as direções, de fontes imagináveis. O BI, então, atua como um farol, transformando esse vasto e muitas vezes caótico volume de dados em informações estruturadas e visualmente intuitivas. Por meio de ferramentas e técnicas especializadas, o BI coleta, processa e apresenta dados em formatos como relatórios e dashboards, permitindo que gestores e decisores tenham uma visão clara e concisa dos seus negócios, identificando tendências, padrões e áreas de oportunidade.

Mas por que o BI é tão importante no contexto da ciência de dados? Bem, se a ciência de dados é o motor que impulsiona a análise avançada, o BI é o painel de controle que oferece uma leitura instantânea e acessível do desempenho em tempo real. Ele se concentra em entregar informações prontas para a ação, tornando os insights acessíveis e acionáveis para todos, desde o nível executivo até as operações do dia a dia.

Neste capítulo, mergulharemos profundamente no mundo do business intelligence. Exploraremos suas ferramentas, seus métodos e a arte do storytelling com dados, bem como a grande importância da visualização de dados no contexto do BI. Entender o papel e o valor do BI nos ajudará a apreciar ainda mais como as diversas áreas que integram a ciência de dados se complementam e como em conjunto moldam o panorama dos negócios orientados por dados no mundo moderno.

1 O que é business intelligence

Business intelligence (BI) é um conjunto integrado de processos, tecnologias e estratégias que converte dados brutos em informações significativas e úteis, permitindo uma análise aprofundada e baseada em evidências para a tomada de decisões estratégicas e operacionais em uma organização (Schaedler, 2021; Sharda; Delen; Turban, 2019). Englobando desde a coleta e limpeza de dados até sua análise, visualização e interpretação, o BI oferece às organizações uma visão clara e acionável do

seu ambiente operacional, capacitando-as a fundamentar decisões tanto em contextos cotidianos quanto em cenários estratégicos de alto nível.

1.1 Origens e evolução

A concepção central de business intelligence – coletar, analisar e aplicar informações para tomar decisões esclarecidas – tem raízes que datam de milênios. Na Antiguidade, civilizações como a dos egípcios antigos já utilizavam métodos primários de registro e análise, mantendo informações meticulosas de colheitas, inundações e transações para prever os melhores períodos para atividades agrícolas e comerciais.

Com a Revolução Industrial no século XIX, a demanda por informação acentuou-se. As empresas da era industrial começaram a reconhecer a necessidade de informações detalhadas para administrar suas crescentes operações, embora essas análises ainda fossem majoritariamente manuais e demoradas. Foi a invenção dos computadores no século XX que revolucionou a coleta, o armazenamento e a análise de dados. As décadas de 1980 e 1990 foram especialmente significativas para o BI, com o surgimento dos primeiros sistemas de apoio à decisão (DSS) e ferramentas de relatório. Estas ferramentas permitiam que empresas visualizassem e analisassem seus dados de formas inovadoras. No início dos anos 2000, com o *boom* digital e a proliferação da internet, a quantidade de dados ao alcance das empresas cresceu exponencialmente. Esse aumento, junto dos avanços nas tecnologias de armazenamento e processamento, consolidou o BI como ferramenta essencial no cenário corporativo. O termo “big data” ganhou destaque (Basso, 2020) e o BI evoluiu, tornando-se a chave para gerenciar e capitalizar esses imensos volumes de informação. Assim, o BI transitou de registros em tábuas de argila para sofisticados dashboards digitais, refletindo a transformação do papel dos dados na tomada de decisões ao longo da história.

1.2 Componentes centrais

O BI e a ciência de dados, embora entrelaçados, têm pontos de ênfase distintos e componentes centrais que diferem em sua abordagem e aplicação (Sharda; Delen; Turban, 2019). A espinha dorsal do BI começa com a coleta de dados, em que informações são colhidas de várias fontes, principalmente focadas em processos de negócios. No mundo da ciência de dados, estes podem ser mais diversificados, vindo de sensores IoT, fluxos de mídia social, entre outros. Após a coleta, o BI foca no processamento e no armazenamento para garantir dados limpos e prontos para análise, normalmente armazenados em data warehouses. Na ciência de dados, o processamento é mais extenso, com ênfase em data lakes, podendo conter dados estruturados e não estruturados. No estágio de análise no BI, os dados são examinados para fornecer insights operacionais e táticos sobre o negócio. Em contraste, a ciência de dados pode empregar técnicas mais avançadas, como aprendizado de máquina e IA, para prever tendências futuras e comportamentos. Finalmente, o BI se concentra fortemente na apresentação por meio de dashboards e relatórios para tomada de decisão rápida. A ciência de dados, enquanto ainda valoriza a visualização, pode ser mais orientada para a implementação de modelos em sistemas ou produtos. Em essência, enquanto o BI é focado em informar decisões de negócios com dados do passado e do presente, a ciência de dados olha para o presente, fazendo previsões e automações para o futuro.

1.3 Importância no mundo moderno

Na era atual, os dados são frequentemente referidos como o “novo petróleo”, de modo que o BI se tornou fundamental para empresas de todos os tamanhos e setores. Ele fornece uma vantagem competitiva, ajudando as empresas a entender seu ambiente operacional, a identificar oportunidades de mercado, a otimizar processos e a prever desafios

futuros. Em um mundo que está em constante mudança, em que a agilidade é essencial, o BI serve como os olhos e ouvidos das organizações, garantindo que elas estejam sempre um passo à frente.

2 Ferramentas de BI

No universo corporativo contemporâneo, as ferramentas de business intelligence surgem como elementos vitais. Estes softwares, projetados especificamente para coletar, processar, analisar e apresentar dados de negócios, servem como pontes, transformando volumes massivos de dados em insights relevantes, os quais sustentam a tomada de decisões informadas.

O leque de ferramentas de BI é vasto. Existem ferramentas de relatório, como o SQL Server Reporting Services (SSRS), voltadas para elaboração, publicação e distribuição de relatórios detalhados. Já as ferramentas de dashboard, como Tableau e Power BI, focam em oferecer visualizações gráficas instantâneas de indicadores-chave de desempenho (KPIs). Para mergulhos mais profundos em conjuntos de dados, ferramentas de análise como QlikView e TIBCO Spotfire são essenciais, permitindo explorações *ad hoc* e análises avançadas. E, claro, há as ferramentas ETL, como Talend e Informatica PowerCenter, que são cruciais na preparação de dados para as análises subsequentes.



IMPORTANTE

Tableau é uma das ferramentas de visualização de dados e BI mais renomadas do mercado, reconhecida por sua capacidade intuitiva de transformar grandes conjuntos de dados em insights visuais impactantes. Com uma abordagem simplificada, utilizando recursos como arrastar e soltar, ele democratiza a análise de dados, permitindo que profissionais de diversas áreas extraiam valor de seus dados sem a necessidade de conhecimento profundo em programação. Além disso, sua capacidade de se integrar a uma ampla variedade de fontes de dados e sua

escalabilidade tornam o Tableau a escolha preferida de empresas de todos os tamanhos que buscam otimizar suas estratégias de BI. Entre no link e descubra mais: <https://public.tableau.com/app/discover> (Tableau Public, 2023).

Além das ferramentas tradicionais de BI, as linguagens de programação têm ganhado destaque no panorama de análise de dados. Elas oferecem flexibilidade e personalização que muitos softwares convencionais podem não proporcionar. O Python é um exemplo emblemático, pois essa linguagem, apoiada por bibliotecas poderosas como pandas (manipulação de dados), Matplotlib e Seaborn (visualização) e scikit-learn (aprendizado de máquina), se estabeleceu como um pilar na análise de dados moderna. Outras linguagens, como R e Java, entretanto, também desempenham papéis significantes em diferentes nichos da análise de dados.

A decisão sobre qual ferramenta ou linguagem de BI adotar deve ser realizada com cuidado, considerando uma variedade de fatores, desde as demandas específicas do negócio até a facilidade de uso e integração com sistemas já existentes. Vale lembrar que enquanto algumas ferramentas são mais amigáveis para usuários não técnicos, linguagens de programação, como Python, podem requerer uma dedicação maior para a obtenção de resultados otimizados.

Olhando para o horizonte, a arena de BI está em constante transformação, impulsionada pela integração crescente de inteligência artificial, machine learning e automação. Assim, enquanto o cenário de BI continua evoluindo, a intersecção entre softwares tradicionais e linguagens de programação se torna cada vez mais proeminente, garantindo que as empresas tenham uma variedade de opções para enfrentar desafios presentes e futuros.

3 Storytelling

O ato de contar histórias é uma arte antiga, profundamente enraizada na natureza humana. É a maneira como compartilhamos experiências, transmitimos conhecimentos e conectamos emoções. No mundo dos negócios e da análise de dados, o storytelling assume um papel crucial, servindo como a ponte entre complexos conjuntos de informações e decisões informadas (Knafllic, 2019).

O storytelling em business intelligence refere-se ao processo de criar uma narrativa convincente em torno dos dados, transformando números brutos e tabelas em histórias que têm impacto, relevância e são facilmente compreensíveis. O principal objetivo é simplificar o que é complexo, realçando os insights mais importantes e apresentando-os de forma que dialoguem com o público-alvo, seja ele um executivo, um cliente ou uma equipe inteira.

Existem algumas etapas essenciais no processo de storytelling com dados. Primeiro, é fundamental entender o público e o que ele precisa saber, pois isso ajuda a moldar a narrativa e a focar nos pontos mais relevantes. Em seguida, é importante selecionar os dados certos, aqueles que efetivamente sustentam a história que se deseja contar. A visualização de dados, então, entra como um elemento-chave: gráficos, diagramas e dashboards bem elaborados podem ilustrar pontos cruciais, facilitando a compreensão e a retenção da mensagem. Por fim, a narrativa deve ser construída de forma lógica, guiando o público por meio dos insights, resultando em uma conclusão ou em um chamado à ação.

Uma das maiores forças do storytelling é a sua capacidade de evocar emoções e criar conexões pessoais. Em BI, essa habilidade se traduz na capacidade de fazer com que os dados “falem” ao público, tornando a informação mais memorável e persuasiva. Além disso, um bom storytelling pode facilitar a tomada de decisões, pois as informações essenciais são destacadas e apresentadas de forma clara.

Como qualquer ferramenta poderosa, entretanto, o storytelling também possui suas armadilhas. A narrativa não deve distorcer ou manipular os dados para se encaixar em um argumento pré-concebido. A integridade e a precisão dos dados sempre devem ser mantidas, garantindo que a história contada seja verdadeira e representativa da realidade.

Em resumo, o storytelling em BI é muito mais do que apenas relatar fatos e números. É criar uma conexão emocional com o público, apresentando dados de uma forma que seja relevante, compreensível e, acima de tudo, impactante. Neste contexto, ferramentas e técnicas modernas de BI, como visualização de dados e análise interativa, desempenham um papel fundamental, enriquecendo e aprimorando a capacidade de contar histórias com dados.

4 Visualização de dados

A visualização de dados é a arte e a ciência de representar informações de maneira gráfica, permitindo que complexos conjuntos de dados sejam interpretados, analisados e comunicados de forma eficiente e intuitiva (Milani, 2020). Em um mundo repleto de informações, a capacidade de visualizar dados de maneira inteligível e coerente é mais determinante do que nunca. O cérebro humano é excepcionalmente adaptado para processar informações visuais. Neste contexto, gráficos, tabelas e outros métodos de visualização desempenham um papel fundamental, permitindo que tomemos decisões rápidas e informadas, com base em dados que, de outra forma, seriam difíceis de compreender.

4.1 Princípios da visualização de dados

A principal função de qualquer visualização é comunicar a informação de forma compreensível, ou seja, busca-se evitar distorções, reduzir o ruído e garantir que o público possa entender a mensagem principal sem dificuldades. Além disso, muitas vezes a simplicidade é a chave para a


eficácia. Gráficos complicados ou sobrecarregados podem confundir mais do que esclarecer. Cada elemento de uma visualização deve ter um propósito, assim, elementos desnecessários, que não adicionam valor à compreensão, devem ser evitados. A cor pode ser uma ferramenta poderosa para destacar, diferenciar e categorizar. No entanto, é essencial usar cores com propósito e cuidado, garantindo que a visualização permaneça acessível e a interpretação não seja prejudicada. Por fim, as visualizações interativas, que permitem aos usuários explorar os dados por conta própria, podem oferecer insights mais profundos e personalizados.

Existem várias ferramentas disponíveis para criar visualizações de dados, variando em complexidade e funcionalidade. Ferramentas como Tableau e Power BI são líderes no campo de BI e oferecem uma ampla gama de opções para visualização. Por outro lado, linguagens de programação, como Python e R, com bibliotecas como Matplotlib, Seaborn e Pyplot, oferecem flexibilidade para criações mais personalizadas.


4.2 Tipos de gráficos

Cada tipo de gráfico é adequado para visualizar determinado aspecto dos dados. A seguir, vamos explorar alguns dos principais tipos.

O histograma é uma representação gráfica de uma distribuição de dados. Ele divide o conjunto de dados em uma série de intervalos contíguos e mostra a quantidade de pontos de dados que caem em cada intervalo. É utilizado principalmente para entender a distribuição de um conjunto de dados unidimensional, identificando padrões como simetria, assimetria, picos e outliers. Já o KDE é uma técnica não paramétrica para estimar a função de densidade de probabilidade de uma variável aleatória. Ela produz uma curva suave que é uma aproximação da distribuição dos dados. Semelhante ao histograma, o KDE é utilizado para visualizar a distribuição de dados; contudo, ao contrário do histograma, que é discreto, o KDE fornece uma visualização contínua e suave. O histograma e o KDE muitas vezes são representados em conjunto.

Gráfico 1 – Histograma


O gráfico de linha utiliza linhas contínuas para representar dados ao longo de um eixo comum, que geralmente é o tempo. É comumente utilizado para visualizar tendências ao longo do tempo ou sequências ordenadas.

Gráfico 2 – Gráfico de linha

Um gráfico de barras, por sua vez, representa dados por meio de retângulos verticais ou horizontais, em que o comprimento de cada retângulo


é proporcional ao valor representado. Muito utilizado para comparar quantidades de diferentes categorias ou grupos.

Gráfico 3 – Gráfico de barras




O *scatterplot*, ou gráfico de dispersão, mostra pontos individuais plotados em um espaço de duas dimensões, nos quais os valores de duas variáveis determinam a posição de cada ponto. Ideal para visualizar a relação ou correlação entre duas variáveis quantitativas e como essa correlação é determinada de forma espacial.

Gráfico 4 – Scatterplot



O *boxplot* representa a distribuição de dados por meio de quartis, mostrando os valores mínimo, primeiro quartil, mediana, terceiro quartil e máximo. Ele é ideal para visualizar a dispersão e a presença de outliers em um conjunto de dados. Já o *violinplot* combina aspectos do *boxplot* e do KDE. Ele mostra a distribuição de dados por meio de densidades em ambos os lados de um eixo e é útil para visualizar a distribuição de dados ao longo de uma variável categórica, dando uma noção da densidade e da distribuição dos dados.




Um *heatmap* representa dados em formato de matriz usando cores para indicar as magnitudes dos valores apresentados. É comumente usado para visualizar matrizes de correlação ou dados tabulares, quando estes compartilham alguma relação de ordem.

Gráfico 6 – Mapa de calor



Por fim, o *pairplot* mostra gráficos de pares para todas as combinações possíveis de variáveis numéricas em um dataframe em forma de gráfico de dispersão e gráfico de linha. Ele também suporta uma opção para colorir os pontos por uma variável categórica. É muito útil para uma visualização rápida das relações entre variáveis.

Gráfico 7 – Pairplot



5 Hands-on: BI e DataViz na prática


Vamos explorar aqui o BI e a visualização de dados por meio de um projeto importante para o contexto brasileiro: a análise de incêndios florestais no país. Os incêndios florestais representam um desafio significativo para a preservação de nossos ecossistemas e para a segurança das comunidades. Com o auxílio da ciência de dados, temos a oportunidade de examinar o número de ocorrência de cada evento, assim como seu foco e sua sazonalidade, e com base nisso, facilitar o desenvolvimento de soluções.

Para esse projeto, utilizaremos uma base de dados presente no Kaggle sobre o tema. Vamos tentar formular e responder a algumas perguntas

específicas. Em qual mês e ano foram registrados mais incêndios? Qual total de incêndios registrados nos estados da Amazônia Legal?

Como resposta à primeira pergunta, podemos criar gráficos de linha com a soma dos números de incêndio registrados em cada linha de dados separados por mês e ano. Já para a segunda, é possível fazer um gráfico de barras com cada estado da Amazônia Legal. Podemos desenvolver essas visualizações, inclusive de forma interativa, usando o Tableau.

Figura 1 – Demonstração da criação de gráficos com Tableau



PARA SABER MAIS

No Tableau é possível compartilhar de forma on-line e pública as visualizações geradas, permitindo a interação dos leitores. Você pode acessar os gráficos gerados neste capítulo no link: <https://public.tableau.com/app/profile/poliana.ferreira/viz/IncndiosnoBrasil-1990a2017/Painel1> (acesso em: 20 nov. 2023). Fonte: Ferreira (2023).

Observamos, então, que há maior necessidade de atenção para os incêndios florestais entre os meses de julho e novembro, especialmente para incêndios pontuais no estado do Mato Grosso. Percebemos também que os incêndios tiveram tendência crescente com o passar dos anos. Para entender de fato quais medidas tomar, seria necessário ter mais dados, como o tamanho e a área do incêndio, a gravidade dos prejuízos ambientais e as causas.

Considerações finais

Ao longo deste capítulo, navegamos pelas profundezas do business intelligence, destacando sua inestimável importância no universo da ciência de dados. Conforme apreendemos, o BI não é apenas uma ferramenta, é um guia essencial que ilumina o caminho em um mundo saturado de dados, oferecendo clareza e direção aos negócios modernos.

Conhecemos as variadas ferramentas e os métodos que o BI emprega, bem como a arte sofisticada do storytelling com dados, que relata e contextualiza os fatos, permitindo decisões mais informadas e estratégicas. A visualização de dados, por sua vez, se apresentou como uma força poderosa, tornando as informações ao mesmo tempo compreensíveis e visualmente atraentes e persuasivas.

É essencial destacar que, enquanto a ciência de dados e o business intelligence podem operar independentemente, sua verdadeira potência é revelada quando atuam em sinergia. O BI traduz as análises avançadas da ciência de dados em linguagem acessível, tornando as descobertas úteis para tomadores de decisão em todos os níveis hierárquicos de uma organização.

Referências

BASSO, Douglas Eduardo. **Big data**. Curitiba: Contentus, 2020. *E-book*.

FERREIRA, Poliana N. Incêndios no Brasil - 1990 a 2017. **Tableau Public**. Seattle, WA, USA, 9 out. 2023. Disponível em: <https://public.tableau.com/app/profile/poliana.ferreira/viz/IncndiosnoBrasil-1990a2017/Painel1>. Acesso em: 23 out. 2023.

KNAFLIC, Cole Nussbaumer. **Storytelling com dados**: um guia sobre visualização de dados para profissionais de negócios. Rio de Janeiro: Alta Books, 2019.

MILANI, Alessandra Maciel Paz *et al.* (org.). **Visualização de dados**. Porto Alegre: Sagah, 2020.

SCHAEDLER, Andrew; MENDES, Giselly Santos. **Business intelligence**. Curitiba: InterSaber, 2021.

SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business intelligence e análise de dados para gestão do negócio**. Tradução: Ronald Saraiva de Menezes. 4. ed. Porto Alegre: Bookman, 2019.

TABLEAU PUBLIC. Bem-vindo(a) ao Tableau Public. Seattle, WA, USA, 2023. Disponível em: <https://public.tableau.com/app/discover>. Acesso em: 23 out. 2023.

A ética na ciência de dados

A ciência de dados se estabeleceu como uma ferramenta indispensável na decodificação e na compreensão de vastos conjuntos de dados das pessoas no geral. No entanto, à proporção que nos profundamos nas complexidades e potencialidades desta disciplina, surge uma questão incontornável: a ética. Não se trata apenas de entender o que *pode* ser feito com os dados, mas sim o que *deve* ser feito com eles. Essas questões estão em constante discussão e ainda não foram resolvidas, sendo importante que todos, em conjunto, reflitam e pensem nas melhores soluções.

A capacidade de coletar, analisar e tomar decisões com base nos dados carrega consigo o peso de expressivas responsabilidades éticas. Afinal, por trás de números e padrões, há histórias humanas, privacidade e direitos que não podem ser negligenciados. Assim, à medida que a ciência de dados avança, enfrentamos dilemas éticos inéditos que desafiam nossas concepções tradicionais de privacidade, consentimento e justiça.

A questão ética na ciência de dados não é somente um tópico de debate acadêmico, mas uma preocupação prática e urgente para profissionais, empresas e a sociedade em geral. Decisões equivocadas ou uso irresponsável dos dados podem ter consequências reais e duradouras para indivíduos e comunidades. Portanto, é imperativo que também abordemos seu contexto ético, garantindo um equilíbrio entre inovação e responsabilidade.

1 A ética e a privacidade em ciência de dados

A privacidade, em sua essência, é um direito fundamental do ser humano. No entanto, na era digital, o conceito de privacidade foi desafiado e redefinido em razão da expansão da capacidade de coletar, armazenar e analisar dados em escala sem precedentes. Na intersecção entre a ciência de dados e a privacidade, surgem importantes considerações éticas que buscam equilibrar os benefícios do avanço tecnológico com os direitos e a dignidade dos indivíduos (Grus, 2016).

1.1 Consentimento informado

O consentimento informado é um conceito fundamental em muitas disciplinas, desde a medicina até a pesquisa social. Na ciência de dados, sua relevância não é menor. À medida que o mundo digital cresce, torna-se essencial que os usuários compreendam e concordem ativamente com a coleta e uso de seus dados. O consentimento informado, neste contexto, refere-se ao processo pelo qual um usuário é informado sobre como seus dados serão usados e, em seguida, dá sua permissão explícita para essa utilização (Grus, 2016).

O consentimento não deve ser genérico, ou seja, se os dados coletados serão usados para várias finalidades, cada uma delas deve ser

claramente explicada e o consentimento deve ser solicitado para cada propósito individualmente. Além disso, se a maneira como os dados são usados muda ou se expande além do escopo original do consentimento, os usuários devem ser informados novamente e um novo consentimento deve ser obtido.

Outra questão importante é como garantir que os usuários realmente leiam e entendam as informações passadas a eles sobre os usos dos dados, uma tarefa nada fácil. Desaconselha-se a utilização de jargões técnicos, ou que a adesão aos termos seja apenas uma caixa de seleção em uma longa lista de condições necessárias. A melhor forma de repassar essas informações ainda é um desafio, uma vez que, em geral, quando sobrecarregamos o usuário com informações excessivas, ele tende a não ler. Afinal, quem de nós já não assinalou um “Li e aceito os termos de consentimento” sem de fato ter lido, mesmo que fosse obrigatório passar por todo o termo rolando a página até o final?

1.2 Minimização de dados

Minimização de dados refere-se ao princípio de coletar, processar e armazenar apenas os dados estritamente necessários para atingir o propósito específico para o qual foram solicitados. Em um ambiente digital em que a coleta e o armazenamento de grandes volumes de dados é facilmente acessível, a minimização de dados emerge como uma prática essencial para garantir a privacidade e a proteção dos dados dos usuários.

Um dos benefícios mais diretos da minimização de dados é a redução do risco. Quanto menos dados uma organização mantém, menor é a exposição em caso de violações de dados. Em situações de vazamento, a quantidade de informações sensíveis expostas é diretamente proporcional à quantidade de dados armazenados (Basso, 2020). Outro benefício que podemos citar é que, ao se concentrar apenas em dados

pertinentes, as empresas podem garantir análises mais precisas e orientadas. Além disso, os usuários se sentem mais seguros sabendo que suas informações não estão sendo coletadas sem um propósito claro, aumentando sua confiança na empresa.

Entretanto, assim como no consentimento, determinar o que é “estritamente necessário” pode ser subjetivo e variar de acordo com o setor ou a aplicação. As organizações podem enfrentar desafios ao tentar assegurar uma coleta de dados suficiente para fornecer serviços personalizados ou insights profundos enquanto aderem ao princípio da minimização.

1.3 Transparência

Transparência refere-se à clareza e à abertura com que as organizações comunicam suas práticas relacionadas a coleta, processamento, armazenamento e compartilhamento de dados. Ela perpassa a questão do consentimento informado e do acesso e controle dos dados pelos usuários, ou seja, parte da transparência é permitir que os usuários tenham acesso aos seus próprios dados e controle sobre como eles serão usados. Também pode incluir a capacidade de visualizar, editar, transferir ou excluir suas informações pessoais. Ademais, a transparência exige que as organizações expliquem, pelo menos em termos gerais, como os algoritmos de análise descritiva, preditiva e prescritiva funcionam e quais fatores influenciam suas decisões (Russel; Norvig, 2022).

1.4 Direito ao esquecimento na era digital

Conceito emergente em proteção de dados e privacidade que se refere ao direito de indivíduos solicitarem a remoção de informações pessoais de sites, bancos de dados e resultados de busca, especialmente quando essas informações são obsoletas, irrelevantes ou prejudiciais. Embora tenha raízes em certas jurisdições, sua atual relevância é amplamente

impulsionada pela proliferação digital e pela capacidade quase infinita da internet de reter e recuperar informações.

O direito ao esquecimento ganhou destaque principalmente na Europa com o Regulamento Geral sobre a Proteção de Dados (RGPD). Um caso marcante envolveu um cidadão espanhol que solicitou ao Google a remoção de links para um artigo antigo sobre a venda forçada de sua propriedade para liquidar dívidas. O Tribunal de Justiça da União Europeia decidiu a favor do cidadão, estabelecendo um precedente importante.

Um dos principais desafios do direito ao esquecimento é equilibrá-lo com o direito à liberdade de expressão e o interesse público. Não se trata de reescrever a história ou de impedir o jornalismo legítimo, mas de proteger os direitos individuais nos quais a informação não tem valor público claro. Também, do ponto de vista técnico, garantir o direito ao esquecimento pode ser desafiador. Esse direito envolve não apenas remover links ou referências de sites, mas também garantir que os dados sejam apagados de backups, caches e outros locais onde possam ser armazenados. Por fim, com o aumento da inteligência artificial e da análise profunda de dados, o direito ao esquecimento ganhará ainda mais relevância. Como garantimos que os dados esquecidos não sejam usados para treinar modelos de aprendizado de máquina ou para análises futuras?

1.5 Anonimização

A anonimização é uma abordagem essencial na proteção da privacidade dos dados, transformando as informações de modo que não possam ser associadas a um indivíduo específico (Grus, 2016; Russel; Norvig, 2022). No mundo dominado pelos dados, em que cada clique, compra ou interação on-line pode ser registrado, a necessidade de proteger a identidade das pessoas é vital. Ao mesmo tempo, para organizações e pesquisadores é crucial acessar padrões e tendências dentro desses

conjuntos de dados. É aqui que a anonimização entra como uma ponte entre a privacidade e a utilidade.

Vamos ilustrar com um exemplo: imagine que uma clínica médica deseja compartilhar informações sobre os pacientes para um estudo sobre diabetes. A lista original pode ter informações como: [João Silva, 28 anos, São Paulo, diabetes tipo 2], [Maria Oliveira, 45 anos, Rio de Janeiro, diabetes tipo 1]. Para proteger a privacidade dos pacientes, a clínica pode anonimizar os dados antes de compartilhá-los. O conjunto de dados anonimizado pode parecer como: [Paciente 001, faixa etária 25-30, região Sudeste, diabetes tipo 2], [Paciente 002, faixa etária 40-50, região Sudeste, diabetes tipo 1].

Neste exemplo, as informações pessoais identificáveis, como nome, idade exata e estado, são substituídas ou generalizadas, tornando quase impossível identificar os indivíduos específicos. No entanto, os dados ainda retêm sua utilidade para o estudo, pois as características relevantes, como o tipo de diabetes e a faixa etária, permanecem intactas. Em resumo, a anonimização é como um filtro, preservando a utilidade dos dados enquanto protege a identidade, permitindo que organizações e pesquisadores acessem insights valiosos sem comprometer a privacidade dos indivíduos envolvidos.

2 O mau uso de informações derivadas de dados e metadados

Na era digital, enquanto nos beneficiamos do acesso instantâneo a informações e da interconexão global, também nos deparamos com o lado sombrio do uso indevido de informações. A imensa quantidade de dados que produzimos não diz respeito apenas ao conteúdo explícito, mas também aos metadados, informações sutis que detalham, por exemplo, quando e de onde um conteúdo foi gerado (Basso, 2020; Sharda; Delen; Turban, 2019).

Uma das facetas desse uso indevido é observada na área do marketing. A publicidade direcionada, por exemplo, pode parecer útil inicialmente, fornecendo anúncios mais relevantes. No entanto, torna-se preocupante quando, após uma simples pesquisa on-line sobre um produto, somos inundados por anúncios desse mesmo produto em quase todas as plataformas digitais que visitamos. Ou ainda, quem nunca suspeitou que o smartphone ou o assistente virtual escutou o que falamos, pois algumas horas depois esse produto estava sendo anunciado em nossas redes sociais ou e-mails?

Ainda mais alarmante é o uso de metadados. Um exemplo é o uso de informações de localização para monitorar indivíduos. Existem relatos de aplicativos de namoro sendo explorados por *stalkers* (alguém que segue obsessivamente outra pessoa, invadindo sua privacidade) utilizando dados de localização fornecidos pelo próprio aplicativo. Na área comercial, as implicações podem ser igualmente preocupantes. Algumas empresas recorrem a preços dinâmicos com base nas informações do usuário, por exemplo, mostrando preços mais altos para uma passagem aérea simplesmente porque a pesquisa foi feita em um smartphone mais recente.

Em um nível mais sistêmico, os sistemas automatizados de tomada de decisão, se alimentados com dados tendenciosos, podem perpetuar discriminações. Um algoritmo de contratação, por exemplo, poderia favorecer inadvertidamente um gênero sobre o outro, com base em dados históricos. Além, também, das complexas teias de manipulação em massa de opiniões dos usuários, muito utilizadas em questões políticas.

E, por fim, há o mercado da venda de dados. A ideia de que nossos dados, coletados muitas vezes sem nosso consentimento claro, podem ser vendidos para terceiros é uma preocupação crescente. Aplicativos que usamos diariamente, especialmente aqueles que são “gratuitos”, muitas vezes ganham dinheiro vendendo nossos hábitos, preferências e outros dados para empresas de publicidade ou corretores.

Todos esses exemplos reforçam a necessidade urgente de uma abordagem ética e regulamentada referente a coleta e uso de dados, uso de metadados e privacidade. A tecnologia pode estar avançando rapidamente, mas devemos garantir que a ética e a responsabilidade não sejam abandonadas como nos exemplos e situações mencionados.

3 LGPD, *compliance*, data protection officer, data governance

Para garantir que a coleta, o processamento e o armazenamento de dados ocorram de maneira ética e responsável, surgiram novas regulamentações, práticas e funções. Entre as mais significativas estão a Lei Geral de Proteção de Dados (LGPD), as práticas de *compliance*, o papel do data protection officer (DPO) e a implementação de data governance.

3.1 LGPD

A Lei Geral de Proteção de Dados (LGPD), promulgada como Lei nº 13.709 em agosto de 2018 e que entrou em vigor em setembro de 2020 no Brasil, tornou-se um marco na abordagem da privacidade de dados no país (Brasil, 2018). Concebida para proteger os direitos fundamentais de liberdade e privacidade dos brasileiros, a LGPD surge no contexto de um cenário global que reconhece cada vez mais a importância dos dados pessoais. A lei é clara ao estipular princípios fundamentais para o tratamento desses dados, como a finalidade legítima e específica, a transparência no uso e a necessidade de se limitar ao mínimo requerido.

Por outro lado, o indivíduo, titular dos dados, ganha protagonismo, tendo direito a acessar, corrigir e até mesmo pedir a eliminação de suas informações, além de poder se informar sobre o compartilhamento desses dados e de revogar o consentimento dado. Com a LGPD, as

organizações também passam a ter responsabilidades mais claras. A figura do *controlador*, que decide como os dados são tratados, e do *operador*, que efetivamente realiza o tratamento, emerge, exigindo uma estruturação mais sólida e transparente das operações usando dados.

A introdução de sanções, que incluem multas significativas, reforça o compromisso com a conformidade. E para supervisionar e garantir que a lei seja cumprida, foi instituída a Autoridade Nacional de Proteção de Dados (ANPD). Esta entidade atua como um regulador, garantindo que os direitos dos titulares de dados sejam respeitados e aplicando penalidades quando necessário. Assim, a LGPD não somente alinha o Brasil com padrões internacionais de proteção de dados, como também envia uma mensagem clara às empresas e instituições sobre a importância da privacidade no mundo moderno. Adotar suas diretrizes é uma necessidade legal e um indicativo de respeito e transparência para com os cidadãos.

3.2 *Compliance*

Compliance, originário do verbo inglês *to comply*, traduz a ideia de agir em conformidade com regras e diretrizes estabelecidas. Dentro das corporações, o *compliance* não se restringe a seguir leis; ele engloba a criação e a manutenção de políticas internas, garantindo que os colaboradores estejam cientes e alinhados às expectativas da empresa. Essas práticas envolvem treinamentos contínuos, monitoramento das atividades e implementação de canais de comunicação para reportar possíveis desvios de conduta. Em caso de irregularidades, um bom programa de *compliance* busca não apenas corrigir o problema, mas também entender suas causas e prevenir reincidências. Os benefícios são inúmeros. Além de proteger a empresa de riscos legais e regulatórios, fortalece a cultura organizacional, promove eficiência nas operações e constrói uma imagem positiva perante os stakeholders e o mercado. Vale destacar que, dependendo do setor de atuação, as exigências de *compliance* podem

ser mais rigorosas. Por exemplo, indústrias como a financeira ou a de saúde possuem regulamentações específicas dadas as particularidades e sensibilidades de suas operações.

3.3 Data protection officer

O data protection officer (DPO) é imprescindível para garantir a conformidade com as legislações de proteção de dados em vigor. Este profissional tem como função o monitoramento e a aplicação de procedimentos e políticas internas relacionados à coleta, processamento e armazenamento de dados. O DPO atua como intermediário entre a entidade de tratamento de dados (seja ela organização ou empresa) e as autoridades supervisoras, garantindo a comunicação transparente e imediata sobre questões regulatórias. Uma das funções primordiais do DPO é a condução de avaliações de impacto à proteção de dados (AIPD), especialmente quando novas técnicas de processamento ou tecnologias são incorporadas, assegurando a identificação, quantificação e mitigação de riscos associados. Além disso, o DPO é responsável por assegurar a conformidade contínua, o que envolve a orientação sobre implementações tecnológicas e procedimentais, bem como a capacitação regular dos colaboradores sobre padrões e boas práticas em proteção de dados.

Para desempenhar eficazmente suas funções, o DPO deve possuir *expertise* em regulamentações de proteção de dados, além de conhecimentos aprofundados em áreas correlatas, como sistemas de informação, cibersegurança e direito. Esse profissional deve garantir também uma atuação isenta, evitando conflitos de interesse, o que implica em autonomia em sua função e decisões, livre de influências organizacionais que possam comprometer a integridade dos dados.

3.4 Data governance

A governança de dados estabelece uma estrutura organizacional para aquisição, armazenamento e uso de dados. Para ilustrar, considere que uma empresa colete dados de clientes. Com políticas claras de governança, ela especificará padrões técnicos, como a formatação consistente de metadados e a utilização de taxonomias padronizadas, para que os dados de diferentes departamentos sejam compatíveis. Mecanismos como trilhas de auditoria seriam empregados para rastrear quem acessou ou alterou um registro específico. Em relação à conformidade, a governança trataria de adesão às leis do país no qual a empresa está atuando, adotando práticas como solicitar consentimento antes de coletar dados e fornecer opções de exclusão. Por fim, a governança garantiria que equipes de marketing ou vendas, por exemplo, pudessem acessar informações relevantes dos clientes para suas operações de forma protegida e de acordo com todas as práticas e padrões mencionados.

4 Cases

Infelizmente, a ocorrência de problemas resultantes da utilização imprópria de dados de usuários é comum. Empresas e instituições, ávidas por insights que possam dar vantagens competitivas, muitas vezes coletam e armazenam mais informações do que realmente precisam ou têm capacidade de proteger adequadamente. Tais ações, por si só, criam ambientes propícios para falhas de segurança e brechas que podem ser exploradas por agentes mal-intencionados. O cenário reforça a necessidade urgente de medidas mais rigorosas, educação contínua e uma abordagem mais ética em relação a coleta, processamento e armazenamento de informações pessoais. Nesse subcapítulo serão apresentados dois cases importantes de mau uso e falhas de privacidade no contexto de dados.

4.1 Cambridge Analytica

A Cambridge Analytica, uma empresa de consultoria política com sede no Reino Unido, utilizou-se de dados obtidos a partir do Facebook para criar perfis psicográficos de milhões de eleitores americanos. Estes perfis foram posteriormente utilizados para direcionar publicidade política de forma estratégica durante a campanha presidencial dos Estados Unidos em 2016 (France Presse, 2019).

A raiz do escândalo reside no modo como a Cambridge Analytica obteve os dados. Um aplicativo de quiz, denominado Thisisyourdigitallife, foi criado por um pesquisador e proposto como ferramenta acadêmica no Facebook. Embora cerca de 270.000 pessoas tenham dado consentimento para compartilhar seus dados com este aplicativo, o programa também acessou informações de todos os amigos desses usuários, expandindo o alcance para milhões de indivíduos que não deram consentimento direto. Este é um exemplo flagrante de falta de transparência e violação de privacidade.

Além de coletar dados diretamente do usuário, o aplicativo extraiu metadados, como curtidas e interações. Esses metadados, quando analisados, revelaram padrões de comportamento, preferências políticas, crenças religiosas, entre outras informações. A Cambridge Analytica usou esses metadados para ampliar sua capacidade de segmentar e influenciar eleitores específicos.

Na época do escândalo, legislações sobre proteção de dados, como a RGPD na Europa, ainda estavam em seus estágios iniciais. Contudo, o incidente acelerou o debate sobre a necessidade de regulamentações mais rígidas. Se conceitos como direito ao esquecimento, anonimização e minimização de dados tivessem sido aplicados, o escopo da coleta de dados poderia ter sido muito mais limitado. A falta de um efetivo data protection officer ou de uma robusta estrutura de governança de dados permitiu que tal violação ocorresse em grande escala. O escândalo da

Cambridge Analytica não foi apenas uma falha técnica ou um erro operacional, mas sim um sinal de alerta sobre os perigos inerentes à era digital e a responsabilidade que empresas, governos e indivíduos têm na proteção e uso ético dos dados.

4.2 Vazamento de dados de 220 milhões de brasileiros

Em janeiro de 2021, o Brasil foi palco de um dos maiores vazamentos de dados de sua história. Informações de aproximadamente 220 milhões de brasileiros, incluindo indivíduos já falecidos, foram encontrados à venda em fóruns da dark web (Rohr, 2021). Esse número excede a própria população do Brasil, sugerindo que algumas pessoas podem ter tido mais de um registro vazado.

Os dados expostos eram abrangentes e sensíveis. Incluíam informações básicas como nome, CPF e data de nascimento, mas em muitos casos iam além, abarcando títulos eleitorais, informações sobre veículos, níveis de escolaridade, benefícios do INSS, entre outras. Tal amplitude e profundidade de informações tornam esse vazamento especialmente alarmante, já que fornecem um panorama muito completo sobre cada indivíduo afetado.

A origem precisa do vazamento não foi determinada de imediato. Havia especulações de que os dados poderiam ter vindo de alguma entidade governamental ou de grandes empresas privadas. Independentemente da fonte, a magnitude do incidente evidenciou uma grave falha de segurança e gerou preocupações significativas sobre as consequências a longo prazo para os cidadãos afetados. Diversas autoridades e organizações de segurança cibernética no Brasil iniciaram investigações para rastrear a origem do vazamento e determinar a causa exata. Entre as possíveis causas especuladas estavam falhas de segurança, ataques de *hackers*, acesso indevido por funcionários ou terceiros, entre outras.

É importante ressaltar que os vazamentos de dados podem ser o resultado de uma combinação de fatores, incluindo vulnerabilidades técnicas, falhas humanas e ações maliciosas. No caso deste vazamento específico, dada sua magnitude, é provável que houvesse um nível significativo de sofisticação envolvido.

O incidente ocorreu em um momento crítico para a proteção de dados no Brasil pouco tempo após a Lei Geral de Proteção de Dados ter entrado em vigor. A LGPD foi criada para fortalecer a privacidade e proteção de dados pessoais dos cidadãos brasileiros, e o vazamento serviu como um lembrete contundente da urgência dessas medidas. O caso enfatizou a necessidade de empresas e instituições adotarem uma postura proativa em relação à segurança de dados, realizando auditorias regulares, investindo em infraestrutura e treinamento, e estabelecendo protocolos rigorosos para prevenir, detectar e responder a incidentes de segurança. Para os cidadãos, o vazamento foi um alerta sobre os riscos associados à exposição de dados pessoais. Muitos se voltaram para serviços de proteção de identidade, começaram a monitorar mais atentamente suas contas bancárias e adotaram medidas para se proteger contra possíveis golpes, fraudes e outras atividades maliciosas que poderiam surgir a partir do uso indevido dessas informações. Ainda hoje, o vazamento de 2021 é citado como um marco no cenário brasileiro de segurança cibernética, reforçando a necessidade constante de vigilância e ação no mundo digital em rápida evolução.

Considerações finais

Neste capítulo, abordamos a ética na ciência de dados e sua importância crescente em um mundo altamente digitalizado. Destacamos o papel da privacidade, evidenciado por conceitos como consentimento informado e direito ao esquecimento. O vazamento de dados de 220 milhões de brasileiros salientou os riscos inerentes às falhas de segurança e a necessidade de uma governança de dados consistente.

A LGPD surge como resposta regulatória para proteger os direitos dos cidadãos no que se refere a seus dados. No entanto, a mera existência de uma lei não é garantia de sua aplicação efetiva. Papéis como o do data protection officer e práticas de governança de dados são essenciais para assegurar o cumprimento das normas e os princípios éticos.

Os exemplos citados, como o caso da Cambridge Analytica, mostram as consequências do uso inadequado de dados. Eles ressaltam a necessidade de um compromisso contínuo com práticas éticas na coleta, análise e uso de dados. À medida que a ciência de dados se torna mais integrada às nossas vidas, o peso da responsabilidade sobre os profissionais da área cresce. É imperativo que essa responsabilidade seja reconhecida com esforços direcionados para garantir a integridade, a transparência e o respeito em todas as etapas do processo de trabalho com dados, protegendo sempre os direitos e a dignidade dos indivíduos.

Referências

BASSO, Douglas Eduardo. **Big data**. Curitiba: Contentus, 2020. *E-book*.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). **Diário Oficial da União**: seção 1, Brasília, DF, p. 59, 15 ago. 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 12 set. 2023.

FRANCE PRESSE. Cambridge Analytica se declara culpada em caso de uso de dados do Facebook. **G1**, [s. l.], 9 jan. 2019. Disponível em: <https://g1.globo.com/economia/tecnologia/noticia/2019/01/09/cambridge-analytica-se-declara-culpada-por-uso-de-dados-do-facebook.ghtml>. Acesso em: 15 out. 2023.

GRUS, Joel. **Data science do zero**. Tradução: Wellington Nascimento. Rio de Janeiro: Alta Books, 2016. *E-book*.

ROHR, Altieres. Megavazamentos de dados expõem informações de 223 milhões de números de CPF. **G1**, [s. l.], 25 jan. 2021. Disponível em: <https://g1.globo.com/economia/tecnologia/blog/altieres-rohr/post/2021/01/25/>

vazamentos-de-dados-expoem-informacoes-de-223-milhoes-de-numeros-de-cpf.ghml. Acesso em: 15 out. 2023.

RUSSELL, Stuart; NORVIG, Peter. **Inteligência artificial**: uma abordagem moderna. 4. ed. Rio de Janeiro: LTC, 2022.

SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business intelligence e análise de dados para gestão do negócio**. Tradução: Ronald Saraiva de Menezes. 4. ed. Porto Alegre: Bookman, 2019.

Sobre a autora

Poliana N. Ferreira é mestra em ciência da computação (UFABC) e graduada em análise e desenvolvimento de sistemas (FIAP) e letras português-inglês (UNICSUL). É pesquisadora na área de aprendizado de máquina, computação quântica, *wearables* e informática na educação, com diversas publicações e prêmios. Atua também como professora de ciência de dados, estrutura de dados, IA, IoT e robótica. Além disso, é cofundadora, coordenadora e palestrante da comunidade de tecnologia AI Girls, que promove o protagonismo de mulheres na Inteligência Artificial.

